DATA ANALYSIS PROFESSIONAL

단기 합격을 위한 학습서

7일 완성
ADsP
통합 개념 정리

PDF 6종과 웹 1종을 비교하여 중복 설명은 통합하고
고유한 정의·공식·예시·시험 포인트는 모두 누적한 통합본

1과목 데이터 이해 · 2과목 데이터분석 기획 · 3과목 데이터분석

편집 원칙 같은 개념은 하나로 · 다른 내용은 계속 보강 · 시험 오개념은 교정

파란 소제목 / 비교표 / 필요한 도식 / 노란 시험 포인트

Contents

7일 학습 목차

DAY 01 1과목 · 데이터 이해
데이터에서 비즈니스 가치까지

DAY 02 2과목 · 데이터분석 기획
분석 과제 발견과 실행 설계

DAY 03 3과목 · 데이터분석
R 기초·데이터 전처리·기술통계·확률

DAY 04 3과목 · 데이터분석
통계적 추정·검정·회귀·시계열

DAY 05 3과목 · 데이터분석
데이터마이닝·분류·군집·연관

DAY 06 3과목 · 데이터분석
모형 평가와 R 결과 해석

DAY 07 3과목 · 데이터분석
텍스트·사회관계망·시뮬레이션·최적화

통합 기준 같은 내용은 중복 삭제 / 추가 정의·조건·사례는 기존 개념에 누적 / 서로 충돌하는 정보는 교정 부록 참조

페이지를 찾을 때는 PDF 뷰어의 책갈피에서 DAY와 부록을 선택하세요.

DAY 01 · 1과목 · 데이터 이해

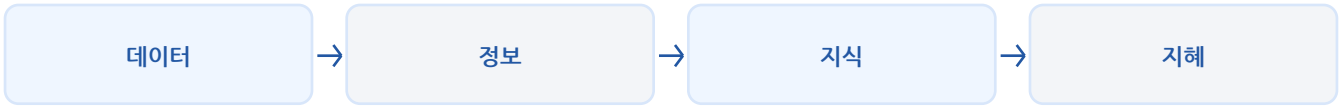
데이터에서 비즈니스 가치까지

데이터와 정보의 차이에서 출발해 데이터베이스, 빅데이터, 저장·활용·윤리를 연결한다.

01-01 데이터·정보·지식·지혜(DIKW)

핵심 개념 데이터는 기록한 사실, 정보는 가공해 의미를 얻은 결과, 지식은 정보에서 학습한 규칙, 지혜는 그 규칙으로 합리적 결정을 내리는 통찰이다.

단계	한눈에 구분
데이터	있는 그대로의 사실·수치
정보	비교·가공해 의미를 얻음
지식	정보에서 패턴·규칙을 발견
지혜	지식으로 적절한 판단·행동



- 단계의 상위로 갈수록 단순 사실에서 판단과 행동으로 이어진다
- D→I→K→W는 네 글자의 순서를 외우기보다 같은 사례를 네 단계로 바꾸어 설명할 수 있어야 한다.
- 데이터의 존재적 특성은 객관적 사실로서의 존재, 당위적 특성은 추론·판단을 위한 근거로서의 기능이라는 관점을 추가로 구별한다.
- DIKW의 최고 단계인 지혜는 근본 맥락을 바탕으로 선택하고 응용하는 판단이다. 정보의 단순 비교와 지혜의 의사결정을 구별한다.

예시 A마트 사과 1000원·B마트 800원(데이터)→B마트가 저렴함(정보)→저녁 할인 경향(지식)→구매 시점 결정(지혜).

시험 포인트 데이터를 비교한 문장은 정보, 규칙과 판단이 등장하면 지식·지혜를 구별한다.

참고: A3 B3 C1 D1 E2 E7

01-02 정성·정량 데이터

핵심 개념 정성 자료는 종류·특성·평가를 언어나 범주로 나타낸 것이고, 정량 자료는 수치의 양과 크기를 측정한 것이다.

구분	성질	간단한 예
정성(범주형)	종류·특성·등급	지역·만족도
정량(수치형)	양·크기·횟수	매출·방문횟수

- 정성적 자료가 반드시 비정형인 것은 아니다. 성별·지역처럼 표의 범주형 값도 정성적 자료다
- 정량적 자료는 나이·금액·기온처럼 수량 연산이 의미가 있다.
- 정성·정량은 응답·변수의 내용에 대한 분류다. 고객 만족 등급을 숫자로 코딩해도 값에 산술적 간격이 생기는 것은 아니다.

예시 고객 평가 '매우 만족'은 정성(서열), 결제 금액 32000원은 정량.

시험 포인트 정성/정량은 값의 의미, 정형/비정형은 저장 구조라는 다른 분류 기준이다.

참고: A4 B3 C1 D1 E3

01-03 정형·반정형·비정형 데이터

핵심 개념 정형 데이터는 정해진 행·열 스키마, 반정형은 태그·키 등의 일부 구조, 비정형은 일관된 표 스키마가 없는 자료다.

종류	구조	대표 자료
정형	행·열 형태 고정	CSV·RDB 테이블
반정형	태그·키 등 일부 구조	XML·JSON·HTML
비정형	일정한 표 스키마 없음	이미지·음성·자유글

- CSV·관계형 테이블은 정형, JSON·XML·HTML은 반정형, 일반 사진·음성·자유문은 비정형이다
- 비정형 데이터도 AI·텍스트 처리로 계산할 수 있으므로 '연산 자체 불가능'은 지나친 표현이다.
- 반정형 자료는 고정된 열 정의가 없더라도 키·태그·메타데이터로 의미와 구조를 탐색할 수 있다.

예시 쇼핑몰 주문 테이블=정형, API의 JSON 응답=반정형, 상품 리뷰 영상=비정형.

시험 포인트 데이터의 '구조'와 분석 가능성을 구분한다.

참고: A4 B3 C2 D1 E12

01-04 측정 척도 네 가지

핵심 개념 명목은 분류만, 서열은 순서까지, 등간은 동일한 간격까지, 비율은 절대영점과 비율 비교까지 가능한 척도다.

척도	판별 기준	예시
명목	구별만 가능	혈액형·지역
서열	순서 비교 가능	만족도·등급
등간	간격 비교 가능	섭씨 기온·연도
비율	절대영점·비율 비교	나이·금액·길이

- 명목(혈액형)에서 평균은 의미 없다
- 서열(만족도 등급)은 순서 있지만 등급 간 차이는 보장되지 않는다
- 섭씨온도는 등간, 길이·무게는 비율척도다.

예시 고객등급(서열), 방문횟수(비율), 지역명(명목), 섭씨기온(등간).

시험 포인트 명목→서열→등간→비율로 추가되는 성질을 생각한다.

참고: C20 D27

01-05 암묵지와 형식지

핵심 개념 암묵지는 체험으로 몸에 익어 말로 옮기기 어려운 지식이고, 형식지는 문서·그림·수식으로 표현돼 전달 가능한 지식이다.

구분	전달 방식	대표 예
암묵지	관찰·실습·경험	숙련된 손감각
형식지	문서·수식·매뉴얼	작업 지침서

- 암묵지는 개인 노하우·숙련 동작, 형식지는 설명서·설계도·매뉴얼이다
- 정보의 문서화 여부와 지식의 내면화 정도는 다르다.
- 교육영상은 형식지를 전달할 수 있지만 영상에 숙련 동작이 나온다는 이유만으로 암묵지가 모두 문서화되었다고 볼 수 없다.

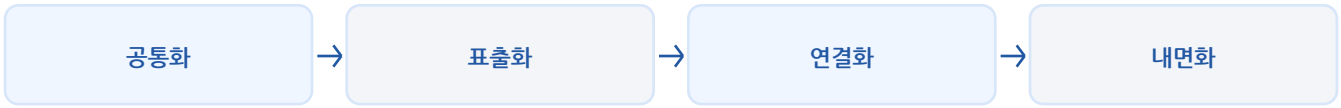
예시 숙련된 바리스타의 손감각을 레시피로 기록해 신규 직원 교육에 활용.

시험 포인트 암묵지=경험 중심, 형식지=표현·공유 용이.

참고: A3 B3 C1 D1 E4

01-06 SECI 지식변환 모델

핵심 개념 공통화(S)→표출화(E)→연결화(C)→내면화(I)를 통해 암묵지와 형식지가 순환하며 새로운 조직 지식이 만들어진다.



구분	의미·특징
공통화	암묵→암묵(함께 일하기)
표출화	암묵→형식(노하우 문서화)
연결화	형식→형식(문서 체계화)
내면화	형식→암묵(매뉴얼 실습으로 체화).

- 연결화(Combination)는 이미 표현된 여러 형식지를 수집·재구성해 새로운 체계로 만드는 과정이다.

예시 선배 작업 관찰→작업 매뉴얼 작성→부서별 매뉴얼 통합→신입 실습.

시험 포인트 SECI 방향은 네 쌍의 화살표로 검산한다: 암암·암형·형형·형암.

참고: A3 B3 C1 D1 E6

01-07 데이터베이스와 DBMS

핵심 개념 데이터베이스(DB)는 목적에 맞게 조직한 데이터의 집합이고 DBMS는 이를 생성·조회·변경·통제하는 소프트웨어다.

- 데이터베이스 시스템은 DB와 DBMS뿐 아니라 사용자·응용 프로그램 등으로 구성된다
- DBMS는 중복 최소화·동시 접근·무결성·보안·복구를 지원하지만 구축·관리 비용이 든다.
- DBMS는 DB 그 자체와 구분하며 검색·삽입·변경 외에도 접근 권한·무결성·복구를 담당한다.

예시 은행의 거래 기록이 DB라면 조회·갱신·권한을 관리하는 프로그램이 DBMS.

시험 포인트 DB≠DBMS. 저장된 데이터와 관리 프로그램을 바꾸어 선택지로 내기 쉽다.

참고: B3 C2 D1 E9

01-08 데이터베이스 설계의 네 단계

핵심 개념 업무에 필요한 자료를 정의한 뒤 개념적·논리적·물리적으로 구체화해 실제 DB에 구현하는 과정이다.

요구사항 → 개념 설계 → 논리 설계 → 물리 설계

구분	의미·특징
요구사항 분석	어떤 데이터를 누가 왜 이용하는지 확인.
개념적 설계	개체와 관계를 ER 모델로 표현.
논리적 설계	테이블과 속성·관계·제약을 정리.
물리적 설계	인덱스·파일 저장·성능을 구체화.

예시 온라인 서점의 고객·도서·주문 관계를 ERD로 그린 뒤 테이블을 설계하고 인덱스를 만든다.

시험 포인트 요구사항 → 개념 → 논리 → 물리. ERD는 개념적 설계, 인덱스는 주로 물리적 설계에서 다룬다.

참고: E14

01-09 데이터베이스 네 가지 기본 특성

핵심 개념 통합된 데이터, 저장된 데이터, 공용 데이터, 변화되는 데이터가 대표적인 데이터베이스의 기본 특성이다.

구분	핵심
통합된 데이터	불필요한 중복 최소화
저장된 데이터	컴퓨터 매체에 저장
공용 데이터	여러 목적·사용자와 공유
변화되는 데이터	추가·삭제·갱신 가능

- 통합은 불필요한 중복 최소화, 저장은 접근 가능한 저장매체, 공용은 여러 목적의 공동 이용, 변화는 삽입·삭제·갱신으로 최신성 유지다
- 일부 자료는 '운영 데이터'를 함께 설명하지만 네 가지 기본 특성의 네 번째는 '변화'로 구분해야 한다.
- 데이터의 갱신 가능성인 변화성은 데이터베이스가 업무 목적에 맞게 최신 상태를 유지해야 한다는 의미다.

예시 여러 부서가 공통 고객정보를 사용하고 주소 변경이 즉시 반영된다.

시험 포인트 시험 구분: 통·저·공·변. '운영 데이터'는 별도의 설명 맥락에서 나타날 수 있다.

참고: A3 B3 C1 D2 E15

01-10 데이터베이스 특징의 추가 관점

핵심 개념 DB는 정보를 기계로 읽고 검색하고 원격으로 조작할 수 있는 기반을 제공한다.

- 축적·전달 측면은 기계가독성·검색가능성·원격조작성
- 이용 측면은 신속한 정보 접근, 관리 측면은 표준화된 저장·갱신, 사회경제적 측면은 정보 활용 인프라다.

예시 원격 물류센터의 재고 데이터를 사무실에서 조회·수정한다.

시험 포인트 기계가독성·검색가능성·원격조작성은 통·저·공·변과 구분되는 설명 차원이다.

참고: C2 D2

01-11 RDBMS·ODBMS·NoSQL

핵심 개념 관계형 DBMS는 테이블과 키·SQL을 중심으로 데이터를 관리하고, 객체지향 DBMS는 객체·상속 등을 표현하며, NoSQL은 키값·문서·열·그래프 같은 다양한 모델을 쓴다.

구분	데이터 표현	예
RDBMS	테이블·키·관계	PostgreSQL
ODBMS	객체·상속	객체 기반 DB
NoSQL	문서·키값·그래프 등	MongoDB·Redis

- NoSQL이 'SQL을 절대로 쓰지 않는다'거나 '일관성은 항상 포기한다'는 뜻은 아니다.
- 관계형 DB도 분산·수평 확장이 가능하고 NoSQL도 ACID 특성이나 쿼리를 지원할 수 있으므로 고정된 성능 우열로 판단하지 않는다.
- RDBMS 예: MySQL·PostgreSQL·Oracle
- NoSQL 예: MongoDB(문서), Redis(키-값), Cassandra(분산 열 계열)

예시 주문·결제 정합성이 중요한 기록에 RDBMS, 유연한 JSON 문서를 다루는 데 문서형 DB 고려.

시험 포인트 RDBMS=관계·SQL, ODBMS=객체, NoSQL=다양한 비관계 모델.

참고: B3 C2 D2 E51

01-12 DBMS의 세대별 모델 변화

핵심 개념 DBMS는 데이터를 표현하는 방식이 계층·네트워크 구조에서 관계형 테이블, 객체 확장, 다양한 비관계형 저장소로 발전해 왔다.

- 초기 계층형·네트워크형 모델은 데이터 연결 구조가 복잡해 변경이 어렵다.
- 관계형 DBMS는 표·키·SQL 중심, 객체형 및 객체관계형은 복합 데이터 표현 지원, NoSQL은 문서·키값·그래프 등 여러 데이터 모델을 제공한다.
- 이러한 세대 구분은 교육용 개략 분류이므로 모든 제품이 정확히 한 세대에만 속하는 것은 아니다.

예시 기존 은행 거래 테이블은 관계형 DB, 구조가 계속 바뀌는 이벤트 JSON은 문서 DB를 고려한다.

시험 포인트 관계형과 NoSQL을 단순히 옛것/새것 또는 성능 우열로 비교하면 틀린다.

참고: E10-11

01-13 메타데이터·인덱스

핵심 개념 메타데이터는 데이터의 구조·의미·형식·관리 정보를 설명하는 데이터이고, 인덱스는 검색 대상에 빠르게 접근하기 위한 자료구조다.

- 메타데이터는 컬럼명·자료형·출처·갱신일 등을 포함한다
- 인덱스는 조회 성능을 높일 수 있지만 저장 공간과 갱신 비용이 추가된다.

예시 고객 테이블의 가입일 타입 설명은 메타데이터, 고객ID 검색용 B-tree는 인덱스.

시험 포인트 메타데이터=데이터 설명, 인덱스=검색 가속.

참고: B3 C2 D1

01-14 OLTP와 OLAP

핵심 개념 OLTP는 주문·입금 등 짧고 빈번한 거래를 정확히 처리하고, OLAP은 집계된 다차원 자료를 분석·탐색해 의사결정을 돕는다.

구분	OLTP	OLAP
목적	거래 처리	다차원 분석
질의	삽입·갱신·조회	집계·추세 분석
예	주문 접수	월별 매출 분석

- OLTP는 현재 거래·동시성·정합성 중시, OLAP은 과거 추세·집계·드릴다운 중시
- 분석 데이터는 흔히 DW에 적재해 OLTP 업무와 부하를 분리한다.
- OLTP는 거래 단위의 정확한 현재 상태, OLAP은 다양한 축으로 드릴다운·집계하는 분석 질의에 더 적합하다.

예시 결제 승인은 OLTP, 지난 분기 지역별 매출 비교는 OLAP.

시험 포인트 거래 처리(T)와 분석 처리(A)를 구분한다.

참고: B3 C2 D2 E18

01-15 ERP·CRM·SCM

핵심 개념 ERP는 전사 자원 관리, CRM은 고객관계 관리, SCM은 공급망과 물류의 흐름을 최적화하는 시스템이다.

- ERP는 회계·인사·생산 통합, CRM은 고객 접점·캠페인·이탈·충성도, SCM은 조달·재고·생산·배송 연결
- 서로 연동할 수 있다.
- 고객 경험을 다루는 CRM과 상품의 수급·배송을 다루는 SCM은 서로 연계되어 구매 데이터의 가치를 키울 수 있다.

예시 고객별 재구매 마케팅=CRM, 물류 배송 시점 관리=SCM, 급여·회계 통합=ERP.

시험 포인트 고객=CRM, 공급망=SCM, 전사 자원=ERP.

참고: B3 C2 D2 E20

01-16 EAI와 기업 애플리케이션 통합

핵심 개념 EAI는 ERP·CRM·SCM 등 서로 다른 업무 애플리케이션이 데이터를 교환하고 함께 작동하도록 연결하는 통합 체계다.

- ERP가 기업 자원을 관리하는 기능 자체인 반면 EAI는 여러 업무 시스템 사이의 연계·동기화를 지원한다.
- 인터페이스·메시지 변환·업무 연계 규칙을 관리하며 시스템 전체를 단일 프로그램으로 합치는 것을 의미하지 않는다.

예시 쇼핑몰 신규 주문을 ERP 재고와 CRM 고객 이력 양쪽에 연결한다.

시험 포인트 ERP=업무 통합 관리, EAI=서로 다른 응용 시스템의 연계.

참고: E22

01-17 BI·BA·RTE·KMS

핵심 개념 BI는 보고·대시보드로 현황을 파악하고, BA는 통계·예측·최적화에 더 무게를 둔다. RTE는 실시간 대응 기업, KMS는 조직의 지식관리 시스템이다.

- BI의 Ad-hoc 보고서는 특정 질문이 생겼을 때 만드는 즉석 보고서
- BA는 분석을 통한 의사결정 고도화
- RTE는 변화에 대한 대응 지연을 줄이고, KMS는 노하우의 축적·검색·공유를 지원한다.
- BI는 주로 과거와 현재를 파악하는 보고·대시보드, BA는 통계·수학적 모델을 통해 예측·최적화로 확장하는 맥락에서 대비한다.

예시 월 매출 현황 BI, 구매확률 예측 BA, 수요 급증 즉시 생산조정 RTE, 사내 위키 KMS.

시험 포인트 BI(현황)와 BA(분석·예측)의 중심 목적 차이를 본다.

참고: B3 C2 D2 E21

01-18 데이터 웨어하우스(DW)·EDW·데이터 마트

핵심 개념 DW는 의사결정을 위해 여러 원천의 데이터를 주제별로 통합해 장기간 보관한 분석용 저장소다.

- DW의 전형적인 성격은 주제 지향·통합·시계열·비휘발
- EDW는 전사 범위를 강조하며 데이터 마트는 부서·업무용 작은 분석 저장소다
- '비휘발'은 분석 이력이 빈번히 거래 갱신되지 않는다는 뜻이지 영구 수정 불가를 뜻하지 않는다.
- 데이터 마트는 DW의 일부를 단순히 잘라낸 경우뿐 아니라 특정 업무 영역에 맞춰 독립 설계해 운영할 수도 있다.

예시 전사 판매 이력을 DW에 모으고 마케팅 부서용 고객 데이터 마트를 구성한다.

시험 포인트 DW 네 성격과 DB 네 특성은 다른 암기 묶음이다.

참고: A5 B3 C2 D3 E16

01-19 데이터 레이크와 ETL·ELT

핵심 개념 데이터 레이크는 정형·반정형·비정형 원천 자료를 폭넓게 저장하고, ETL은 추출→변환→적재 순서의 통합 절차다.

- ETL은 가공 후 적재, ELT는 원천을 적재한 뒤 분석 환경에서 변환
- 레이크도 메타데이터·보안·품질 관리가 없으면 활용이 어려운 '데이터 늪'이 될 수 있다.

예시 로그 원본은 레이크에, 표준화된 일별 매출 테이블은 DW에 적재한다.

시험 포인트 DW=정돈된 분석 저장, 레이크=다양한 원천 보관(관리 불필요 X).

참고: A5 B3 D23

01-20 기업 및 공공 분야 DB 활용

핵심 개념 DB는 제조·유통·금융·물류·의료·교통·교육의 운영 기반이며 각 분야에서 서로 다른 의사결정을 지원한다.

- 제조는 설계·생산·재고, 유통은 상품·CRM, 금융은 거래·위험관리, 교통은 ITS, 지리는 GIS, 의료는 진료·영상, 교육은 학사·행정정보를 활용한다
- RTE·RFID·EDI 등 관련 기술과 함께 발전했다.
- 공공 부문의 GIS·ITS·의료 EDI·NEIS는 지리·교통·의료·교육 영역에서 데이터베이스가 사회 인프라로 작동하는 예이다.

예시 대중교통 센서 자료를 모아 혼잡 시간대 배차를 조정한다.

시험 포인트 영역별 용어: ITS=지능형 교통, GIS=지리정보, RFID=무선 주파수 인식, EDI=전자 문서 교환.

참고: B3 C3 D2 E23

01-21 빅데이터 3V·4V·5V

핵심 개념 기본 3V는 규모(Volume)·속도(Velocity)·다양성(Variety)이며, 확장 관점에서 가치(Value)·신뢰성(Veracity)을 더하기도 한다.

V	의미	판단 질문
Volume	규모	얼마나 많은가?
Velocity	속도	얼마나 빠른가?
Variety	다양성	어떤 유형인가?
Value	가치	무엇을 개선하는가?
Veracity	신뢰성	믿을 만한가?

- 4V가 어느 네 번째 V를 택했는지는 교재에 따라 다르다. ADsP 투자 대비 효과 비교에서는 3V를 비용·난이도 쪽, Value를 사업 효과 쪽으로 설명한다
- 단순히 V 개수가 많다고 출제 기준이 통일된 것은 아니다.
- 5V는 Volume·Velocity·Variety에 가치(Value)와 신뢰성(Veracity)을 더한 설명이며, 4V의 네 번째 V는 교재 맥락에 따라 명시해야 한다.

예시 초당 대량 센서(속도), 이미지·문서(다양성), 수년간 로그(규모), 불량 탐지 성과(가치).

시험 포인트 3V는 공통. 4V는 출처 맥락에서 Value인지 Veracity인지 확인한다.

참고: A4 B4 C3 D3 E24

01-22 빅데이터의 출현 배경

핵심 개념 디지털 기록의 확대와 센서·SNS·인터넷·저렴한 저장장치·클라우드·분산처리 발전이 데이터 양과 활용 범위를 키웠다.

- 산업계는 고객정보 누적, 학계는 대규모 데이터 활용 연구, 기술계는 모바일·네트워크·분산 병렬처리 발전이 견인했다
- 양의 축적이 새로운 분석 기회를 만드는 '양질 전환' 관점도 등장한다.
- 대용량 처리 비용을 낮춘 클라우드와 분산 저장·처리 기술의 발전은 데이터의 양뿐 아니라 활용 가능성의 확대로 이어졌다.
- 산업계의 데이터 축적, 학계의 데이터 기반 연구, 기술계의 저비용 저장·처리가 함께 빅데이터 확대를 이끌었다.

예시 모바일 앱 클릭 로그를 클라우드에 장기간 저장하고 추천 모델에 활용한다.

시험 포인트 빅데이터는 큰 파일 한 개가 아니라 자료·기술·조직의 변화까지 포함할 수 있다.

참고: A4 B4 C3 D3 E25 E26

01-23 빅데이터의 네 가지 변화

핵심 개념 전처리 중심→사후처리 활용, 표본→전수 활용 가능성, 질→양의 확대, 인과→상관 발견 확대가 교재에 나오는 패러다임 서술이다.

- 이는 변화의 '방향'을 강조한 표현이지 품질관리·표본조사·인과적 검증이 불필요하다는 뜻은 아니다
- 전수 분석도 편향된 수집이나 측정 오류를 자동 해결하지 못한다.
- 전수조사 가능성이 늘었다고 대표성 있는 표본·실험설계가 불필요해지는 것은 아니다.

예시 전체 구매기록에서 의외의 연관을 탐색한 뒤 검증 실험을 설계한다.

시험 포인트 '이전 방식 완전 폐지' 같은 절대 표현을 경계한다.

참고: B4 C4 D4 E28

01-24 빅데이터의 산업적 비유

핵심 개념 빅데이터는 산업혁명의 원료인 철·석탄, 21세기 원유, 세상을 새로 보게 한 렌즈, 공동 활용 기반인 플랫폼에 비유된다.

- 철·석탄/원유는 생산 요소, 렌즈는 새로운 발견, 플랫폼은 다양한 주체가 공유하는 활용 기반이라는 강조점이 다르다.
- 렌즈는 새로운 패턴을 발견하는 관찰 도구, 플랫폼은 다양한 서비스가 함께 이용할 수 있는 기반이라는 비유다.

예시 도로 데이터 개방 플랫폼을 여러 기업이 활용해 교통 서비스를 개발한다.

시험 포인트 렌즈는 구글 Ngram Viewer 사례, 플랫폼은 공동 활용이라는 의미.

참고: B4 C4 D4 E27

01-25 빅데이터 가치 측정의 어려움

핵심 개념 데이터는 재사용·재조합할 수 있고 미래 기술에 따라 뜻밖의 가치가 생겨 현재의 금전가치가 고정되기 어렵다.

- 누가·언제·어떤 목적에 사용할지 예측이 어렵다
- 분석 기술이 발전하면 과거에 가치 없던 자료도 새로운 재료가 된다
- Value가 모든 데이터셋의 즉각적인 수익을 의미하지는 않는다.
- 수집 시점에는 유용성이 낮아 보였던 센서 기록도 새로운 분석 방법이나 다른 데이터와의 결합으로 후속 가치를 만들 수 있다.

예시 택배 이동기록을 배송 예측뿐 아니라 안전사고 예방에도 활용한다.

시험 포인트 재사용·재조합·기술발전의 세 이유를 구분한다.

참고: A4 B4 C4 D4 E30

01-26 빅데이터의 기본 활용 기법

핵심 개념 연관규칙·유형분석·유전알고리즘·기계학습·회귀·감성분석·사회관계망 분석은 서로 다른 질문에 답한다.

- 연관은 함께 일어남, 유형/분류는 어떤 범주인가, 유전알고리즘은 제약 아래 좋은 해 탐색, 회귀는 수치 관계, 감성은 텍스트 태도, SNA는 연결 구조를 분석한다.
- 대표적 적용 영역은 추천·연관규칙·사회관계망 영향력 분석·감성분석·최적화이며 데이터의 구조에 따라 분석 방법을 선택한다.
- 유전 알고리즘은 자연 선택·변이·교배를 흉내 내 해 공간을 탐색한다. 목적변수가 범주형인 분류 분석과 구별한다.

예시 고객 이탈=분류, 배송 경로=최적화, SNS 영향력=SNA, 리뷰 만족도=감성.

시험 포인트 문제의 출력 형태·데이터 구조부터 기술을 구분한다.

참고: B4 C4 D5 E31 E32

01-27 빅데이터 위험 세 가지

핵심 개념 사생활 침해, 결과가 나오기 전 개인에게 책임을 묻는 원칙의 훼손, 잘못된 결과를 과신하는 데이터 오용이 주요 위험이다.

- 개인 재식별은 프라이버시, 미래 범행 점수로 처벌하면 결과 기반 책임 훼손, 편향된 신용평가를 무비판적으로 활용하면 오용
- 알고리즘 감시·감사·이의제기 절차가 필요하다.
- 개인정보 침해·결과 책임의 왜곡·분석 결과의 오용은 서로 다른 위기이며 각각 보호·책임·검증 장치가 중요하다.

예시 이상 신용점수로 대출을 자동 거절할 때 판정 이유와 구제 절차를 제공한다.

시험 포인트 위험과 대응을 짝지어 이해한다: 프라이버시 보호, 결과 기반 책임, 알고리즘 검증.

참고: A5 B4 C5 D5 E34

01-28 가명처리와 익명처리

핵심 개념 가명처리는 추가 정보 없이는 개인을 바로 알아보기 어렵도록 치환하며, 익명처리는 합리적으로 예상 가능한 수단으로도 개인을 알아볼 수 없도록 하는 처리다.

- 가명정보는 추가 정보 결합으로 재식별 가능성이 남는다
- 마스킹·총계처리·삭제·범주화는 개인정보 보호를 돕는 기술이며 어느 한 기술만으로 법적 익명성이 자동 보장되지는 않는다.

예시 이름 '김하늘'→'회원 A12'(가명), 나이 37→30대(범주화), 주민번호 일부 별표(마스킹).

시험 포인트 '절대 재식별 불가능' 또는 '가명정보는 아무 목적이나 자유 사용' 같은 단정은 부정확하다.

참고: A5 B4 C5 D6

01-29 데이터 3법과 개인정보 관리

핵심 개념 데이터 3법은 개인정보보호법·정보통신망법·신용정보법을 함께 부르는 통칭으로, 개인정보 보호와 데이터 활용의 법적 틀과 연결된다.

- 데이터의 분석 가능성만으로 개인정보 처리의 적법성이 확보되지 않는다.
- 가명정보와 익명정보, 처리 목적, 법률상 허용 요건을 구분해야 하며 세부 요건은 현행 법령으로 확인해야 한다.

예시 고객 연구용 데이터를 준비하면서 식별 가능성·처리 목적·보관 및 접근 통제를 확인한다.

시험 포인트 데이터 3법은 세 법률의 이름이며, 가명처리=무조건 자유 활용이라고 외우면 안 된다.

참고: E36-38

01-30 비식별 처리 기법 다섯 가지

핵심 개념 개인정보 식별 위험을 낮추기 위해 값을 대체하거나 삭제·묶기·가리기·집계하는 여러 방법을 구별한다.

- 가명처리 후에도 다른 정보와 결합하면 다시 식별될 수 있으며 기법을 하나만 적용한다고 익명성이 자동 보장되지 않는다.
- 가명처리: 식별자를 다른 값으로 치환, 총계처리: 개인별 수치 대신 집계만 제공.
- 삭제: 직접·간접 식별값을 제거, 범주화: 상세 나이 대신 연령대, 마스킹: 이름 일부를 별표 처리.

예시 홍길동/35세/서울 → H001/30대/수도권으로 변환하되 별도 키 관리와 재식별 위험을 점검한다.

시험 포인트 대체·집계·삭제·범주화·마스킹을 예시에서 구분한다.

참고: E37-38

01-31 데이터 사이언스의 세 영역

핵심 개념 데이터 사이언스는 분석(통계·수학·모형), IT/데이터 관리(프로그래밍·엔지니어링), 비즈니스 이해(문제 정의·전달)를 연결하는 학문이다.

- 데이터 마이닝이 규칙 탐색에 더 집중한다면 데이터 사이언스는 수집·배포·설명과 비즈니스 반영을 함께 포괄한다
- 정형뿐 아니라 비정형도 다룬다.
- 데이터 마이닝은 주로 패턴 추출 활동이고 데이터 사이언스는 수집·관리·분석·활용·전달까지 더 넓은 범위를 다룬다.
- 데이터 사이언스에서 IT는 데이터 기반, Analytics는 정량적 분석, 비즈니스 이해는 실질적 문제 해결·결과 전달을 담당한다.

예시 고객 이탈 이유 분석부터 데이터 수집·모형 설계·경영진 발표까지 진행한다.

시험 포인트 Analytics·IT·Business가 세 원의 교집합으로 제시될 수 있다.

참고: B4 C6-7 D6 E43 E44

01-32 데이터 사이언티스트의 역량

핵심 개념 하드 스킬은 분석 이론·통계·프로그래밍·도구 활용, 소프트 스킬은 비즈니스 통찰·설득·협업·스토리텔링이다.

구분	주요 역량
하드 스킬	통계·머신러닝·R·SQL·인프라
소프트 스킬	문제 정의·통찰·소통·설득

- 시각화는 기술을 사용하는 측면과 결과를 전달하는 측면이 모두 있어 문제의 관점을 봐야 한다
- 특정 역량 분류를 말할 때는 인용된 프레임워크의 기준을 따른다.
- 기술·모델링뿐 아니라 결과를 설득력 있게 전달하는 소프트 스킬이 분석 역량과 결합되어야 한다.
- 하드 스킬은 이론·분석기술, 소프트 스킬은 호기심·스토리텔링·협업·비판적 사고로 예시를 구분한다.

예시 수요 예측 모형을 만든 뒤 재고 담당자가 행동할 수 있도록 설명한다.

시험 포인트 '소프트 스킬=선천적 감각'이 아니라 문제 이해·소통 능력이다.

참고: A4 B4 C6-7 D6 E45 E46

01-33 인문학적 통찰과 전략적 분석

핵심 개념 데이터만으로 보이지 않는 고객 맥락·동기·사회적 변화까지 고려해 핵심 사업 문제에 답하는 것이 전략적 분석이다.

- 현황 확인 중심의 일차 분석도 필요하지만 장기 경쟁우위는 효과적 의사결정·업무 내재화와 연결될 때 강화된다
- 관찰된 상관만으로 모든 행동 원인을 설명할 수 없다.
- 분석 성과의 핵심은 데이터 처리량이 아니라 조직의 중요한 의사결정에 연결되는 전략적 질문을 만드는 것이다.
- 일차적 업무분석은 내부 문제를 개선하고 전략적 가치 기반 분석은 외부 환경·시장 변화를 반영한 경쟁 우위를 탐색한다.

예시 앱 이용시간 감소 수치를 확인한 뒤 고객 인터뷰로 사용 맥락을 탐색한다.

시험 포인트 데이터가 많다는 것과 사업 성과를 낸다는 것은 별개의 문제다.

참고: C6-8 D6-8 E40 E42

01-34 디지털화·연결·에이전시

핵심 개념 디지털화는 현실 정보를 데이터로 만들고, 연결은 정보와 주체를 결합하며, 에이전시는 연결된 시스템이 판단·행동에 영향을 주는 단계다.

- 비즈니스 가치의 발전을 설명하는 개념적 관점으로, 데이터→기술→인력의 '활용 3요소'와 다른 분류다.
- 연결은 단순 온라인 저장이 아니라 서로 다른 디지털 정보·시스템의 상호작용, 에이전시는 그 연결 속에서 판단과 행동이 가능한 상태다.

예시 공장 온도 기록→설비끼리 센서 정보 공유→온도 이상 시 자동 조치.

시험 포인트 Digitalization→Connection→Agency의 맥락을 묻는 선택지에 주의.

참고: B4 C8 D8 E47

01-35 데이터·기술·인력 3요소

핵심 개념 빅데이터의 활용에는 데이터화된 자료, 분석을 가능하게 하는 기술·알고리즘, 가치를 이해하고 해석할 사람이 함께 필요하다.

- 데이터에는 IoT·디지털 발자국, 기술에는 저장·분산처리·AI, 인력에는 데이터 사이언티스트·알고리즈미스트가 대응한다
- 거버넌스와 조직문화도 실제 활용성을 좌우한다.
- 데이터 자체만 많아서는 분석 가치가 생기지 않으며 수집·처리 기술과 문제를 해석하는 인력의 결합이 필요하다.

예시 고객 로그만 쌓지 않고 모델링 인력과 배포 시스템을 함께 확보한다.

시험 포인트 3V, 가치 패러다임 3요소, 활용 자원 3요소를 혼동하지 않는다.

참고: B4 C5 D8 E39

01-36 데이터 거버넌스 3요소

핵심 개념 데이터 거버넌스는 전사 데이터를 같은 기준으로 관리하도록 원칙·조직·프로세스를 마련하는 체계다.

원칙	조직	프로세스
정책·기준	책임·권한·조직	업무절차·품질 점검

- 원칙은 품질·보안·표준 기준, 조직은 책임자·역할, 프로세스는 정의·승인·변경·감사 절차
- 데이터 사전·메타데이터·마스터 데이터·저장소와 연결된다.
- 데이터 거버넌스의 3요소는 원칙(기준), 조직(책임), 절차(실제 실행)로 구분한다.

예시 부서마다 고객ID 기준이 달라지는 문제를 전사 표준으로 통제한다.

시험 포인트 원·조·절. 개별 예측 알고리즘 자체와 거버넌스 구성요소를 구분한다.

참고: A5 B6 C14-17 D16-17 E106

01-37 데이터 품질·표준화·마스터 데이터

핵심 개념 마스터 데이터는 고객·상품·조직처럼 업무 전반에서 공통으로 참조하는 핵심 기준 정보이며 데이터 사전은 용어·형식을 정의한다.

- 표준화는 용어와 코드·도메인 규칙 통일, 품질 관리는 정확성·완전성·일관성·적시성 등을 다룬다
- 데이터 구조 변경 전 영향평가와 담당자의 책임 정의가 중요하다.
- 데이터 사전·메타데이터·표준화 활동·저장소 관리를 이용해 명칭과 의미가 바뀌지 않도록 관리한다.

예시 회사마다 다른 지역코드를 표준 코드로 통일한다.

시험 포인트 마스터 데이터는 '절대로 변하지 않는 데이터'라는 뜻이 아니다.

참고: B6 C14 D16-17 E107

01-38 저장 용량 단위와 비트·바이트

핵심 개념 비트(bit)는 0·1 한 자리, 바이트(byte)는 일반적으로 8비트이며 자료 크기는 KB~PB 같은 단위로 표현한다.

- SI 접두어 KB·MB·GB는 1000배 체계, KiB·MiB·GiB는 1024배 이진 체계다
- 워드(word) 크기는 CPU 아키텍처에 따라 다르며 모든 문자를 무조건 1바이트·2바이트로 고정할 수 없다.

> **예시** 10 GB 로그파일과 10 GiB 파일의 크기는 정확히 동일하지 않다.

시험 포인트 bit/byte, SI/IEC 표기를 구별한다.

참고: B4 C4 D2

DAY 02 · 2과목 · 데이터분석 기획

분석 과제 발견과 실행 설계

데이터보다 먼저 문제를 정하고, 분석 방법론·과제 선별·조직·거버넌스를 통합해 읽는다.

02-01 데이터분석 기획의 목적

핵심 개념 분석 기획은 해결할 업무문제, 기대 가치, 필요한 데이터·방법·일정·자원·위험을 분석 시작 전에 정하는 일이다.

- 데이터 확보 가능성과 모델의 기술적 적합성뿐 아니라 실제 업무에 쓸 수 있는지까지 고려한다
- 목표 불명확한 모델은 정확도가 높아도 유용하지 않을 수 있다.
- 분석 가능 데이터 확보, 재활용 가능한 유스케이스 탐색, 예상 장애요소 검토는 기획 실패를 줄이는 기본 확인 영역이다.

예시 쇼핑몰의 '매출 증가'를 고객 이탈률 감소와 재구매율 개선 같은 구체 목표로 정의한다.

시험 포인트 Data·Model·Business case의 균형이 중요하다.

참고: A6 B5 C7 D9 E50

02-02 분석 대상 What·방법 How 2×2

핵심 개념 대상(무엇을 분석할지)과 방법(어떻게 분석할지)을 각각 알고 있는지에 따라 최적화·솔루션·통찰·발견으로 구분한다.

	방법(How) O	방법(How) X
대상 O	**최적화** 대상 O · 방법 O	**솔루션** 대상 O · 방법 X
대상 X	**통찰** 대상 X · 방법 O	**발견** 대상 X · 방법 X

- What O·How O=최적화
- What O·How X=솔루션
- What X·How O=통찰
- What X·How X=발견. 같은 개념을 '대상'과 '방법' 축의 위치를 바꿔 그려도 판단은 같다.
- What은 분석할 대상, How는 적용 가능한 방법이다. 대상 O·방법 X가 솔루션이라는 축 확인법을 포함한다.

예시 이탈 고객이라는 문제는 알지만 해결법을 모름=솔루션, 패턴 탐색법은 있지만 발견할 문제를 모름=통찰.

시험 포인트 일부 PDF에는 2×2 셀의 문구·설명이 바뀐 부분이 있으므로 축의 뜻으로 검증한다.

참고: A6 B5 C7 D9 E48

02-03 하향식 접근 Top-down

핵심 개념 이미 알고 있는 비즈니스 문제를 정리하고 원인·해결방안·타당성을 단계적으로 탐색한다.

- 문제 탐색→문제 정의→해결안 탐색→타당성 검토의 흐름
- 고객·제품·업무·지원인프라·규제·감사 관점에서 빠진 문제를 확인한다.
- 하향식은 해결할 문제를 명확히 인지할 때, 상향식은 데이터로 문제를 발견할 때 유용하며 혼용도 가능하다.
- 문제 탐색→문제 정의→해결방안 탐색→타당성 검토의 순서에서 마지막은 데이터·비용·기술적 실행 가능성을 평가한다.

예시 배송 지연 문제를 먼저 정하고 지연 원인을 예측할 변수와 데이터를 정한다.

시험 포인트 하향식은 문제 해결(Problem Solving) 중심, 지도학습과 자주 연결되지만 동의어는 아니다.

참고: A6 B5 C10 D9 E72 E75

02-04 상향식 접근 Bottom-up

핵심 개념 무엇이 문제인지 명확하지 않을 때 데이터의 특성·패턴을 탐색하면서 새로운 분석 질문을 발굴한다.

- 비지도학습·EDA·프로토타입이 도구가 될 수 있다
- 데이터 자체에 나타난 뜻밖의 현상을 비즈니스 문제가치로 연결해야 한다.
- 상향식은 비지도 탐색과 연관이 깊지만 비지도학습만 사용해야 하는 고정 규칙은 아니다.

예시 방문기록을 군집화해 회사가 몰랐던 고객 행동 유형을 발견한다.

시험 포인트 상향식=문제 발견(Discovery), 엣지 컴퓨팅 같은 처리 '위치' 개념과 구별.

참고: A6 B5 C10-11 D9 E83

02-05 디자인 씽킹과 발산·수렴

핵심 개념 디자인 사고는 사용자를 관찰·공감해 문제를 다시 정의하고, 아이디어·시제품·검증을 반복하는 접근이다.

- 공감→문제정의→아이디어→프로토타입→테스트의 기본 흐름
- 다양한 아이디어를 넓히는 발산은 상향식, 후보를 평가·결정하는 수렴은 하향식 접근과 연결된다.
- 발산은 다양한 후보를 넓히는 접근, 수렴은 대안을 검증·선택하는 접근이며 디자인 씽킹은 두 사고를 반복한다.

예시 고객의 구매 포기 과정을 관찰한 후 결제 단계를 바꾸는 시안을 테스트한다.

시험 포인트 상향식만의 기법이라기보다 상향식·하향식 사고의 반복 결합이다.

참고: A8 B5 C11 D9 E73

02-06 디자인 씽킹의 5단계

핵심 개념 디자인 씽킹은 사용자의 경험을 관찰해 문제를 다시 정의하고 여러 해결안 중 검증 가능한 아이디어를 반복적으로 발전시키는 방식이다.



- 공감(Empathize) → 정의(Define) → 아이디어 발상(Ideate) → 프로토타입(Prototype) → 테스트(Test).
- 상향식 발산과 하향식 수렴을 연결하지만 단계 진행은 실제로 반복·되돌아갈 수 있다.
- 프로토타입 개발 모델과 디자인 씽킹은 연관되어도 동일한 범위의 개념은 아니다.

예시 배송 불만 인터뷰→숨은 지연 문제 정의→배송 안내 화면 시제품→사용자 테스트.

시험 포인트 공감·정의·발상·시제품·시험을 순서대로 구별한다.

참고: E73-74

02-07 문제 발굴의 비즈니스 모델 관점

핵심 개념 사업 가치를 만드는 주요 부분을 업무·제품·고객·지원 인프라·규제/감사로 나누어 분석 기회를 찾는다.

- 시장·경쟁·사회환경은 STEEP(사회·기술·경제·환경·정치), 경쟁자 확대(기존 경쟁·신규 진입·대체재), 고객 니즈(고객·채널·영향자) 등의 틀로 살펴본다.
- 비즈니스 모델 기반 문제 탐색은 업무·제품·고객·규제와 감사·지원 인프라의 다섯 영역에서 분석 기회를 찾는다.

예시 신규 배송 서비스 기획 시 경쟁 앱, 고객 불편, 물류·규제 조건을 함께 분석한다.

시험 포인트 STEEP는 거시 환경 분석 틀이고 PESTEL과 유사하나 범위를 확인한다.

참고: B5 C10 D9-10 E78

02-08 비즈니스 모델 캔버스·전략테마

핵심 개념 비즈니스 모델을 구성 요소로 나눠 어떻게 가치를 만들고 전달하는지 정리하고 분석 후보를 사업 전략과 연결한다.

- 고객가치·채널·관계·활동·파트너·자원·비용·수익과 같은 구성 요소를 보며, 조직의 '전략테마→실행활동→분석 질문'을 구체화한다
- 현장 상황에 따라 9블록을 요약한 5영역 모델도 사용한다.

예시 고객 유지를 핵심테마로 정한 뒤 반복구매에 영향을 주는 경험을 분석 질문으로 바꾼다.

시험 포인트 비즈니스 모델 그림을 그리는 목적은 예쁜 도표가 아니라 실행 가능한 분석 질문 발굴이다.

참고: B5 D9-10

02-09 STEEP와 시장 탐색

핵심 개념 STEEP는 Social·Technological·Economic·Environmental·Political의 다섯 거시환경 요인이다.

- 거시환경과 경쟁구조, 고객·채널·영향자, 내부·파트너 역량을 구분해 관찰한다
- 한 관점만으로 분석 과제를 확정하지 않고 외부 참고 사례와 결합할 수 있다.
- 경쟁자 확대(대체자·경쟁자·신규진입자), 시장 니즈(고객·채널·영향자), 역량 재해석(내부·파트너) 관점을 구분한다.

예시 정책 변화와 스마트폰 보급 속도를 함께 고려해 모바일 인증 수요를 전망한다.

시험 포인트 사회·기술·경제·환경·정치, 다섯 단어의 의미를 알아야 적용 문제를 푼다.

참고: B5 C10 D9 E79

02-10 외부 참조·유즈케이스 분석

핵심 개념 다른 기업·업종의 모범 분석 사례를 참고하거나 실제 업무 시나리오를 세부 질문으로 바꾸어 과제를 발굴한다.

- 유즈케이스는 '누가 어떤 상황에서 무엇을 결정하는가'라는 작업 맥락을 드러낸다
- 그대로 복제하지 않고 조직의 데이터·자원·규제에 맞는지 판단한다.
- 외부 참조 모델은 업종별 사례를 벤치마킹해 후보를 발굴하지만 그대로 복제하지 않고 자사 데이터·목표에 맞게 다시 평가한다.
- 분석 유즈케이스는 추상적인 사업 문제를 데이터 분석으로 옮기기 위해 문제 설명·기대 효과·판단 기준을 구체화한다.

예시 타 업계의 이탈예측 방법을 온라인 교육 서비스에 맞게 변형한다.

시험 포인트 참조사례는 출발점이고 과제 정의서가 실행 조건을 구체화한다.

참고: B5 D9-11 E81 E82

02-11 연속 질문법과 문제 정련

핵심 개념 큰 업무 목표를 작은 질문으로 나누어 최종적으로 데이터로 답할 수 있는 분석 문제를 만드는 방법이다.

- 질문에 대한 질문을 이어 가거나 행위자(agent)·객체·장소·이벤트 관점으로 누가 무엇을 왜 했는지 파고든다
- 결과 지표를 측정 가능하게 정의해야 한다.

예시 '매출이 왜 줄었나?'→어느 고객군? 어느 상품? 어떤 경로?→재구매율 감소 원인 분석.

시험 포인트 관찰 가능하고 검증 가능한 질문으로 바꾸지 못하면 분석 성과를 판단할 수 없다.

참고: D11-12

02-12 인과 고리도 CLD·이벤트 반응 분석

핵심 개념 인과고리도(CLD)는 요소들이 서로 영향을 주는 방향과 강화·균형 피드백을 그림으로 표현하는 도구다.

- 이벤트-반응 관점은 사건이 발생했을 때 어떤 판단·조치가 이어져야 하는지 분석 서비스의 요구사항으로 번역한다
- 인과 방향을 가정했더라도 데이터·실험으로 검증해야 한다.

예시 고객 불만 증가→상담량 증가→응답 지연→불만 재증가의 강화고리를 탐색한다.

시험 포인트 CLD의 화살표는 구조적 가설이지 인과효과가 실험으로 확정됐다는 뜻이 아니다.

참고: D11-13

02-13 의사결정 요소와 분석 패턴 서비스

핵심 개념 어떤 정보가 어떤 의사결정에 쓰이고, 분석 패턴이 언제 누구에게 제공되는지를 모델화한다.

- 의사결정 요소를 수치 지표·행동 옵션·제약으로 분해해 분석체계와 서비스 아키텍처를 정한다
- 분석 결과를 저장만 하지 말고 실제 운영 이벤트에 연결한다.

예시 고객 이탈 위험점수 상승 시 담당자에게만 CRM 작업을 추천한다.

시험 포인트 분석모델 자체와 분석 결과를 소비하는 업무 서비스는 별도 설계 대상이다.

참고: D12-13

02-14 분석 방법론의 계층

핵심 개념 방법론은 보통 큰 단계(Phase)→단위 활동(Task)→구체 작업(Step)으로 세분화한다.

- 단계는 전체 관리 구간, 태스크는 단계에서 달성할 단위 업무, 스텝은 수집·인터뷰·검사 같은 실제 수행 절차다
- 템플릿과 산출물은 재현성을 높인다.
- 단계(Phase)는 프로젝트의 큰 영역, 태스크(Task)는 작업 단위, 스텝(Step)은 도구·입력·출력으로 구체화된 수행 단위로 구분한다.

예시 데이터 준비(Phase) 안에 정제(Task)와 NA 대치 작업(Step)을 둔다.

시험 포인트 단·태·스 순서. 단계와 태스크를 같은 수준으로 보지 않는다.

참고: A7 B5 C8 D18 E65

02-15 분석 방법론의 네 구성요소

핵심 개념 분석 방법론에는 순서만이 아니라 실제 일을 수행할 방식·도구·결과물이 함께 필요하다.

- 도구와 기법(Tools & Techniques): R·Python·통계·알고리즘 등 구체적 실행 수단.
- 템플릿과 산출물(Templates & Outputs): 분석 계획서·데이터 정의서·모델 보고서 등.
- 상세한 절차(Procedure): 분석을 어떤 순서로 진행하는가.
- 방법(Methods): 어떤 사고·분석 접근으로 해결하는가.

예시 이탈 예측 프로젝트에서 CRISP-DM 절차와 분류 기법, Python, 최종 성능 보고서를 구별해 준비한다.

시험 포인트 Phase·Task·Step은 방법론의 계층, 절차·방법·도구·산출물은 구성요소다.

참고: E53

02-16 폭포수·나선형·프로토타입 개발

핵심 개념 폭포수는 순서에 따른 단계 완료, 나선형은 위험 분석을 수반한 반복, 프로토타입은 시제품으로 요구사항을 확인하는 방식이다.

방법	주요 특징
폭포수	계획된 단계를 순차적으로 진행
나선형	위험평가와 반복 개발
프로토타입	시제품을 통해 요구사항 구체화

- 요구가 불명확하면 프로토타입을 빠르게 보여주고 수정한다.
- 나선형은 위험을 평가하며 반복하고, 프로토타입은 사용자의 모호한 요구를 시제품으로 구체화하는 차이가 있다.
- 프로토타이핑은 초기 데이터·사용자 요구가 불확실할 때 소규모 시도를 통해 모호함을 줄이는 장점이 있다.
- 프로토타입은 필요 데이터가 실제 존재하는지, 문제 정의가 적절한지, 분석 목적 변경 가능성이 있는지를 조기에 확인할 수 있다.
- 나선형의 큰 반복: 목표 설정→위험 평가→개발·검증→이해관계자 평가

예시 사용자 인터페이스 요구가 자주 변하면 프로토타입을 먼저 개발해 피드백 받는다.

시험 포인트 폭포수=순차, 나선형=위험 중심 반복, 프로토타입=시제품 중심.

참고: B5 C8 D9 E54 E84 E85

02-17 KDD 다섯 단계

핵심 개념 KDD는 데이터베이스에서 지식을 찾는 과정으로 선택→전처리→변환→데이터 마이닝→해석·평가의 다섯 단계를 따른다.



- 선택은 대상자료 결정, 전처리는 잡음·결측·이상값 정리, 변환은 변수·차원 정리, 마이닝은 모형 적용, 해석은 발견의 유용성 판단
- 각 단계는 필요하면 반복될 수 있다.
- KDD의 관례적인 다섯 단계 전에 도메인·비즈니스 이해가 필요할 수 있지만 다섯 단계 이름을 여섯 단계로 잘못 외우지 않도록 구분한다.

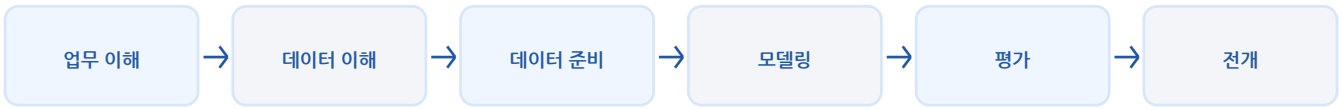
예시 고객 거래를 선택하고 결측 처리→구매빈도 변수 생성→군집화→고객군 해석.

시험 포인트 암기: 선·전·변·마·평. 전처리와 변환의 차이 강조.

참고: A7 B5 C9 D9 E57

02-18 CRISP-DM 여섯 단계

핵심 개념 업무 이해→데이터 이해→데이터 준비→모델링→평가→전개의 업무 중심 데이터마이닝 표준 프로세스다.



- 업무 이해=목표·계획, 데이터 이해=수집·탐색·품질, 준비=정제·통합·포맷, 모델링=학습·튜닝, 평가=비즈니스 적합성, 전개=운영·모니터링
- 단계 사이 되돌아가기가 가능하다.
- CRISP-DM 도식의 단계 간 화살표는 결과를 검토하면서 이전 단계로 돌아갈 수 있음을 보여준다.
- 모델링 단계에서 알고리즘의 기술 성능을 검증하는 활동과 평가 단계에서 업무 목적에 맞는지 판단하는 활동은 기준이 다르다.

예시 이탈 방지 목표 설정부터 이탈 점수 계산을 CRM에 연동하기까지 진행한다.

시험 포인트 업·데·준·모·평·전. '모델링 기술평가'와 '평가 단계의 사업평가'를 구별.

참고: A7 B5 C9 D9 E60 E61

02-19 KDD·CRISP-DM·빅데이터 방법론 비교

핵심 개념 KDD는 지식 발견 절차, CRISP-DM은 업무 목표 중심의 6단계, 빅데이터 분석 방법론은 분석기획→데이터 준비→분석→시스템 구현→평가·전개의 5단계로 정리된다.

방법론	단계 수	강조점
KDD	5	데이터에서 지식 발견
CRISP-DM	6	업무 이해부터 배포까지
빅데이터 분석 방법론	5	기획·준비·분석·구현·평가

- 세 방법론 모두 데이터의 이해·정제·분석·활용이라는 큰 흐름을 공유하지만 명칭과 범위가 다르다
- '시스템 구현'은 빅데이터 방법론에 독립 단계로 나타나며 프로젝트 성격에 따라 생략 또는 축소 가능하다.

예시 실험으로 끝나는 통계 보고서와 실제 서비스 배포가 필요한 모델 사업의 계획을 달리 설계한다.

시험 포인트 단계 수 KDD 5, CRISP-DM 6, 빅데이터 분석 5; 단계 이름 섞지 말 것.

참고: A7 B5 C9 D18

02-20 빅데이터 분석 방법론 5단계

핵심 개념 분석 기획→데이터 준비→데이터 분석→시스템 구현→평가 및 전개로 구성된다.



- 기획에는 범위·프로젝트 정의·위험 대응, 준비에는 수집·정합성, 분석에는 탐색·변수·모델링, 구현에는 서비스·시스템 시험, 평가에는 개선·전개 계획이 포함된다.
- 빅데이터 방법론의 5단계는 분석기획→데이터 준비→데이터 분석→시스템 구현→평가 및 전개이며 CRISP-DM과 단계 개수가 다르다.
- 기획의 SOW·WBS, 데이터 준비의 스토어·정합성, 분석의 알고리즘 설명서, 시스템 구현의 테스트, 평가의 모델 발전 계획을 산출물과 연결한다.

예시 분실물 데이터 대시보드를 기획한 뒤 API 수집·분석·웹 구현·운영 점검을 한다.

시험 포인트 시스템 구축이 불필요한 일회성 분석에서는 그 단계의 적용 여부를 판단한다.

참고: B5 C9 D18-23 E66 E67

02-21 분석 프로젝트의 다섯 특징

핵심 개념 데이터 크기·복잡성·처리 속도·분석 복잡성·정확도와 정밀도는 일반 프로젝트보다 추가로 살펴야 할 관리 요인이다.

- 대량 자료는 인프라 비용, 여러 원천은 통합 난도, 실시간 요구는 응답성, 해석 어려운 모형은 설득 비용, 정확성 요구는 성능·신뢰도 관리와 연결된다
- 여기서 프로젝트 정밀도는 반복 측정의 일관성을 뜻하는 경우가 있어 이진 분류 Precision과 혼동 금지.
- 데이터 크기와 복잡성·요구 속도·모형 복잡성·정확도와 정밀성은 일반 사업 일정 관리에 더해 점검하는 특성이다.

예시 일일 보고면 배치, 이상 거래 차단이면 실시간 파이프라인을 고려한다.

시험 포인트 Data size·Complexity·Speed·Analytic complexity·Accuracy/Precision.

참고: A6 B6 C11 D18 E87

02-22 프로젝트 10대 관리영역

핵심 개념 범위·시간·원가·품질·자원·위험·의사소통·조달·통합·이해관계자 영역이 서로 영향을 준다.

- 모델 정확도가 높아도 일정·예산·데이터 접근 권한 등이 해결되지 않으면 프로젝트 성공이 아니다
- 변화 요청을 받으면 범위와 일정·비용 영향을 함께 확인한다.
- 일정 관리는 타임박싱 등 운영 기법을 활용할 수 있으며 계획 범위·품질·리스크와 함께 관리한다.

예시 예상보다 데이터 수집이 늦어져 일정과 분석 범위를 재협의한다.

시험 포인트 위험관리는 대응전략 하나가 아니라 위험 식별부터 추적까지의 과정이다.

참고: B6 C11 D18 E89

02-23 위험 대응 네 전략

핵심 개념 회피는 위험 원인 활동을 없애거나 변경, 완화는 확률·피해를 줄임, 전가는 보험·계약 등으로 일부 부담을 옮김, 수용은 위험을 알고 감수하는 것이다.

전략	의미
회피	위험의 원인이 되는 활동을 바꿈
완화	발생가능성·영향을 줄임
전가	보험·계약 등으로 부담 일부 이전
수용	감수하고 대응 계획 준비

- 전가했다고 책임이 전부 사라지는 것은 아니다
- 발생 가능성과 영향을 각각 평가하고 대응 우선순위를 정한다.

예시 데이터 손실 위험에는 백업(완화), 외부 사용료 위험에는 계약(전가)을 적용.

시험 포인트 회피·완화·전가·수용의 정의와 예시를 연결.

참고: B5 C9 D9

02-24 SOW·WBS·분석과제 정의서

핵심 개념 SOW는 작업 범위·결과물·인수 조건, WBS는 프로젝트 작업을 관리 가능한 단위로 분해한 구조다.

- 분석과제 정의서는 목표, 입력 데이터, 분석방법, 난이도, 주기, 검증법·이해관계자 등을 구체화하며 업무 범위 합의의 근거가 된다.
- 분석과제 정의서에는 목표·소스 데이터·분석방법·수행 주기·난이도·검증 기준 등을 확인 가능하게 기록한다.

예시 이탈모형 구축 SOW에 인수기준을 쓰고 WBS에 수집·전처리·모형·검증 작업을 나눈다.

시험 포인트 SOW=무엇을 납품, WBS=어떤 작업으로 나눔.

참고: B5-6 C11 D18 E86

02-25 과제 발굴 풀(Pool)과 모니터링

핵심 개념 아이디어 발굴→후보 등록→과제 확정→팀 구성·수행→성과 공유·개선의 흐름으로 분석과제를 관리한다.

- 후보와 진행 과제를 한곳에서 관리하면 중복 투자와 누락을 줄일 수 있다
- 제안·수행·성과 피드백의 상태를 지속적으로 추적한다.
- 분석 아이디어의 발굴·후보 등록·선정·실행·모니터링·결과 공유를 하나의 과제 관리 주기로 이해한다.

예시 물류·마케팅에서 제출한 분석 아이디어를 목록에 두고 선정 상태를 표시한다.

시험 포인트 Pool이 반드시 단 한 단계에서만 갱신된다고 외우기보다 역할·흐름을 이해한다.

참고: C12-13 D14 E111

02-26 Quick-win과 장기 마스터플랜

핵심 개념 단기 과제 중심 계획은 빠른 실험과 성과 검증(Speed & Test), 장기 마스터플랜은 전체 방향·정확성·배포 체계(Accuracy & Deploy)를 강조한다.

- 빠른 과제는 현업 설득과 학습에 유리하고, 장기 로드맵은 데이터·인프라·조직 투자와 중복 과제 관리에 유리하다
- 둘은 경쟁이 아니라 단계적 결합 대상이다.
- 빠른 시험·검증의 Quick-Win은 Speed & Test, 장기 도입 로드맵은 Accuracy & Deploy를 강조하는 대비가 사용된다.

예시 작은 고객 이탈 시범사업으로 효익을 확인하고 전사 CRM 분석으로 확대한다.

시험 포인트 Quick-win=단기 성과, Long-term view=전사·지속 운영.

참고: B5 C12 D14 E49

02-27 분석 마스터플랜과 로드맵

핵심 개념 분석 후보의 전략적 중요도·기대 성과·실행 용이성으로 과제를 고른 다음 적용 범위·시기·기술 수준을 정하는 중장기 계획이다.

- 전략적 중요도는 필요성과 시급성, 실행 용이성은 기술·투자 가능성을 고려한다
- 분석 데이터·업무 내재화·기술 적용 수준을 점검해 단계별 로드맵에 반영한다.
- 마스터플랜은 후보 과제 발굴, 효과와 실현가능성 평가, 적용 로드맵과 추진 체계를 묶어 지속적으로 관리한다.
- 전략적 필요·시급성·ROI·실행 용이성의 기준으로 과제를 비교하고 업무 내재화 수준을 반영해 도입 순서를 정한다.

예시 재고 분석→수요 예측→자동 발주를 3단계로 도입한다.

시험 포인트 우선순위 선정과 적용 범위·방식 선정은 별개 판단이다.

참고: A8 B6 C12-14 D14 E91 E92

02-28 시급성·난이도 우선순위

핵심 개념 분석 과제는 사업 시급성과 실행 난이도를 서로 다른 축으로 평가해 수행 순서를 정한다.

- 시급함·쉬움이 보통 우선이지만 시급하면서 어려운 과제는 경영진의 판단으로 앞당길 수 있다
- 사분면 번호는 그림에서 배치에 따라 달라지므로 축의 실제 의미로 판단해야 한다.
- 우선순위는 난이도만 낮추거나 시급성만 높이는 일변도의 순서가 아니라 조직 목표·사업 가치에 따른 조정이 가능하다.
- 시급성과 난이도의 2×2 사분면에 배치해 어려움·쉬움, 현재·미래 가치의 균형으로 과제 포트폴리오를 조정한다.
- 자료가 제시한 우선순위 기호 I~IV는 사분면의 축 위치 정의를 함께 보고 판단해야 하며 기호만 단독 암기하면 뒤집힐 수 있다.

예시 데이터가 이미 있는 긴급 재고 알림은 빠르게 시작, 큰 차세대 시스템은 장기 로드맵에 배치.

시험 포인트 그림 번호를 외우는 것보다 '우선하면 무엇인가?'를 먼저 읽는다.

참고: A8 B6 C12-14 D14 E94 E95 E96

02-29 ROI·Value·3V 투자요소

핵심 개념 ROI는 투자금에 대비해 발생한 순편익을 평가하는 관점이고 Value는 분석이 만든 매출·비용절감·리스크 감소 등 사업 효과다.

- 빅데이터 관점에서 Volume·Variety·Velocity는 투자비용·구현 난도에 영향을 줄 수 있고 Value는 효과에 해당한다
- ROI 값은 비용 정의와 분석 기간에 따라 달라진다.
- 빅데이터 4V를 투자 관점에서 볼 때 3V는 수집·처리 비용요소, Value는 기대 효과를 나타내는 축으로 활용한다.

예시 새 수요 예측 모델의 구축비와 품절 감소로 얻은 이익을 비교한다.

시험 포인트 Value는 수익 그 자체만이 아니라 비용절감·위험회피 편익도 포함한다.

참고: A8 B6 C12 D14 E93

02-30 분석 준비도 여섯 영역

핵심 개념 분석 업무·인력 및 조직·분석 기법·분석 데이터·분석 문화·IT 인프라가 분석을 실행할 준비를 갖췄는지 진단한다.

- 자료가 풍부해도 책임자가 없거나 의사결정 문화가 없다면 준비도가 낮을 수 있다
- 산출값을 이용해 투자 우선순위를 정한다.
- 준비도 6영역은 업무·인력조직·기법·데이터·문화·IT 인프라이고 한 영역만 높다고 전체 준비가 충족된 것은 아니다.

예시 데이터는 갖췄지만 분석 인력이 없다면 채용·교육을 먼저 계획한다.

시험 포인트 준비도=분석할 수 있는 기반, 성숙도=실제로 활용하는 수준.

참고: A8 B6 C13 D16 E99

02-31 분석 성숙도 네 단계

핵심 개념 도입→활용→확산→최적화는 조직이 데이터 분석을 얼마나 체계적으로 활용하는지 구분하는 단계다.

단계	핵심
도입	분석을 시작하는 단계
활용	업무에 분석을 적용
확산	조직 전반으로 확대
최적화	데이터 기반 운영을 고도화

- 도입은 기초 환경·실적 분석, 활용은 업무에서 분석 사용, 확산은 전사적 공유·전담환경, 최적화는 혁신·프로세스 내재화
- 평가 관점은 비즈니스·조직역량·IT를 포함한다.
- 성숙도는 비즈니스·조직역량·IT를 바탕으로 도입→활용→확산→최적화 단계의 발전 정도를 평가한다.

예시 부서별 보고서에 머무르던 조직이 전사 수요 예측으로 의사결정을 자동화한다.

시험 포인트 성숙도 네 단계와 CMMI의 5단계 평가모형을 혼동하지 않는다.

참고: A8 B6 C13 D16 E101

02-32 준비도×성숙도 2×2

핵심 개념 준비도(분석 인프라·인력)와 성숙도(활용 경험)를 조합해 조직 수준을 준비형·도입형·정착형·확산형 등으로 구분한다.

- 준비도 낮음·성숙도 낮음은 준비형, 준비도 높음·성숙도 낮음은 도입형, 준비도 낮음·성숙도 높음은 정착형, 둘 다 높으면 확산형으로 표현하는 자료가 있다
- 방향은 축을 먼저 확인한다.
- 준비형(낮은 준비·낮은 성숙), 도입형(높은 준비·낮은 성숙), 정착형(낮은 준비·높은 성숙), 확산형(높은 준비·높은 성숙) 좌표를 구분한다.

예시 분석 문화는 좋으나 공통 플랫폼이 부족한 조직은 성숙도와 준비도에서 서로 다른 평가를 받는다.

시험 포인트 축과 위치를 함께 외운다. 회차별 그림 배치 표기 변형에 주의.

참고: B6 C13 D16 E103

02-33 분석 조직 기능형·집중형·분산형

핵심 개념 기능형은 현업 중심·전담조직 부재, 집중형은 중앙 전담분석조직, 분산형은 분석 인력을 현업 부서에 배치하는 방식이다.

유형	구조	주의점
기능형	부서별 자체 분석	전사 협업 약화
집중형	중앙 전담 조직	현업 업무와 거리
분산형	분석 인력 현업 배치	조정·책임 복잡

- 집중형은 전문성·전사 자원 활용이 좋지만 현업과 분리될 위험, 분산형은 빠른 현업 적용이 좋지만 중복·표준 불일치 위험, 기능형은 적은 비용이나 조직 전체 통합 분석이 어려울 수 있다.
- 집중형은 전문성 축적에 유리하지만 현업 이원화 위험, 분산형은 현업 신속성이 높으나 전사 표준 약화 위험을 점검한다.

예시 본사 데이터 사이언스센터 운영은 집중형, 각 사업부에 분석가 배치는 분산형.

시험 포인트 전담 조직과 현업 인력의 위치를 기준으로 구별한다.

참고: B6 C14 D17 E109

02-34 분석 교육·문화 정착

핵심 개념 경영진 지원, 현업 교육, 표준 도구와 성과 공유를 통해 분석을 일상 업무 방식으로 만드는 변화관리다.

- 기획자에게는 문제정의·기획 역량, 실무자에게는 통계·모델링·도구 역량, 관리자에게는 데이터 기반 의사결정 역량이 필요하다.
- 교육은 도구 사용법 전수에 끝나지 않고 분석 결과를 업무 의사결정에 실제 적용하는 능력과 문화를 확산해야 한다.

예시 대시보드만 만드는 데서 끝내지 않고 부서 회의에서 지표를 주기적으로 사용한다.

시험 포인트 분석 구축 성공과 분석 내재화는 구분된다.

참고: C14 D17 E113

02-35 분석 거버넌스와 데이터 거버넌스

핵심 개념 분석 거버넌스는 분석 조직·프로세스·시스템·데이터·교육 등 분석 활동 전체의 운영 체계를, 데이터 거버넌스는 데이터 표준·책임·품질에 초점을 맞춘다.

- 분석 규칙 관리·모형 변경 통제·성과 평가·교육도 분석 거버넌스의 영역
- 저장소의 메타데이터 표준화·품질 규정은 데이터 거버넌스의 중심 업무다.
- 분석 거버넌스는 분석의 기획·수행·확산·책임과 데이터 자산 관리를 함께 조정한다.
- 데이터 거버넌스는 조직 전체의 데이터 표준·메타데이터·마스터 데이터·접근 및 변경을 일관되게 관리한다.

예시 분석모델 개편 승인위원회와 데이터 표준 관리자를 별도로 두되 협력한다.

시험 포인트 데이터 거버넌스 기본 3요소(원칙·조직·프로세스)와 분석 거버넌스 5요소는 문맥이 다르다.

참고: A5 B6 C14 D16 E97 E105

02-36 분석 거버넌스의 다섯 구성요소

핵심 개념 데이터 거버넌스가 데이터 자체의 표준·품질을 주로 다룬다면 분석 거버넌스는 분석 과제와 결과를 조직 차원에서 운영·확산하는 체계다.

구분	의미·특징
조직	책임과 인력 배치.
분석 과제 기획·운영 프로세스	과제 발굴에서 평가까지.
분석 관련 시스템	수집·분석·공유 인프라.
데이터	표준·품질·접근을 포함한 데이터 자산.
교육·마인드 육성	직원의 역량·분석 문화.

예시 영업팀의 예측 모델을 운영하려면 담당자, 주간 모델 점검, 데이터 접근 정책, 교육이 모두 필요하다.

시험 포인트 분석 거버넌스 다섯 요소와 데이터 거버넌스 세 기본 요소(원칙·조직·프로세스)를 혼동하지 않는다.

참고: E97-98

02-37 데이터 기반 의사결정의 방해요인

핵심 개념 기존 관행·프레이밍·확증편향·경영진의 직관 과신은 데이터를 보고도 잘못된 결정을 내리게 할 수 있다.

- 수치만 제시하는 것보다 적절한 비교 기준·대안·불확실성을 함께 보여야 한다
- 데이터 분석이 경험을 무조건 대체하는 것은 아니다.
- 프레이밍 효과는 동일 사실도 위험률·생존율처럼 표현을 달리하면 사람의 선택이 바뀔 수 있는 현상이다.

예시 동일한 손실률을 '성공률 90%'와 '실패율 10%'로 표현하면 판단이 달라질 수 있다.

시험 포인트 프레이밍 효과는 정보의 표현 방식이 판단에 영향을 주는 현상이다.

참고: C8 D6 E52

02-38 분석 플랫폼·Self-Service Analytics

핵심 개념 분석 플랫폼은 데이터에 접근하고 전처리·모델링·시각화·배포를 수행하는 공통 환경이며 셀프서비스 분석은 현업이 직접 탐색할 수 있도록 돕는다.

- BI 보고서·애드혹 질의·OLAP·시각적 탐색·머신러닝 도구가 함께 제공되기도 한다
- 보안·권한·문서화와 분석 역량 교육은 여전히 필요하다.

예시 마케팅 담당자가 IT 개발 요청 없이 대시보드에서 캠페인 결과를 비교한다.

시험 포인트 셀프서비스 도구가 있다고 모든 현업 담당자가 통계적 판단을 자동으로 올바르게 한다는 뜻은 아니다.

참고: B5 C12 D17

02-39 분석 내재화·운영 모니터링

핵심 개념 만든 분석 결과를 운영시스템에 반영하고 실제 효과가 유지되는지 추적해 개선하는 단계다.

- 데이터 지연·품질 오류·성능 저하·모델 드리프트를 감시하고 재학습·변경관리 계획을 마련한다
- 결과 지표는 사업 목표와 연결돼야 한다.

예시 고객 이탈 점수를 일별 CRM 상담 우선순위에 반영하고 이탈률 변화를 추적한다.

시험 포인트 완성한 모형의 배포·운영은 '보고서 제출'보다 긴 주기 관리가 필요하다.

참고: B6 D17-23

02-40 분석요건 식별·정제·확정

핵심 개념 분석요건은 업무 담당자에게 필요한 판단·지표를 추출해 실제로 검증 가능한 데이터·분석·시스템 요구사항으로 구체화한 것이다.

- 워크숍·인터뷰·설문으로 요구를 식별하고 데이터 존재·가공 가능성·비용·운영상 제약을 확인한다
- 기획·데이터마이닝·분석 단계마다 요건을 더 세밀하게 정제하고 이해관계자의 확인을 받는다.

예시 '고객 이탈 방지' 요구를 '매주 위험 고객 상위 5%를 리스트로 제공'이라는 검증 가능한 요건으로 작성한다.

시험 포인트 막연한 희망사항과 측정 가능한 분석요건은 다르며 요건 변경은 범위·일정·성과 기준에 영향을 준다.

참고: B5 D18-19

DAY 03 · 3과목 · 데이터분석

R 기초·데이터 전처리·기술통계·확률

숫자를 믿기 전에 자료구조와 품질을 점검하고, 표본의 평균·분산·확률을 읽는 능력을 만든다.

03-01 R 언어와 RStudio

핵심 개념 R은 통계 계산·그래프·데이터 처리에 강한 오픈소스 언어이며 RStudio는 코드를 편집·실행하는 개발 환경이다.

- R 언어와 도구를 구분한다
- 패키지는 기능 모음이며 install.packages()로 설치하고 library()로 불러온다
- 콘솔과 스크립트 파일의 실행·재현성을 이해한다.

예시 install.packages('dplyr') 뒤 library(dplyr)로 필요한 함수를 사용한다.

시험 포인트 패키지 설치는 최초/버전 변경 시, 로드는 실행 세션마다 필요하다.

참고: C15-16 D24-25

03-02 R 자료형·기본 연산

핵심 개념 numeric·integer·character·logical·factor 등으로 값을 나타내고 연산자 +,-,*,/,^ 및 논리 연산자로 계산한다.

자료형	용도
numeric / integer	수치
character	문자
logical	TRUE / FALSE
factor	범주(수준)

- R의 TRUE/FALSE는 논리형이고 1/0으로 강제 변환될 수 있다
- : 는 연속 정수 수열을 만들고 c()는 원소 결합
- 다른 자료형을 하나의 원자 벡터에 섞으면 자동 형변환이 일어날 수 있다.

예시 c(1,2,'a')는 문자 벡터로 바뀌고 1:5는 1부터 5까지의 수열이다.

시험 포인트 NA와 NULL, NaN의 의미를 구별하며 연산의 결측 전파를 확인한다.

참고: C16 D25

03-03 벡터·행렬·배열

핵심 개념 벡터는 같은 기본 자료형 원소의 1차원 묶음, 행렬은 2차원, 배열은 그 이상 차원까지 확장된 구조다.

- c()로 벡터, matrix(...,nrow=,ncol=)로 행렬
- R의 행렬 값 채움과 as.vector()의 기본 순서는 열 우선(column-major)이다
- byrow=TRUE를 주면 행 우선 입력한다.

예시 matrix(1:6,nrow=2)는 열을 먼저 채워 2행3열이 된다.

시험 포인트 R 행렬과 데이터프레임의 다른 열 자료형 허용 여부 구분.

참고: C16 D25

03-04 데이터프레임·리스트·팩터

핵심 개념 데이터프레임은 열별로 다른 자료형을 담는 표, 리스트는 다양한 길이·형태의 객체를 담는 컨테이너, 팩터는 범주형 자료의 수준(levels)을 관리한다.

구조	특징
데이터프레임	열마다 다른 자료형 허용
리스트	다양한 객체를 중첩·포함
팩터	범주 수준(levels)을 가진 자료

- 데이터프레임의 열 선택에 $ 또는 [[ ]]를 쓰고, 데이터프레임 부분집합에 [행,열]을 쓴다
- factor에는 순서형 levels 설정도 가능하다.

예시 고객 데이터는 data.frame(id,age,region), 지역 값은 factor로 관리.

시험 포인트 벡터는 같은 기본형, 데이터프레임은 열별 자료형 혼합 가능.

참고: C16-17 D25-26

03-05 R 인덱싱·부분집합

핵심 개념 벡터의 원소는 [ ]로, 데이터프레임은 [행,열] 구조로 선택하며 논리조건으로 필터링할 수 있다.

- R 인덱스는 보통 1에서 시작
- 음수 인덱스는 제외, 논리 벡터는 TRUE 원소 선택, is.na()로 결측 위치 확인
- subset()은 조건과 선택 컬럼을 명시한다.

예시 df[df$age>=20, c('id','age')]는 조건에 맞는 행과 두 열을 추린다.

시험 포인트 df[1,]은 첫 행, df[,1]은 첫 열이다.

참고: C16-17 D25-26

03-06 R 자주 쓰는 요약·확인 함수

핵심 개념 head·tail은 자료 일부, str은 구조, summary는 자료 유형에 맞는 요약, dim·nrow·ncol·length는 크기를 파악한다.

- mean·median·sd·var·range·quantile·table·unique 등을 목적에 따라 사용한다
- mean(x,na.rm=TRUE)는 결측을 제거하고 평균을 계산한다.

예시 요약 전에 str(df)로 문자·숫자 타입을 확인한다.

시험 포인트 summary()가 항상 같은 6개의 수치를 출력하는 것은 아니며 범주형은 빈도를 요약할 수 있다.

참고: C16-17 D26

03-07 apply·lapply·sapply·tapply

핵심 개념 apply는 행렬·배열의 행/열 방향, lapply는 리스트 결과, sapply는 단순화 가능한 결과, tapply는 그룹별 함수 적용에 쓰인다.

- apply(x,1,mean)은 행별 평균, apply(x,2,mean)은 열별 평균
- 반복문을 줄이지만 모든 경우에 무조건 더 빠르거나 동일한 데이터형을 유지하지는 않는다.

예시 tapply(df$score,df$class,mean)은 반별 평균을 계산한다.

시험 포인트 MARGIN 1=행, 2=열, lapply=리스트 반환을 기억한다.

참고: C16-17 D26

03-08 결측값 NA·NULL·NaN

핵심 개념 NA는 관측치의 누락, NULL은 객체·값의 부재, NaN은 정의되지 않은 수치 결과를 뜻한다.

- is.na·complete.cases·na.omit으로 탐색할 수 있다
- 평균·중앙값 대체, 집단별 대체, 다중 대치 등의 선택은 누락 기전과 분석 목적에 따라 달라진다
- 결측을 무조건 0으로 채우면 왜곡될 수 있다.

예시 고객 생일 누락은 확인하고 필요시 별도 '미입력' 값으로 표시한다.

시험 포인트 결측 대치값·표준화 기준을 검증/시험 데이터까지 보고 정하면 정보 누출이 생긴다.

참고: C17-19 D31-32

03-09 단순대치·다중대치·완전사례분석

핵심 개념 결측이 있는 데이터는 빠진 행을 제외하거나 값을 한 번 대체하거나 여러 개의 대체자료를 생성하는 방식으로 처리할 수 있다.

- 완전사례분석(complete-case analysis): 결측이 없는 행만 분석하며 자료 손실·편향 위험이 있다.
- 다중대치(multiple imputation): 여러 개의 그럴듯한 완성 데이터를 만들고 분석 결과를 결합해 결측 불확실성을 반영한다.
- 어떤 방식이 적합한지는 결측 원인 MCAR·MAR·MNAR과 연구 목적에 달려 있다.
- 단순대치: 평균·중앙값 등으로 한 번 값을 채우지만 실제 불확실성을 지나치게 작게 평가할 수 있다.

예시 설문 소득이 빠진 응답자를 전부 버리기보다 결측 패턴을 보고 적절한 다중대치 적용 가능성을 검토한다.

시험 포인트 다중대치는 평균대치를 여러 번 반복하는 것과 다르다.

참고: F1 E58

03-10 이상치 탐색·IQR·MAD

핵심 개념 이상치는 다른 관측치에 비해 드물거나 극단적인 값이며 오류일 수도 중요한 사건일 수도 있다.

- IQR=Q3-Q1, 흔한 표시 기준은 Q1-1.5 IQR 미만 또는 Q3+1.5 IQR 초과
- MAD는 median(|x-median(x)|) 기반의 강건한 산포
- Z점수·상자그림·시계열 맥락도 사용한다.
- 평균 ±3표준편차나 사분위범위 1.5×IQR은 이상 후보 탐색 규칙일 뿐 일괄 삭제 명령이 아니다. 극단값의 업무 의미·측정 오류 여부를 반드시 점검한다.

예시 1000원대 거래 중 900만원 결제는 입력 오류인지 사기인지 검토한다.

시험 포인트 이상치와 결측은 다른 문제, 탐지된 이상치를 자동 삭제하지 않는다.

참고: C18-19 D31 F1-2

03-11 데이터 표준화·정규화·스케일링

핵심 개념 특성의 단위나 범위가 크게 달라 거리·규제·최적화 계산을 지배하지 않도록 수치 변수를 변환하는 방법이다.

- Z표준화 z=(x-평균)/표준편차, Min-Max는 (x-최솟값)/(최댓값-최솟값)
- 정규화는 다양한 뜻으로 쓰이므로 문맥을 확인
- 거리기반 KNN·K-means·SVM 등에서 중요하다.

예시 나이 20~80과 연봉 수천만 원을 그대로 거리 계산하지 않도록 표준화한다.

시험 포인트 표준화는 원래 분포를 반드시 정규분포로 만들지 않는다.

참고: C28-34 D30-33

03-12 범주형 인코딩·더미변수

핵심 개념 범주에 수치 코드나 0·1 더미변수를 부여해 모형에서 사용할 수 있게 하는 작업이다.

- 명목형의 임의 숫자 부여는 가짜 거리·순서를 만들 수 있다
- 원핫 인코딩과 기준 범주를 뺀 k-1 더미를 구분한다
- 교호작용은 한 변수의 효과가 다른 변수에 따라 달라짐을 뜻한다.

예시 결제수단 현금·카드·계좌를 더미로 표현한다.

시험 포인트 표준화와 범주형 인코딩은 처리 대상이 다르다.

참고: C23-24 D30-31

03-13 데이터 마트·요약변수·파생변수

핵심 개념 데이터 마트는 특정 분석 목적에 맞춰 원천 데이터를 재구성한 표이며 요약변수는 집계, 파생변수는 기존 값으로 새 특성을 만든 결과다.

- 고객별 구매횟수·평균액은 요약변수, 최근 구매 후 경과일·구매액 대비 환불율은 파생변수
- 변수는 시점 정보 누출 여부를 확인해야 한다.

예시 주문 로그에서 고객 1명당 1행의 분석용 데이터 마트를 만든다.

시험 포인트 원천 거래 1행과 모델 학습 데이터 1행의 의미가 다를 수 있다.

참고: C17 D30-31

03-14 ODS·DW·데이터 마트의 역할

핵심 개념 운영 데이터 저장소(ODS)는 운영시스템에서 모은 비교적 최신 데이터를 통합·정리하고, DW는 장기 분석용 통합 이력을, 데이터 마트는 특정 부서에 필요한 분석 데이터를 제공한다.

- 전형적 흐름은 업무 원천 → ODS/ETL → DW → 부서별 데이터 마트이지만 모든 조직이 이 순서로 설계해야 하는 것은 아니다.
- ODS는 운영 조회·통합에, DW는 추세·통합 분석에, DM은 분석 목적에 맞는 가공에 초점.
- 데이터 레이크는 원천 형태의 다양한 자료 보관과 연결되는 별도 저장 패턴이다.
- 분석용 데이터가 DW에 없다면 ODS 또는 원천 운영시스템에서 데이터를 추출·정제해 결합할 수 있다.

예시 온라인 주문을 ODS에서 통합하고 연도별 판매 이력을 DW로 쌓은 뒤 마케팅 DM에서 고객별 매출을 분석한다.

시험 포인트 ODS=상대적으로 현재 운영 데이터를 연결, DW=분석 이력, DM=분야별 분석.

참고: F1 E16-17

03-15 reshape·melt·cast·plyr

핵심 개념 자료의 길고 긴(long) 형식과 넓은(wide) 형식을 서로 바꾸거나, 분리·계산·결합(split-apply-combine)하는 데이터 가공 방식이다.

- melt는 여러 열을 변수·값 형태로 펼치고 cast는 키별로 다시 표를 넓힌다
- plyr의 기본 사고는 그룹으로 나눠 계산한 뒤 결합하는 것
- 구체 함수 문법은 패키지별로 다르다.

예시 월별 매출 열을 행으로 모아 분기별 집계한 뒤 다시 지역별 표로 펼친다.

시험 포인트 pivot_longer/wider와 melt/cast의 목적은 유사하지만 함수 인터페이스는 다르다.

참고: D30-31

03-16 R의 sqldf·data.table 패키지

핵심 개념 R에서는 SQL식 데이터 처리와 대규모 테이블의 효율적인 조작을 돕는 패키지를 선택해서 쓸 수 있다.

- sqldf는 data.frame 등에 SQL식 질의를 적용할 수 있는 패키지.
- data.table은 빠른 행 필터링·그룹별 집계·결합 작업을 제공하는 자료구조·패키지.
- reshape 계열의 melt·cast는 데이터의 형태 변환, plyr는 split-apply-combine 계열의 처리에 초점이 있다.

예시 구매액을 지역별로 집계할 때 sqldf의 SQL 문법이나 data.table의 그룹 집계를 사용한다.

시험 포인트 sqldf=SQL 사용, data.table=빠른 테이블 연산, melt/cast=형태 변환.

참고: F1

03-17 EDA 탐색적 데이터분석

핵심 개념 EDA는 정식 모형을 만들기 전에 분포·관계·결측·이상·가설 후보를 탐색하는 과정이다.

- 히스토그램·상자그림·산점도·그룹별 요약·상관 등을 사용한다
- 저항성(강건함), 잔차 관찰, 재표현(변환), 그래프 현시성은 전통적인 EDA 강조점이다.

예시 판매액 히스토그램과 요일별 상자그림으로 분포 차이를 먼저 살핀다.

시험 포인트 EDA는 탐색적 발견이므로 우연한 패턴을 발견 즉시 인과 법칙으로 확정하지 않는다.

참고: C15 D23-24,31

03-18 기술통계·추론통계

핵심 개념 기술통계는 관측 데이터를 표·그래프·대표값으로 요약하고, 추론통계는 일부 표본으로 모집단의 특성을 추정·검정한다.

구분	질문	대표 기법
기술통계	현재 자료가 어떤가?	평균·분산·그래프
추론통계	전체도 그럴까?	구간추정·검정

- 기술통계의 평균·중앙값·표준편차는 현재 자료에 관한 진술, 추론통계의 신뢰구간·가설검정은 표본추출에 따른 불확실성을 고려한다.

예시 반 평균은 기술통계, 전국 학생 평균의 추정은 추론통계.

시험 포인트 기술/추론의 차이는 사용하는 수식의 복잡성보다 질문 범위다.

참고: A9 C19-21 D27-28

03-19 모집단·표본·모수·통계량

핵심 개념 모집단은 관심 대상 전체, 표본은 관찰한 일부, 모수는 모집단의 수치적 특성, 통계량은 표본에서 계산한 수치다.

대상	범위	계산값
모집단	관심 대상 전체	모수 μ·σ^2
표본	추출한 일부	통계량 x_bar·s^2

- 모집단 평균 μ·분산 σ^2, 표본 평균 x_bar·분산 s^2를 구분한다
- 표본 선정 방식이 나쁘면 표본 크기가 커도 편향을 피하기 어렵다.

예시 전국 수험생 전체=모집단, 임의의 300명=표본, 그 300명 평균=통계량.

시험 포인트 모집단과 표본을 무엇으로 정하느냐는 연구 질문에 달려 있다.

참고: A9 C19-21 D27

03-20 표본추출 네 방법

핵심 개념 단순무작위는 모든 단위에 무작위 기회, 계통은 무작위 시작 후 일정 간격, 층화는 각 층에서 추출, 집락은 일부 집락을 선정해 조사한다.

방법	뽑는 방식
단순무작위	대상을 무작위로 직접 추출
계통	무작위 시작 후 일정 간격
층화	모든 층에서 일부씩 추출
집락	일부 집락을 뽑아 조사

- 층화는 층마다 대표 확보를 목적으로 하고 집락은 조사 비용 절감에 유리하다
- 층화·집락이 무조건 같은 모집단 구조를 이용하는 것은 아니다.

예시 전국 학교를 지역 층별 표집=층화, 몇 학교를 뽑아 학급 조사=집락.

시험 포인트 층화=모든 층에서, 집락=일부 묶음에서, 계통=일정 간격.

참고: C19-20 D27

03-21 확률과 비확률 표집·표본오차

핵심 개념 확률표집은 추출 확률이 정의된 표집 방식이고 비확률표집은 편의·판단·할당 등으로 선택한다.

- 표본오차는 표본을 쓴 탓에 생기는 변동이고, 비표본오차는 무응답·측정·처리 실수·비응답 편향 등에서 생긴다
- 표본 확대는 표본 변동을 대체로 줄이지만 체계적 편향은 자동 제거하지 않는다.

예시 온라인 자발적 설문에 청년층이 과대표집되는 문제를 점검한다.

시험 포인트 표본오차와 모집단 편향은 별개의 개념이다.

참고: C19-22 D27

03-22 평균·중앙값·최빈값

핵심 개념 평균은 값의 합/개수, 중앙값은 순서상 가운데 위치, 최빈값은 가장 많이 나타나는 값이다.

대표값	의미	주의
평균	값들의 합/개수	이상값에 민감
중앙값	정렬한 가운데	극단값에 강건
최빈값	가장 많이 나온 값	범주형에도 사용

- 평균은 극단값에 민감하지만 중앙값은 강건하다
- 최빈값은 범주형에도 쓸 수 있고 여러 개가 존재할 수 있다.

예시 연봉 3000,3100,3200,3500,30000만 원에서 평균은 극단적 고액의 영향을 크게 받는다.

시험 포인트 치우친 소득 분포의 대표값으로 중앙값이 더 적절할 수 있다.

참고: C18-20 D28

03-23 산술·기하·조화평균

핵심 개념 산술평균은 단순 값의 중심, 기하평균은 곱셈적 변화율, 조화평균은 같은 양의 일을 수행하는 속도·비율을 평균낼 때 자주 사용한다.

- 양의 값에 대해 GM=(Πx_i)^(1/n), HM=n/(Σ1/x_i)
- 성장률의 누적에는 곱셈 관계를 반영해야 하고 속도는 이동거리·시간의 조건을 확인한다.

예시 연속 2년 매출 성장 배율 1.1과 1.2의 평균 배율은 기하평균 √1.32.

시험 포인트 무조건 모든 비율을 기하평균으로 구하는 것은 아니며 합산 대상의 의미 확인.

참고: C18-20 D28

03-24 분산·표준편차·변동계수

핵심 개념 분산은 평균에서 떨어진 거리의 제곱 평균, 표준편차는 분산의 제곱근, 변동계수는 상대적인 퍼짐을 표현한다.

- 표본분산 $s^2=\Sigma(x_i-\bar{x})^2/(n-1)$, 모집단 분산 $\sigma^2=\Sigma(x_i-\mu)^2/N$
- 변동계수 $CV=s/\bar{x}$는 양의 비율척도 등 적합 조건에서 사용한다.

예시 평균 100·SD 10인 제품과 평균 10·SD 5인 제품의 상대 변동 비교.

시험 포인트 표준편차는 원래 단위, 분산은 제곱 단위다.

참고: C18-20 D28

03-25 사분위수·백분위수·상자그림

핵심 개념 백분위수는 정렬된 관측값의 누적 위치를, Q1·Q2·Q3는 25·50·75백분위수 기준을 나타낸다.

- IQR=Q3-Q1은 중간 50% 범위
- 상자는 Q1~Q3, 가운데 선은 중앙값, 수염의 정의는 도표 방법에 따라 다르며 잠재적 이상값이 점으로 표시된다.

예시 반별 시험점수의 중앙값과 중앙 50% 범위를 상자그림으로 비교한다.

시험 포인트 백분위수의 정확한 보간 계산은 소프트웨어 설정에 따라 조금 다를 수 있다.

참고: C18-20 D28

03-26 공분산·상관계수

핵심 개념 공분산은 두 변수가 같이 움직이는 방향을, 상관계수는 크기와 단위를 표준화한 선형 동반 변화 강도를 나타낸다.

- Pearson $r=cov(X,Y)/(\sigma X\,\sigma Y)$이며 -1~1 범위
- $r>0$ 동행, $r<0$ 반행, $r\approx0$은 선형상관이 약하다는 뜻이지 모든 관계가 없다는 뜻은 아니다.

예시 공부시간과 시험점수의 선형 관련성을 확인한다.

시험 포인트 상관은 인과를 입증하지 않는다.

참고: C22-23 D28

03-27 피어슨·스피어만 상관

핵심 개념 피어슨은 관측값의 선형 관계, 스피어만은 순위의 단조 관계를 평가한다.



- 극단값·비선형 형태·순서형 자료에서는 스피어만이 유용할 수 있다
- 스피어만은 원자료를 순위로 바꾼 피어슨 상관이라는 관점으로 이해할 수 있다.
- 피어슨은 숫자 간 선형 관계에, 스피어만은 순위를 이용한 단조 관계에 초점이 있다. 0 상관도 비선형 관계의 부재를 증명하지 않는다.

예시 등수와 만족도 순위의 일관된 증감 관계를 스피어만으로 검토한다.

시험 포인트 정규분포를 따르지 않는다고 무조건 피어슨 불가라는 단정은 피한다.

참고: C22-23 D28 F2

03-28 인과와 상관 구분

핵심 개념 상관은 두 현상이 함께 변하는 관측 관계, 인과는 한 요인의 변화가 다른 결과를 바꾸는 원인 관계다.

- 혼란변수·역인과·선택편향이 있으면 상관에서 인과로 바로 넘어갈 수 없다
- 무작위 실험·통제·시간 선후관계와 타당한 가정을 통해 인과를 검증한다.

예시 아이스크림 판매와 물놀이 사고 증가의 공통 배경에 더운 날씨가 있을 수 있다.

시험 포인트 '함께 증가한다=원인이다'라는 문장은 위험하다.

참고: C22-23 D28

03-29 확률의 공리·여사건

핵심 개념 확률은 0~1이고 전체 사건의 확률은 1이며, 여사건의 확률은 1-P(A)다.

- 합집합 $P(A \cup B)=P(A)+P(B)-P(A \cap B)$
- 서로 배반일 때 교집합=0
- 적어도 한 번의 확률은 '한 번도 발생하지 않음'을 빼면 간단하다.

예시 앞면이 나올 확률 0.4인 독립 3회 시행에서 최소 한 번 앞면=$1-0.6^3=0.784$.

시험 포인트 독립과 배반은 완전히 다른 성질이며 둘을 혼동하지 않는다.

참고: C20-22 D27

03-30 독립·배반 사건

핵심 개념 독립은 한 사건의 발생이 다른 사건의 확률을 바꾸지 않는 것이고, 배반은 두 사건이 함께 일어날 수 없는 것이다.

구분	교집합 확률	예시
독립	P(A)P(B)	서로 다른 동전의 앞면
배반	0	한 번 던진 동전의 앞·뒤

- 독립이면 $P(A \cap B)=P(A)P(B)$, 배반이면 $P(A \cap B)=0$
- 두 사건의 확률이 모두 양수라면 독립과 배반을 동시에 만족하지 않는다.

예시 한 번 던진 주사위에서 짝수와 홀수는 배반, 다른 동전 두 개의 앞면 사건은 독립이다.

시험 포인트 배반=교집합 0, 독립=곱셈법칙.

참고: C20-22 D27

03-31 조건부·주변·결합 확률

핵심 개념 결합확률은 A와 B가 함께 일어날 확률, 주변확률은 한 변수만 본 확률, 조건부확률은 B가 주어졌을 때 A의 확률이다.

- $P(A|B)=P(A\cap B)/P(B)$, $P(B)>0$
- 조건에 따라 분모가 바뀐다는 사실이 핵심이다
- 결합분포를 합산하면 주변분포를 얻는다.

예시 100명 중 여성 50명·여성 구매 30명이면 여성 중 구매확률 30/50=0.6.

시험 포인트 조건부확률을 결합확률과 혼동하면 분모가 틀린다.

참고: C20-22 D27

03-32 베이즈 정리

핵심 개념 베이즈 정리는 이미 알고 있는 가설의 확률(사전)을 증거의 가능성(우도)으로 갱신해 사후확률을 구한다.

- $P(H|E)=P(E|H)P(H)/P(E)$
- 분모인 증거확률은 가설별 우도의 가중합으로 계산
- 사전확률과 사후확률만 주어지면 우도를 유일하게 알 수 없는 경우가 많다.

예시 질병 유병률·검사 민감도·거짓양성률로 양성 이후 질병확률을 계산한다.

시험 포인트 P(양성|질병)과 P(질병|양성)은 같지 않다.

참고: C20-22 D27

03-33 확률변수와 기대값

핵심 개념 확률변수는 우연한 실험의 결과에 숫자를 대응시킨 것이고 기대값은 값에 확률을 가중해 합한 평균이다.

- 이산형 $E[X]=\Sigma xP(X=x)$, 연속형 $E[X]=\int xf(x)dx$
- $E[aX+b]=aE[X]+b$
- 확률밀도함수의 한 점 높이와 확률은 다르다.

예시 점수 0·10이 각각 0.3·0.7 확률로 나오면 기대점수는 7이다.

시험 포인트 PMF $f(x)=P(X=x)$로 썼다면 $\Sigma xf(x)$도 올바른 기대값 식이다.

참고: C20-22 D27

03-34 베르누이·이항 분포

핵심 개념 베르누이는 한 번의 성공/실패, 이항은 독립 시행 n회 동안 성공 횟수의 확률분포다.

- X~Bin(n,p)일 때 P(X=k)=C(n,k)p^k(1-p)^(n-k), E[X]=np, Var(X)=np(1-p)
- 시행별 성공확률이 같고 독립이어야 한다.

예시 클릭확률 0.2인 10명의 독립 방문 중 클릭한 사람 수를 모델링한다.

시험 포인트 '횟수'가 결과이며 시행 수 n은 고정된다는 조건을 확인.

참고: C20-22 D27

03-35 기하·음이항 분포

핵심 개념 기하분포는 첫 성공까지 걸리는 시행 횟수, 음이항분포는 정해진 성공 횟수까지 걸리는 시행 횟수와 관련된다.

- 성공확률 p가 일정하고 시행 독립일 때 기하분포의 한 표현은 P(X=k)=(1-p)^(k-1)p, E[X]=1/p
- 시행 횟수 정의가 '실패 수'이면 공식 형태가 바뀐다.

예시 첫 번째 광고 클릭을 얻기까지 필요한 노출 횟수.

시험 포인트 이항은 고정 시행 수, 기하는 첫 성공까지 가변 시행 수.

참고: C20-22 D27

03-36 포아송·다항 분포

핵심 개념 포아송은 일정 구간에 드물게 발생하는 사건의 건수, 다항분포는 여러 범주의 결과가 반복될 때 범주별 빈도를 다룬다.

- 포아송 P(X=k)=e^(-λ)λ^k/k!, 평균·분산=λ
- 다항분포는 이항분포의 여러 범주 확장으로 각 시행이 하나의 범주에 속한다.

예시 10분당 평균 2건 발생하는 콜센터 장애 건수는 포아송을 검토한다.

시험 포인트 사건 발생 강도 λ를 '확률' p와 혼동하지 않는다.

참고: C20-22 D27

03-37 정규·표준정규 분포

핵심 개념 정규분포는 평균 μ, 표준편차 σ로 중심과 퍼짐이 정해지는 대칭 종 모양 분포이고 표준정규는 평균0·분산1이다.

- Z=(X-μ)/σ로 표준화한다
- 68-95-99.7 경험법칙은 정규분포에서 평균±1σ·2σ·3σ 구간의 대략적인 비율이다.

예시 측정오차를 정규모형으로 근사해 극단적 수치의 위치를 평가한다.

시험 포인트 모든 실제 데이터가 정규라는 주장은 틀리다.

참고: C20-22 D27

03-38 연속형 주요 분포 t·χ^2·F·지수

핵심 개념 t분포는 작은 표본의 평균 추론, 카이제곱은 분산·범주빈도 검정, F는 분산비·분산분석, 지수분포는 일정 사건률에서 대기시간에 활용된다.

- 자유도가 증가하면 t분포는 정규분포에 가까워진다
- χ^2와 F는 음수가 아닌 값에서 정의되며 검정 목적에 따라 분포 선택이 달라진다.

예시 학생 평균 차이는 t, 세 반 이상 평균은 F검정, 분할표 독립성은 χ^2 검정.

시험 포인트 이름보다 통계량이 어떤 표본 변동을 모델링하는지 연결한다.

참고: C20-22 D27-28

03-39 히스토그램·산점도·시각화

핵심 개념 히스토그램은 수치 분포, 막대그래프는 범주 빈도, 산점도는 수치 변수 관계, 상자그림은 중앙값·사분위수·이상치를 시각화한다.

- 같은 값이라도 그래프 축·구간폭·집계 단위에 따라 인상이 달라진다
- 시각화는 모델링 전 탐색과 결과 전달 모두에 사용한다.

예시 고객 나이 분포는 히스토그램, 나이와 구매액 관계는 산점도.

시험 포인트 히스토그램과 범주형 막대그래프의 빈 간격·대상 차이를 구분한다.

참고: C17-21 D23-24

03-40 웹 크롤링·API·ETL 자료 수집

핵심 개념 웹 크롤링은 웹페이지에서 필요한 정보를 찾아 수집하는 작업이고, API는 시스템이 정한 규격으로 데이터를 주고받는 통로이다.

- API 수집은 요청 방식·응답 형태·인증·제한·오류 처리 등을 확인한다
- 크롤링은 페이지 구조·접근 정책·법적·윤리적 제약을 검토한다
- 수집 후 ETL·정합성 점검을 통해 분석에 적합하게 정리한다.

예시 공공데이터 API에서 XML을 조회하고 날짜와 수량을 검증해 분석 테이블에 저장한다.

시험 포인트 API는 데이터 파일 그 자체가 아닌 호출 규칙·인터페이스, ETL은 수집 이후 가공·적재 프로세스.

참고: B5 D18-20,23

03-41 분석용 데이터 정합성·모델링 마트

핵심 개념 원천 자료를 결합해 분석 목적에 맞는 데이터 마트를 만들 때 키·시간 범위·중복·누락·값의 단위를 일관되게 맞추는 과정이다.

- 동일 고객에 여러 거래가 있으면 분석 단위가 고객인지 거래인지 먼저 결정한다
- 훈련시점 이후의 결과값을 설명변수로 섞지 않고 이상값의 이유와 결측 기전을 점검한다
- 완성 마트의 행수·집계 합계와 원천값 일치도 검증한다.

예시 주문 단위 10만 행을 고객별 1행으로 집계할 때 고객ID 중복과 누락을 검사한다.

시험 포인트 '원자료 수집 성공'과 '모형에 유효한 학습 테이블 완성'은 별도 판단이다.

참고: D18-20,23,30-32

03-42 R 문자열·형식 변환 함수

핵심 개념 문자열 함수는 텍스트에서 필요한 부분을 추출·결합하고 형변환 함수는 값을 분석에 맞는 자료형으로 바꾼다.

- substr(x,start,stop)은 부분 문자열, paste(...,sep=)는 결합, as.numeric·as.character·as.factor는 자료형 변환
- 숫자로 변환할 수 없는 문자는 NA가 생길 수 있어 경고와 데이터 손실을 확인한다.

예시 '2026-10-21' 문자열에서 연도만 substr로 추출하고 적절히 날짜형으로 변환한다.

시험 포인트 R 함수의 부분 문자열 끝 위치 인자와 Python 슬라이싱의 끝 인덱스 규칙은 다르다.

참고: C16-17 D25-26

DAY 04 · 3과목 · 데이터분석

통계적 추정·검정·회귀·시계열

표본으로 전체를 추론하는 통계의 논리부터 변수 관계·시간 흐름·차원 축소까지 이어 읽는다.

04-01 표본분포와 중심극한정리

핵심 개념 표본분포는 같은 모집단에서 표본을 반복 추출할 때 평균·비율 등의 통계량이 만드는 확률분포다.

- 독립적이고 적절한 조건 아래 n이 커질수록 표본평균 분포는 정규에 가까워진다
- 원래 관측값의 분포가 모두 정규로 바뀌는 것은 아니다
- 모집단 분산이 유한한 등의 조건이 중요하다.

예시 평균값이 다른 수많은 표본을 만든 뒤 그 평균들의 히스토그램을 살펴본다.

시험 포인트 중심극한정리는 개별 자료가 아니라 '표본평균의 분포'에 관한 진술이다.

참고: C20-21 D27-28

04-02 점추정·구간추정

핵심 개념 점추정은 모수의 추정값 하나를 제시하고, 구간추정은 표본추출의 불확실성을 고려한 값의 범위를 제시한다.

- 표본평균 x_bar는 모평균 μ의 점추정량
- 신뢰구간은 추정량±오차한계 구조
- 추정량의 편향·분산·일치성·효율성 같은 성질을 검토할 수 있다.

예시 고객 평균 구매액 42,000원(점)과 95% 신뢰구간 40,000~44,000원(구간).

시험 포인트 점추정=하나, 구간추정=범위.

참고: C20-21 D27-28

04-03 표준편차 SD·표준오차 SE

핵심 개념 표준편차는 개별 자료의 퍼짐이고 표준오차는 표본에서 계산한 통계량의 표집 변동 크기다.

- 모평균의 SE=σ/√n, 모표준편차가 알려지지 않았다면 보통 s/√n 사용
- n을 4배로 늘리면 평균 SE가 약 절반으로 감소한다(조건 충족 시).

예시 개인별 시험점수 편차(SD)와 반 평균 추정 불확실성(SE)을 구분한다.

시험 포인트 n 증가로 개인 점수가 덜 흩어진다는 뜻이 아니라 평균 추정이 안정화된다.

참고: C20-21 D27

04-04 신뢰수준·신뢰구간 계산

핵심 개념 신뢰구간은 정해진 표집 절차를 반복했을 때 참모수를 포함하는 구간의 장기 비율로 신뢰수준을 해석한다.

- 모표준편차를 알거나 정규근사가 적절하면 평균의 95% 구간은 x_bar±1.96σ/√n, σ가 미지이고 정규 모집단이면 t 임계값×s/√n을 사용한다
- 복잡한 표본설계는 별도 계산이 필요하다.

예시 x_bar=70, SE=2이면 정규근사 95% 구간은 66.08~73.92.

시험 포인트 '이 특정 구간에 고정된 모수가 들어있을 확률이 95%'라는 빈도주의 해석은 부정확하다.

참고: C20-21 D27-28

04-05 가설검정의 기본 구조

핵심 개념 귀무가설 H0와 대립가설 H1을 정하고, 표본에서 검정통계량·p값을 계산해 유의수준과 비교한다.

- p≤α이면 H0를 기각할 근거가 있다고 판단
- p>α이면 H0 기각 실패. 검정 방향(단측·양측), 표본 가정, 효과 크기를 함께 봐야 한다.

예시 '새 학습법이 평균 점수를 높인다'는 주장을 검정하기 위해 기존 평균과 비교한다.

시험 포인트 기각 실패는 H0가 참으로 증명됐다는 뜻이 아니다.

참고: C21-22 D27-28

04-06 p값·유의수준·제1·2종 오류

핵심 개념 p값은 H0를 가정했을 때 관측한 값만큼 또는 더 극단적인 결과가 나올 가능성, 유의수준 α는 H0가 참일 때 잘못 기각할 위험의 허용 기준이다.

- 1종 오류=참 H0 기각(확률 α), 2종 오류=거짓 H0 기각 실패(확률 β), 검정력=1-β
- 동일 조건에서 α를 엄격하게 줄이면 일반적으로 검정력이 낮아질 수 있다.
- 유의수준 α는 제1종 오류 허용 상한, 검정력 1-β는 실제 차이가 있을 때 이를 발견할 확률이다.

예시 정상 제품을 불량으로 판단=1종 오류(정의가 '정상' H0일 때).

시험 포인트 p값은 H0가 참일 확률도, 효과의 중요성 자체도 아니다.

참고: C21 D27-28 F2

04-07 모수검정과 비모수검정

핵심 개념 모수검정은 평균·분산 같은 분포 모수와 가정을 활용하고, 비모수검정은 주로 순위·부호 등으로 비교한다.

검정	특징	예
모수검정	확률분포 등 가정 활용	t검정·ANOVA
비모수검정	순위·분포 가정 완화	Mann-Whitney U

- 데이터 유형·독립성·분포 가정과 목적에 따라 선택한다.
- 대표 예: t검정·ANOVA(모수), Wilcoxon 부호순위·Mann-Whitney U·Kruskal-Wallis(비모수)

예시 정규성 가정이 부적절한 두 독립 집단의 순위 차이는 Mann-Whitney U를 검토한다.

시험 포인트 비모수검정이 항상 중위수만 검정하거나 항상 더 정확한 것은 아니다.

참고: C21-22 D27-28

04-08 t검정 세 종류

핵심 개념 일표본 t검정은 기준 평균과 비교, 독립표본 t검정은 독립 두 집단 평균 비교, 대응표본 t검정은 같은 사람 전후 등 짝지어진 차이를 비교한다.

형태	비교하는 대상
일표본	기준 평균과 표본 평균
독립표본	서로 다른 두 집단 평균
대응표본	같은 대상의 전후 평균

- 일표본 t=(x_bar-μ0)/(s/√n)
- 독립 두 집단에는 분산이 다를 수 있는 Welch t검정이 널리 사용된다
- 대응은 '개별 차이'를 새 표본으로 만들어 t검정을 수행한다.

예시 치료 전후 같은 환자의 혈압이면 대응표본, 남녀 별개 집단 평균이면 독립표본.

시험 포인트 t통계량=차이/그 차이의 표준오차, 표본구조로 검정 유형 선택.

참고: C21-23 D28

04-09 카이제곱 검정

핵심 개념 카이제곱 검정은 범주형 관측 빈도와 기대 빈도의 차이를 평가하거나 모분산 관련 문제에 쓰인다.

- 독립성 검정은 교차표에서 O와 E를 비교해 Σ(O-E)²/E를 계산한다
- 기대 빈도가 지나치게 작으면 근사 부적합으로 Fisher 정확검정 등 다른 방법을 검토한다.

예시 성별과 제품 구매 여부가 독립인지 교차표로 확인한다.

시험 포인트 표본 개수의 차이와 집단 평균 차이를 혼동하지 않는다.

참고: C21-22 D27-28

04-10 분산분석 ANOVA

핵심 개념 ANOVA는 세 집단 이상 모집단 평균이 모두 같다는 귀무가설을 집단 간 변동과 집단 내 변동의 비로 평가한다.

- F=MS_between/MS_within. 유의하면 적어도 하나의 집단 평균이 다르다는 근거가 있지만 어떤 쌍이 다른지는 사후검정이 필요하다
- 관측치 독립성·잔차 정규성·등분산성 등의 가정을 확인한다.

예시 세 종류 사료를 먹은 병아리의 평균 체중을 비교한다.

시험 포인트 세 집단 '모두 서로 다르다'가 아니라 '적어도 하나 다름'.

참고: C21-23 D28

04-11 일원·이원 분산분석과 사후검정

핵심 개념 일원 ANOVA는 요인 하나, 이원 ANOVA는 요인 둘과 상호작용을 함께 분석할 수 있다.

- 집단 차이가 확인되면 Tukey HSD 등 사후검정으로 어떤 집단 간 차이가 있는지 비교
- 이원분산분석은 요인 A 효과·B 효과·A×B 교호작용을 구별한다.

예시 광고 유형(3개)과 고객 지역(2개)이 구매액에 미치는 영향을 함께 분석한다.

시험 포인트 사후검정은 전체 F검정의 역할을 그대로 대체하는 것이 아니다.

참고: C22-23 D28

04-12 상관분석과 회귀분석의 차이

핵심 개념 상관분석은 두 변수의 동반 변화 방향·크기를 요약하고 회귀분석은 설명변수 X를 이용해 결과 Y의 관계를 모형화한다.

- 회귀는 예측·효과의 조건부 해석에 쓰지만 관찰자료 회귀계수만으로 인과가 입증되지는 않는다
- 회귀에서 X와 Y 역할이 구분된다.

예시 공부시간과 성적의 상관을 본 뒤 성적=절편+기울기×공부시간으로 예측한다.

시험 포인트 상관 r과 결정계수 R^2는 일반 다중회귀에서 같은 값이 아니다.

참고: C22-24 D28-29

04-13 단순·다중·다항 회귀

핵심 개념 단순선형회귀는 설명변수 하나, 다중회귀는 여러 개, 다항회귀는 X^2·X^3 같은 항을 넣어 곡선 관계를 표현한다.

- 단순회귀 $Y=\beta0+\beta1X+\varepsilon$, 다중회귀 $Y=\beta0+\Sigma\beta jXj+\varepsilon$
- 다항회귀도 '계수 β에 대해 선형'이면 선형모형 계열에 속한다
- 잔차·계수의 의미를 확인한다.

예시 광고비와 매출(단순), 광고비·기온·요일과 매출(다중), 나이에 따른 U자형 효과(다항).

시험 포인트 다항 항을 넣었다고 반드시 비선형 추정법이 필요한 것은 아니다.

참고: C23-24 D28

04-14 설명변수·반응변수·오차항

핵심 개념 설명변수(X)는 결과를 설명·예측할 입력, 반응변수(Y)는 설명·예측 대상, 오차항은 관측치가 모형의 평균 관계에서 벗어나는 요인을 나타낸다.

- 잔차는 관측값과 모형 예측값 차이로 오차항의 관측 대용이다
- 변수의 관계가 인과적이라고 단정하려면 추가 식별 가정이 필요하다.

예시 주문량(Y)을 광고비·가격(X)로 예측하고 실제와 예측 차이를 잔차로 확인한다.

시험 포인트 오차항(이론적 확률 변수)과 잔차(관측 추정치) 구별.

참고: C23-24 D28

04-15 회귀계수 t·모형 F·p값

핵심 개념 개별 회귀계수 t검정은 해당 계수가 0인지, 전체 F검정은 여러 기울기가 동시에 0인지, p값은 각 검정의 관측 근거를 평가한다.

- t=beta_hatj/SE(beta_hatj), 전체 F는 설명변수들이 함께 추가 설명력을 제공하는지 확인
- 유의하지 않은 계수를 곧바로 '영향 0 확정'으로 단정하지 않는다.

예시 광고비 계수 p=0.01이면 다른 조건의 적절한 해석 아래 기울기 0과 다른 근거가 있다.

시험 포인트 F=전체 모형, t=개별 계수.

참고: C23-24 D28

04-16 결정계수 R^2·수정 R^2

핵심 개념 R^2는 모형의 표본 내 종속변수 변동 설명 비율이고 수정 R^2는 설명변수 수가 늘어날 때의 복잡도 영향을 보정한다.

- 절편 있는 최소제곱회귀에서 R^2=1-SSE/SST
- 수정 R^2=1-(1-R^2)(n-1)/(n-p-1), p는 설명변수 수
- R^2가 높아도 인과성·미래 예측 정확도가 자동 보장되지는 않는다.

예시 변수를 하나 추가해 R^2가 소폭 올라도 수정 R^2는 떨어질 수 있다.

시험 포인트 R^2는 변수 추가로 감소하지 않지만 수정 R^2는 감소 가능.

참고: C23-24 D28

04-17 회귀 오차항 가정·잔차 진단

핵심 개념 선형회귀의 추론과 예측을 믿으려면 관계의 선형성, 독립성, 일정한 분산, 적절한 오차 분포 등을 점검해야 한다.

- 잔차-예측값 산점도로 이분산·곡선 패턴을, QQ그래프로 오차 정규성을, 시간순서로 자기상관을 탐색한다
- 정규성은 특히 작은 표본에서 t·F 근사에 중요하며 예측 자체에 항상 필수는 아니다.

예시 잔차가 예측값이 클수록 퍼지면 이분산 문제를 의심한다.

시험 포인트 잔차에 패턴이 있으면 모델 가정 위반 가능성.

참고: C23-24 D28

04-18 다중공선성과 VIF

핵심 개념 여러 설명변수가 강하게 상관해 계수의 추정 불확실성이 커지는 현상이다.

- VIFj=1/(1-Rj^2), Rj^2는 한 설명변수를 나머지 변수로 회귀한 보조회귀의 결정계수
- 변수 제거·변환·Ridge 등으로 대처
- 높은 VIF가 곧 모형 전체 예측 실패를 뜻하지는 않는다.

예시 월급·연봉·연간 소득을 같은 회귀에 모두 넣으면 계수 해석이 불안정할 수 있다.

시험 포인트 다중공선성은 오차 정규성 위반과 다르다.

참고: C23-24 D28

04-19 변수 선택 전진·후진·단계적

핵심 개념 전진선택은 빈 모형에서 추가, 후진제거는 전체 모형에서 제거, 단계적 방법은 추가와 제거를 반복해 후보를 선택한다.

방법	선택 방향
전진 선택	빈 모형에 변수 추가
후진 제거	전체 변수에서 제거
단계적 선택	추가와 제거를 함께 사용

- AIC·BIC·검증오차·해석성 등을 기준으로 선택할 수 있다
- 데이터로 반복 선택한 뒤 같은 자료의 p값을 무비판적으로 해석하면 과신 위험이 있다.
- 후진제거법은 전체 후보 변수에서 시작해 기여가 적은 항을 줄이고, 단계적은 추가·제거를 재검토한다.

예시 수요예측에서 기온·요일·마케팅비 중 의미 있는 조합을 찾는다.

시험 포인트 전진/후진의 시작 모형이 서로 반대다.

참고: C24 D28-29 F2-3

04-20 AIC·BIC 정보기준

핵심 개념 AIC와 BIC는 적합도(우도)와 변수·모수 개수에 대한 벌점을 결합해 후보 모델을 비교하는 기준이다.

- AIC=-2logL+2k, BIC=-2logL+klogn
- 작을수록 비교 후보에서 선호
- 같은 응답 데이터·일관된 우도 정의 아래 비교하는 것이 기본이다.

예시 변수 3개·8개인 시계열 모형의 설명력과 복잡도를 함께 비교한다.

시험 포인트 AIC/BIC가 작은 것이 항상 시험셋 예측 성능 최고라는 보장은 없다.

참고: C24-26 D29

04-21 Ridge·Lasso 규제회귀

핵심 개념 Ridge는 L2 제곱 벌점, Lasso는 L1 절댓값 벌점을 줘 큰 회귀계수를 억제하고 과적합을 완화한다.

- 릿지는 상관이 큰 변수들의 계수를 안정화, 라쏘는 일부 계수를 정확히 0으로 만들어 변수 선택 효과
- 일반적으로 스케일 조정과 규제 강도 λ의 교차검증 선택이 필요하다.

예시 고객 변수 100개의 이탈 영향 분석에서 규제로 과적합을 줄인다.

시험 포인트 Ridge=능형회귀는 실제 존재. L1/L2와 AIC/BIC를 혼동하지 않는다.

참고: C24 D28

04-22 로지스틱 회귀·오즈·오즈비

핵심 개념 로지스틱 회귀는 결과가 주로 0/1인 사건일 때 사건확률 p의 로그오즈 log[p/(1-p)]를 입력변수의 선형결합으로 나타낸다.

- 오즈=p/(1-p), β 계수의 지수 e^β는 다른 변수를 고정했을 때 X 한 단위 증가에 대한 오즈비
- 확률비·오즈비는 다르다
- 분류 임계값은 0.5로 고정해야만 하는 것은 아니다.

예시 고객의 구매 여부를 예측하고 광고노출의 오즈비를 해석한다.

시험 포인트 확률·오즈·로그오즈·오즈비를 구별한다.

참고: C23-24 D28

04-23 로지스틱 Pseudo R^2

핵심 개념 로지스틱 회귀의 설명 적합도를 우도 기반으로 요약하는 유사 결정계수로 여러 정의가 존재한다.

- McFadden·Cox-Snell·Nagelkerke 등이 있으며 선형회귀 R^2와 동일하게 'Y분산의 몇 % 설명'이라고 해석하지 않는다
- 예측 성능은 ROC·혼동행렬·교차검증과 별도로 확인한다.

예시 고객 이탈 로지스틱 모델의 후보를 AIC·Pseudo R^2·AUC로 함께 평가한다.

시험 포인트 Pseudo R^2의 공식과 범위는 사용한 종류를 명시해야 한다.

참고: C24 D28

04-24 시계열의 추세·계절·순환·불규칙

핵심 개념 시계열을 장기 추세(T), 일정 달력 주기 반복인 계절(S), 비고정 길이의 순환(C), 예측 어려운 불규칙(I) 요인으로 분해해 이해한다.

- 가법 Y=T+S+C+I와 승법 Y=T×S×C×I는 크기와 계절폭 관계에 따라 고려한다
- 완벽하게 서로 분리하기 어려울 수 있다.
- 계절변동은 달력상 상대적으로 일정한 주기로 반복되지만 순환변동은 고정되지 않은 경기 흐름과 관련된다.

예시 여름 냉방기 매출: 장기 성장·매년 여름 성수기·경기순환·일회성 사고를 구분한다.

시험 포인트 계절은 고정된 반복 주기, 순환은 경기처럼 비교적 불규칙한 긴 주기.

참고: C24-26 D29 F3

04-25 정상성·차분·로그변환

핵심 개념 정상성은 시계열의 평균·분산·시간차 공분산 구조가 시간 이동에 크게 변하지 않는 성질이다(약정상 기준).

- 1차 차분 $\Delta Y_t = Y_t - Y_{t-1}$은 추세·단위근 대응, 계절 차분은 주기 s 전 값과의 차이
- 로그변환은 비율적 변화·분산 안정화에 도움을 줄 수 있다.

예시 점차 커지는 일별 거래량의 차분 그래프와 ACF를 비교한다.

시험 포인트 차분 d는 몇 번 차분했는지, 모든 비정상 시계열이 같은 d를 쓰는 건 아니다.

참고: C24-26 D29-30

04-26 이동평균 평활·백색잡음

핵심 개념 평활 이동평균은 최근 관측값을 평균해 노이즈를 줄이고, 백색잡음은 시차 간 상관이 없고 평균이 일정한 무작위 변동을 가리킨다.

- 백색잡음은 ARMA 모형의 오차항으로 등장한다
- 단순 이동평균 평활과 MA(q) 확률모형은 둘 다 '이동평균'이지만 서로 다른 개념이다.

예시 7일 이동평균으로 요일별 급등락을 완화해 추세를 본다.

시험 포인트 MA 평활은 과거 관측값 평균, MA(q)는 과거 오차의 선형조합.

참고: C24-26 D29

04-27 AR·MA·ARMA·ARIMA·SARIMA

핵심 개념 AR(p)는 과거 관측값, MA(q)는 과거 오차, ARMA는 두 구조, ARIMA(p,d,q)는 차분 d를 추가하고 SARIMA는 계절 구조를 확장한다.

- ARIMA에서 p=AR 차수, d=차분 횟수, q=MA 차수
- SARIMA에는 계절 차분 D와 계절 기간 s, 계절 AR·MA 차수까지 포함된다
- 모형은 정상성·잔차 진단을 거쳐 선택한다.

예시 월별 관광객 수의 매년 여름 패턴은 SARIMA 후보를 고려한다.

시험 포인트 AR=관측값의 과거, MA=오차의 과거, I=차분.

참고: C24-26 D29-30

04-28 ACF·PACF·AIC 진단

핵심 개념 ACF는 시차별 자기상관, PACF는 중간 시차의 영향을 통제한 부분 자기상관, AIC는 후보 모형의 적합도·복잡도 비교 기준이다.

- 대략 AR(p)는 PACF가 p차 이후 절단, MA(q)는 ACF가 q차 이후 절단이라는 전형적인 패턴을 참고하지만 실무 자료는 뚜렷하지 않을 수 있다
- 차분 이후 잔차 자기상관도 검사한다.

예시 월매출 자료의 ACF·PACF를 보고 p,q 후보를 만든 후 AIC로 비교한다.

시험 포인트 정상성 검사와 AIC 모형선택의 역할을 구분한다.

참고: C24-26 D29-30

04-29 GARCH와 조건부 변동성

핵심 개념 GARCH는 시간에 따라 달라지는 변동성, 특히 큰 변동이 연이어 나타나는 현상을 모델링하는 기법이다.

- 평균값 수준을 설명하는 ARIMA와 달리 오차의 조건부 분산을 모형화하는 데 초점을 둔다
- 금융 수익률 위험 측정 등에 자주 쓰인다.

예시 주식 수익률 변동폭이 큰 날이 군집하는 현상을 설명한다.

시험 포인트 ARIMA=평균·시차 패턴, GARCH=변동성.

참고: C24-26 D29

04-30 주성분분석 PCA

핵심 개념 PCA는 상관된 여러 수치변수의 변동을 최대한 보존하는 서로 직교하는 새로운 축(주성분)으로 차원을 줄인다.

- 첫 주성분은 가장 큰 분산을 설명, 두 번째는 첫 주성분에 직교하는 나머지 최대 분산 방향
- 표준화 여부가 결과를 바꾸므로 변수 단위와 스케일 확인
- 누적 기여율·스크리 그림을 보고 개수를 고른다.
- 주성분은 고윳값과 기여율로 각 축이 설명하는 변동의 비중을 평가한다. 누적기여율 85% 같은 숫자는 휴리스틱이지 모든 자료의 절대 규칙이 아니다.

예시 고객 소비 성향 지표 20개를 '가격 민감'·'활동성' 같은 소수 축으로 압축한다.

시험 포인트 PCA는 비지도 차원축소이지 정답 라벨 분류나 군집 자동 배정은 아니다.

참고: A9 C25-26 D28-30 F4

04-31 다차원척도법 MDS

핵심 개념 MDS는 관측대상끼리의 거리·비유사성이 저차원 공간에서도 최대한 유지되도록 점을 배치하는 시각화 방법이다.

- PCA는 원 변수의 분산을 많이 설명하는 축, MDS는 대상 간 거리 관계가 중심이다
- 최종 점 좌표의 회전·반사 자체보다는 거리 구조를 해석한다.

예시 브랜드 간 소비자 인식 유사도를 2차원 포지셔닝 맵으로 표현한다.

시험 포인트 MDS=거리 지도, PCA=분산 최대 축.

참고: C26 D35

04-32 계량·비계량 MDS와 스트레스 값

핵심 개념 MDS는 대상 간 거리/비유사도를 적은 차원의 좌표로 배치하며, 계량 MDS와 비계량 MDS는 원래 거리를 보존하는 방식이 다르다.

- 계량 MDS는 수치적인 거리·비유사도 관계를 재현하는 데 초점을 둔다.
- 비계량 MDS는 원래 거리의 정확한 크기보다 크고 작은 순서의 관계를 보존하려고 한다.
- 스트레스(Stress)는 배치된 거리와 원래 비유사도의 불일치 정도를 나타내며 일반적으로 작을수록 적합이 좋다.

예시 브랜드 간 유사도를 조사해 2차원 지도를 만든 뒤 스트레스 수치로 배치 왜곡을 확인한다.

시험 포인트 MDS 스트레스는 군집 내부 불순도나 PCA의 고윳값과 다른 지표다.

참고: F3-4

04-33 시계열 예측의 평가와 누출

핵심 개념 시간 순서가 있는 자료는 미래 시점의 정보를 학습 시점으로 가져오지 않는 것이 핵심이다.

- 시계열 교차검증은 과거 구간으로 학습해 더 미래의 구간으로 평가하는 확장창·이동창 방식을 쓸 수 있다
- 시간무작위 셔플은 미래 누출 가능성을 확인해야 한다.

예시 2024~2025년 매출로 학습한 뒤 2026년 초 매출 예측 정확도를 확인한다.

시험 포인트 시계열은 단순 무작위 교차검증보다 시간 선후관계 보존이 중요하다.

참고: C25-26 D29-30

DAY 05 · 3과목 · 데이터분석

데이터마이닝·분류·군집·연관

정답이 있는 문제와 없는 문제를 구분하고 각 알고리즘의 입력·출력·한계를 비교한다.

05-01 데이터마이닝의 정의와 흐름

핵심 개념 데이터마이닝은 데이터에서 의미 있는 규칙·분류·예측·연관·군집 패턴을 찾고 의사결정에 활용하는 활동이다.

- 업무 목적 정립→분석 데이터 준비→탐색·가공→모형 구축→검증·활용으로 흐름을 이해한다
- 통계적 유의성만으로 성공을 평가하지 않고 새 자료에서의 성능과 사업 효과를 점검한다.
- 데이터마이닝의 분류·예측·군집·연관은 분석 목표의 성격에 따라 나뉜다. 통계분석과 배타적이지 않고 도구·목적에 따라 중첩된다.

예시 상품 추천을 위해 주문 로그의 반복 구매 패턴을 추출한다.

시험 포인트 KDD는 지식발견 전체 프로세스, 데이터마이닝은 그 안의 분석 핵심 단계로 쓰인다.

참고: C26-27 D32 G(웹)

05-02 지도학습·비지도학습

핵심 개념 지도학습은 X와 정답 Y가 함께 있는 자료로 예측 규칙을 배우고 비지도학습은 Y 없이 자료의 구조·그룹·연관을 탐색한다.

구분	정답 라벨	목적
지도학습	있음	분류·회귀 예측
비지도학습	없음	군집·연관·차원축소

- 지도학습의 분류는 범주, 회귀는 연속 수치
- 비지도에는 군집·차원축소·연관패턴 탐색 등이 있다
- 강화학습은 행동·보상 상호작용이라는 별도 학습 틀이다.

예시 고객 이탈 여부=지도 분류, 라벨 없는 고객 그룹 나누기=비지도 군집.

시험 포인트 지도/비지도는 문제를 발굴하는 상향식/하향식 방법과 동일한 분류가 아니다.

참고: A2 C26-27 D32

05-03 분류·회귀·군집·연관

핵심 개념 분류는 범주를, 회귀는 수치를 예측하고, 군집은 유사한 그룹을, 연관은 사건·품목의 동시 발생 규칙을 탐색한다.

기법	예측/발견 목표
분류	결과 범주 예측
회귀	결과 수치 예측
군집	유사한 대상 묶기
연관	함께 발생하는 규칙 찾기

- 같은 데이터라도 질문에 따라 분석 유형은 달라진다
- 구매 여부는 분류, 구매액은 회귀, 소비 패턴 그룹은 군집, 동시 구매 조합은 연관이다.
- 분류에서는 예측 결과가 미리 정한 클래스이지만 군집에서는 클래스 라벨 없이 데이터만 보고 묶는다는 차이가 핵심이다.

예시 고객 데이터를 대상으로 이 네 질문을 각각 설계할 수 있다.

시험 포인트 문제의 목표변수 유무와 출력 형태를 먼저 보자.

참고: C27-34 D32-37 G(웹)

05-04 데이터마이닝의 고객 활용

핵심 개념 행동 예측·휴면 및 이탈 예측·등급 이동·신규 우량고객 발굴·추천·캠페인 반응 예측·사기탐지가 대표적인 활용이다.

- 예측 결과를 CRM 행동과 연결하는 것이 중요하며 AUC가 높은 모델도 실제 고객 조치가 없으면 비즈니스 가치가 제한된다
- 모델보다 타깃·손익·업무 프로세스를 먼저 정의한다.

예시 고객이 떠날 확률을 계산해 상담 우선순위를 정한다.

시험 포인트 예측점수와 실제 개입 의사결정은 별도 단계이다.

참고: D33-34

05-05 데이터 분할 훈련·검증·시험

핵심 개념 훈련셋은 모형 학습, 검증셋은 하이퍼파라미터·모형 선택, 테스트셋은 최종 일반화 성능 평가에 사용한다.

- 시계열·그룹 반복측정 등에는 순서·그룹 누출 방지 방법을 쓴다.
- 훈련 50%·검증 30%·테스트 20%는 가능한 한 가지 분할 예일 뿐 반드시 지킬 규칙은 아니다.
- 데이터의 크기와 목적에 따라 60: 20:20·70:15:15 등 다양한 비율 가능
- : 30:20을 항상 지켜야 한다는 규칙은 없다

예시 2019~2024 고객 기록으로 학습·검증하고 이후 기간으로 테스트한다.

시험 포인트 테스트셋을 보고 튜닝을 반복하면 최종 평가가 편향된다.

참고: C27-28 D32 F4

05-06 홀드아웃·교차검증·부트스트랩

핵심 개념 홀드아웃은 한 번 나눠 평가, K-fold는 분할을 번갈아 평가, 부트스트랩은 복원추출 표본을 반복 만드는 방식이다.

- K-fold는 K-1개 폴드로 학습해 1개로 검증하며 K회 반복
- LOOCV는 K=n, 각 관측치를 한 번씩 제외
- 부트스트랩은 원본 항목의 중복 선택과 누락이 허용된다.

예시 고객 100건을 5폴드로 5번 훈련·검증한다.

시험 포인트 K=2는 LOOCV가 아니라 2-fold이고 부트스트랩은 K-fold와 추출방식이 다르다.

참고: C27-28 D32

05-07 과적합·과소적합·일반화

핵심 개념 과적합은 훈련자료의 우연한 잡음까지 외워 새 자료에서 성능이 낮아지는 것이고 과소적합은 모델이 너무 단순해 중요한 패턴을 못 배우는 것이다.

- 훈련 손실은 낮고 검증 손실은 높으면 과적합, 둘 다 높으면 과소적합 의심
- 교차검증·규제·가지치기·데이터 추가 등으로 개선을 검토한다.

예시 나무 깊이를 무한히 늘려 훈련 정확도만 높은 상황을 교정한다.

시험 포인트 훈련 성능이 높다고 반드시 실무 성능이 좋지는 않다.

참고: C27-28 D32-34

05-08 KNN 최근접 이웃

핵심 개념 KNN은 새 관측치에 가까운 K개 학습 사례의 정답을 참고해 범주를 다수결로 분류하거나 수치를 평균해 예측한다.

- 특징 스케일과 거리 정의에 민감하고 K가 작으면 복잡·변동 증가, 너무 크면 국소 패턴이 희석될 수 있다
- 별도 명시적 경계 함수를 학습하지 않는 사례 기반 방법이다.

예시 새 고객과 비슷한 기존 K명 고객의 이탈 여부를 참고한다.

시험 포인트 KNN은 지도학습, K-means는 비지도 군집이다.

참고: C27-32 D33

05-09 KNN의 지연 학습과 K값 선택

핵심 개념 KNN은 명시적인 결정함수를 훈련 과정에서 만들기보다 사례를 저장해 두고 새 입력이 들어오면 거리를 계산하여 이웃으로 예측하는 지연 학습(lazy learning) 기법이다.

- 학습 시 단순하지만 예측 때 비교할 후보가 많으면 계산비용이 증가할 수 있다.
- 거리 척도·표준화·K 선택에 민감하며 K가 작으면 잡음에 민감하고 크면 세밀한 지역 특성이 약해질 수 있다.
- KNN의 규칙을 사람이 문장으로 미리 정해줄 필요는 없으며 실제 사례가 분류 기준을 구성한다.

예시 신규 고객과 특성이 가장 비슷한 5명의 고객을 찾아 그중 다수가 이탈했다면 이탈로 분류한다.

시험 포인트 KNN=지도학습·사례기반·예측 시 계산, K-means=비지도학습·중심 갱신.

참고: F5 G

05-10 나이브 베이즈 분류

핵심 개념 나이브 베이즈는 클래스가 주어졌을 때 각 입력 특징들이 조건부 독립이라고 가정해 베이즈 정리로 클래스를 분류한다.

- 확률 계산이 간단하고 텍스트 분류에 자주 쓰지만 특징 간 독립 가정은 실제와 다를 수 있다
- 독립 가정이 완벽하지 않아도 분류 성능이 좋은 경우가 있다.

예시 이메일 문구의 단어 출현을 보고 스팸 여부를 추정한다.

시험 포인트 베이즈 정리 전체와 나이브 베이즈의 추가 '조건부 독립' 가정을 구분한다.

참고: C27 D33

05-11 서포트 벡터 머신 SVM

핵심 개념 SVM은 서로 다른 클래스 사이의 간격(margin)이 큰 결정 경계를 찾는 지도학습 기법이다.

- 경계 가까운 서포트 벡터가 모델을 결정하고 커널로 비선형 분리도 가능하다
- C와 커널·γ 같은 설정이 일반화에 영향을 주고 스케일에 민감하다.

예시 정상 로그인과 이상 로그인을 구분하는 경계를 학습한다.

시험 포인트 SVM은 주로 지도 분류·회귀에 쓰며 DNN/CNN/RNN과 구조가 다르다.

참고: C27-32 D33

05-12 의사결정나무의 구조

핵심 개념 의사결정나무는 입력 특징에 대한 질문으로 데이터를 반복 분할해 결과를 예측하는 지도학습 모형이다.



- 뿌리노드(root)에서 내부노드의 질문을 따라가 리프노드에서 예측한다
- 분류나무는 범주, 회귀나무는 연속값을 예측한다
- 해석은 쉬우나 깊어지면 과적합할 수 있다.

예시 '지난달 방문 3회 이상?'→'최근 결제?'를 질문하며 이탈 여부를 예측한다.

시험 포인트 나무가 데이터를 자동으로 잘 분할하는 것과 인과적 원인을 설명하는 것은 다르다.

참고: C30-31 D33

05-13 의사결정나무 분할 지표

핵심 개념 분류나무는 지니불순도·엔트로피(정보이득)·카이제곱 등을 목적에 맞게 사용하고 회귀나무는 노드 내 분산·SSE 감소를 이용하는 경우가 많다.



- Gini=1-Σp_k², Entropy=-Σp_klog₂p_k
- 모두 한 클래스만 있는 노드일 때 0
- 회귀나무 분할은 평균 예측 오차가 얼마나 줄어드는지 평가한다.
- CART 분류의 지니 불순도는 노드별 클래스 비율의 제곱합을 이용해 계산하고, 부모보다 자식들의 가중 평균 불순도가 줄어드는 분할을 찾는다.

예시 구매자·비구매자가 섞인 노드를 나눠 한쪽에 비구매자가 몰리면 불순도 감소.

시험 포인트 지니·엔트로피=분류, SSE=회귀가 대표 구분이다.

참고: C30-31 D33 G(웹)

05-14 CART·C4.5/C5.0·CHAID

핵심 개념 CART는 이진 분할, C4.5/C5.0는 정보이득·엔트로피 계열, CHAID는 카이제곱 검정 기반의 범주 분할과 관련된다.

- 실제 구현 세부의 가지치기·분할지표는 버전과 소프트웨어에 따라 차이가 있다
- 분할 수와 척도 선택을 모두 단정적 규칙으로 외우기보다 알고리즘 성격을 이해한다.
- CHAID는 카이제곱 분할 계열이며 모든 입력 변수가 반드시 범주형이라는 단정은 구현에서 수치 변수를 범주화하는 경우를 놓친다.

예시 고객 이탈을 CART로 이진질문, CHAID로 범주별 유의한 차이를 탐색한다.

시험 포인트 CART=이진분할, C4.5=정보이득, CHAID=카이제곱 계열.

참고: C31 D33 F4-5

05-15 정지규칙·가지치기

핵심 개념 정지규칙은 나무가 더 자라기 전에 제한하고, 가지치기는 자란 나무에서 과도한 분할을 제거해 일반화 성능을 높인다.

- 최소 노드 크기·최대 깊이·최소 개선량은 사전 정지, 비용복잡도·검증기반 가지치기는 사후 정리
- 단순 나무가 설명에 유리하지만 너무 얕으면 과소적합.

예시 가지가 50개로 갈라지는 과도한 이탈예측 나무를 축소한다.

시험 포인트 사전 정지와 사후 가지치기를 구별.

참고: C30-31 D33

05-16 인공신경망·퍼셉트론

핵심 개념 신경망은 입력의 가중합에 활성화함수를 적용하는 뉴런을 층으로 연결해 복잡한 규칙을 학습한다.

- 단일 퍼셉트론은 선형 결정경계, 다층 퍼셉트론은 은닉층과 비선형 활성화로 복잡한 함수를 표현한다
- 손실·학습률·은닉층 구조가 학습에 영향을 준다.
- 은닉층과 은닉노드가 너무 적으면 복잡한 경계를 표현하기 어렵고 너무 많으면 튜닝과 과적합 문제가 생길 수 있다. 유일하게 올바른 층 수 규칙은 없다.

예시 여러 센서 값으로 기계 고장 확률을 예측한다.

시험 포인트 뉴런의 입력값과 출력값의 역할을 구분한다.

참고: C31-32 D33 G(웹)

05-17 활성화함수 시그모이드·ReLU·Softmax

핵심 개념 활성화함수는 신경망에 비선형성을 주거나 출력 해석에 맞는 범위를 만든다.

- 시그모이드는 0~1, tanh는 -1~1, ReLU=max(0,x), Softmax는 여러 클래스 점수의 합이 1인 확률 분포로 변환한다
- 출력층은 문제에 맞게 선택한다.

예시 이진 이탈확률에는 시그모이드, 5개 상품 분류에는 Softmax.

시험 포인트 Softmax는 여러 클래스, ReLU는 주로 은닉층.

참고: C31-32 D33

05-18 경사하강법·역전파·기울기 소실

핵심 개념 역전파는 미분 연쇄법칙으로 손실의 기울기를 계산하고 경사하강법은 그 반대 방향으로 가중치를 조정한다.

- 학습률이 너무 크면 불안정, 너무 작으면 학습이 느리다
- 깊은 네트워크에서 기울기가 점점 작아지는 소실 문제를 ReLU·초기화·잔차연결·LSTM 등이 완화한다.

예시 이미지 모델에서 손실이 줄어들도록 수많은 가중치를 업데이트한다.

시험 포인트 역전파=기울기 계산, 경사하강=계수 갱신.

참고: C31-32 D33

05-19 DNN·CNN·RNN·LSTM

핵심 개념 DNN은 깊은 층으로 일반 특징을 학습, CNN은 공간·이미지의 지역 패턴, RNN은 순서 데이터의 이전 상태를 활용, LSTM은 게이트로 장기 의존 정보를 보존한다.

- CNN은 필터/합성곱으로 지역 특징을 추출하고, RNN은 시점별 상태가 연결되며, LSTM은 입력·망각·출력 게이트를 사용한다
- 모두 지도·비지도 목적에 맞게 응용될 수 있다.

예시 사진 분류 CNN, 언어·시계열 RNN/LSTM, 일반 구조화된 특징 DNN.

시험 포인트 모형 구조의 주 목적을 비교하고 'RNN=항상 더 우월' 같은 단정 피하기.

참고: C31-32 D33

05-20 배깅·부스팅·스태킹

핵심 개념 배깅은 여러 표본에서 병렬로 학습한 모델을 결합, 부스팅은 이전 모델의 오류를 순차 보완, 스태킹은 여러 모델의 예측을 메타모델로 다시 결합한다.

기법	결합 방식
배깅	서로 다른 표본의 모형들을 병렬 결합
부스팅	앞선 오차를 다음 모델이 순차 보완
스태킹	기본 모델 예측을 메타모델이 결합

- 배깅은 변동성 감소, 부스팅은 편향 보완과 복잡한 결합, 스태킹은 다른 모델의 상호보완이 핵심
- 교차검증 없이 훈련 예측값만으로 메타모델을 만들면 누출 위험이 있다.
- 배깅은 복원표본 기반 여러 모델 예측을 결합하고 부스팅은 앞선 모델의 예측 오차를 후속 학습기가 보완한다. 둘 다 최종 결과를 합치지만 생성 순서가 다르다.

예시 랜덤포레스트=배깅 계열, AdaBoost·Gradient Boosting=부스팅, 예측 조합=스태킹.

시험 포인트 배깅=병렬, 부스팅=순차, 스태킹=2단계 결합.

참고: C27-32 D33 G(웹)

05-21 부트스트랩·랜덤 포레스트

핵심 개념 부트스트랩은 원 자료에서 복원추출해 학습용 표본을 만들고, 랜덤 포레스트는 여러 나무의 표본·특징 선택에 무작위성을 도입한다.

- 같은 행이 한 표본에 여러 번 포함되거나 제외될 수 있다
- 랜덤 포레스트는 분류에서 다수결, 회귀에서 평균을 활용
- 가지치기된 나무 하나와는 다르게 여러 나무로 안정성을 얻는다.
- 랜덤 포레스트는 부트스트랩뿐 아니라 각 분할에서 후보 변수 일부를 무작위로 선택한다. 분류에서 제곱근 변수 수는 흔한 기본설정 중 하나지만 최적값이 항상 제곱근은 아니다.

예시 고객 1만명의 복원표본을 수십 개 만들어 나무들을 학습한다.

시험 포인트 복원추출=중복 허용, 비복원=한 번 뽑힌 자료 제외.

참고: C27-32 D33 G(웹)

05-22 AdaBoost·Gradient Boosting

핵심 개념 AdaBoost는 오분류된 관측치에 다음 학습의 비중을 두며, Gradient Boosting은 손실함수의 기울기 방향을 줄이는 약한 예측기들을 순차 결합한다.

- 약한 학습기를 여러 번 쌓아 복잡한 모형을 만들지만 학습률·나무 수·깊이 등 조정과 검증이 필요하다
- 노이즈·극단값에 대한 반응은 구현에 따라 다르다.

예시 이탈 여부의 어려운 고객 사례를 순차적으로 보완한다.

시험 포인트 배깅과 부스팅은 표본 생성·학습 순서가 핵심 차이.

참고: C27-32 D33

05-23 군집분석의 목적과 유형

핵심 개념 군집분석은 정답 라벨 없이 비슷한 대상을 묶어 자료 속 구조를 탐색한다.

- 계층적 방법은 덴드로그램을 형성하며 비계층적 K-means는 정한 K개 군집을 반복 최적화한다
- 밀도기반 DBSCAN·확률적 혼합모형·퍼지 군집도 존재한다.

예시 거래 기록을 이용해 가격 민감군·고빈도군 등 고객층을 탐색한다.

시험 포인트 군집은 타깃 정답을 예측하는 분류와 다르다.

참고: C32-34 D34-36

05-24 거리 척도 유클리드·맨해튼·민코프스키

핵심 개념 유클리드는 직선거리, 맨해튼은 각 좌표차 절댓값 합, 민코프스키는 두 거리를 포함하는 거리의 일반화다.

거리	판별 기준
유클리드	좌표 차이 제곱합의 제곱근
맨해튼	좌표별 절댓값 차이 합
민코프스키	p값으로 위 두 거리 일반화

- 민코프스키 d_p=(Σ|x_i-y_i|^p)^(1/p): p=1이면 맨해튼, p=2이면 유클리드
- 거리 기반 모델에서 변수 단위와 이상치에 민감하다.

예시 도시 격자길은 맨해튼, 점 사이 직선 거리는 유클리드로 해석한다.

시험 포인트 유클리드 √Σ차², 맨해튼 Σ|차|.

참고: C32-34 D35

05-25 마할라노비스·자카드·해밍

핵심 개념 마할라노비스는 공분산을 반영한 거리, 자카드는 두 집합의 교집합/합집합 유사도, 해밍은 같은 길이 문자열에서 다른 위치의 수다.

- Mahalanobis $d^2=(x-y)^T\Sigma^{-1}(x-y)$, Jaccard=$|A\cap B|/|A\cup B|$
- 이진 희소 특성이나 범주형 코드에서는 수치 거리보다 적합한 유사도를 고려한다.

예시 공동 구매 상품집합 유사도는 자카드, 비트 패턴 차이는 해밍 거리.

시험 포인트 '마할라노비스=단순 표준화 거리'가 아니라 상관성까지 반영할 수 있다.

참고: C32-34 D35

05-26 계층적 군집·덴드로그램

핵심 개념 계층적 군집은 가까운 대상끼리 합치거나 하나의 집단을 나누며 계층 구조를 나타내고 덴드로그램으로 결과를 읽는다.

- 최단연결(single), 최장연결(complete), 평균연결(average), Ward 등의 군집 간 거리 정의에 따라 합쳐지는 순서가 달라진다
- 원하는 높이에서 나무를 잘라 군집 수를 정한다.
- 최단연결은 가까운 한 쌍, 최장연결은 가장 먼 쌍, 평균연결은 군집 간 모든 쌍 거리의 평균을 기준으로 합친다.

예시 지역별 소비성향을 묶어 큰 권역에서 작은 고객군으로 계층을 분석한다.

시험 포인트 덴드로그램 그림 없이 군집 수를 특정값으로 단정하지 않는다.

참고: C32-34 D35-36 G(웹)

05-27 K-means 중심 갱신

핵심 개념 K-means는 미리 정한 K개의 중심에서 시작해 가장 가까운 중심으로 데이터를 할당하고 군집 내 평균으로 중심을 다시 계산해 수렴할 때까지 반복한다.

- 초기 중심·K 선택·자료 표준화·이상치에 영향을 받으며 비볼록 구조·크기 차이가 큰 군집에는 부적합할 수 있다
- 여러 초기화 결과를 비교한다.
- K-means가 최소화하는 대표 목적은 군집 안 관측치에서 각 중심까지의 제곱거리 합(WCSS)이다. 여러 초기화로 지역해를 비교한다.

예시 방문횟수와 평균구매액으로 고객을 K=3 집단으로 묶는다.

시험 포인트 K가 군집 개수이며 KNN의 K는 참고 이웃 수다.

참고: C32-34 D35-36 G(웹)

05-28 PAM·K-medoids

핵심 개념 K-medoids는 실제 관측값 중 대표점(medoid)을 중심으로 군집을 구성하며 PAM은 대표적인 알고리즘이다.

- K-means의 중심이 산술평균인 것과 달리 실제 관측점을 사용해 일부 극단값에 더 강건할 수 있다
- 보통 계산비용은 K-means보다 높다.

예시 소수의 극단적 고액 고객이 포함된 거래 자료를 대표 고객 중심으로 묶는다.

시험 포인트 K-means 평균 중심 vs K-medoids 실제 관측 대표점.

참고: C33-34 D36

05-29 DBSCAN 밀도기반 군집

핵심 개념 DBSCAN은 반경 ε 안의 최소 이웃 수(minPts) 조건을 이용해 밀집된 영역을 군집으로 연결하고 잡음점을 별도로 표시한다.

- 군집 수 K를 미리 지정하지 않고 불규칙한 모양의 군집을 발견할 수 있다
- 밀도가 크게 다른 군집에는 매개변수 하나로 모두 잘 대응하기 어렵다.

예시 지도상 비정상적으로 밀집된 거래 위치를 발견한다.

시험 포인트 K-means는 중심거리, DBSCAN은 밀도연결.

참고: C33-34 D35-36

05-30 혼합분포·EM 알고리즘

핵심 개념 혼합분포모형은 관측값이 여러 확률분포의 조합으로 생성됐다고 가정하고 집단의 소속확률을 추정한다.

- EM은 E단계에서 잠정 소속·잠재변수의 기대를 계산하고 M단계에서 모형 매개변수를 다시 추정해 반복한다
- 하드 할당과 달리 확률적·부드러운 군집할당이 가능하다.

예시 고객이 '절약형'일 확률 0.7, '충성형'일 확률 0.3으로 추정한다.

시험 포인트 K-means=대체로 단일 군집 할당, 혼합분포=소속확률.

참고: C33-34 D35-36

05-31 퍼지 군집·SOM 자기조직화지도

핵심 개념 퍼지 군집은 관측치가 여러 군집에 정도를 달리해 동시에 속하도록 하며, SOM은 경쟁학습으로 고차원 자료를 2차원 격자에 배열한다.

- SOM은 이긴 뉴런과 주변 이웃의 가중치를 조정해 비슷한 데이터가 비슷한 위치에 있도록 만든다
- 지도학습의 일반적인 오차 역전파를 SOM의 핵심 학습 원리로 보지 않는다.

예시 하나의 고객이 두 상품군 취향을 모두 가질 수 있도록 소속 정도를 부여한다.

시험 포인트 퍼지=소속 정도, SOM=경쟁학습·2차원 지도.

참고: C33-34 D36

05-32 군집의 내부 평가·외부 평가

핵심 개념 내부 평가는 라벨 없이 군집의 응집도·분리도를, 외부 평가는 이미 알고 있는 참조 클래스와의 일치 정도를 확인한다.

구분	정답 라벨	대표 지표
내부 평가	필요 없음	실루엣·응집도
외부 평가	필요	순수도 Purity

- 실루엣 s=(b-a)/max(a,b), a=자기 군집 평균거리, b=가장 가까운 다른 군집 평균거리
- Purity는 군집별 가장 많은 참조 라벨 건수를 합해 N으로 나눈다.

예시 K=3과 K=4 결과를 실루엣으로 비교하고, 알려진 고객 등급과 Purity도 비교한다.

시험 포인트 실루엣=내부, Purity=외부. Purity는 연관분석 지표가 아니다.

참고: C33-34 D35-36

05-33 군집 프로파일링과 타깃 세분화

핵심 개념 군집번호만 붙이는 것으로는 실무가 끝나지 않으며 그룹의 크기·특성·안정성·업무 적용 방안을 설명해야 한다.

- 세분집단 간 이동이 잦으면 실무 적용이 어려울 수 있다
- 목표기반 세분화는 특정 구매·가치 목표를 중심으로 그룹을 만들고 결과를 사업 전략에 맞춰 해석한다.

예시 '고빈도·저금액' 고객군에 묶음 할인보다 정기 구독을 실험한다.

시험 포인트 군집화와 타깃 캠페인 설계는 별도의 단계다.

참고: D34-36

05-34 연관분석·장바구니 분석

핵심 개념 연관분석은 거래에서 품목 A와 B가 함께 나타나는 빈번한 패턴을 A→B 규칙으로 표현한다.

- A→B는 A가 B의 원인이라는 뜻이 아니다
- 순차패턴 분석은 시간 순서까지 반영해 A 후에 B가 일어나는 패턴을 찾는다
- 빈도가 낮은 물품은 의미 있는 규칙이어도 쉽게 걸러질 수 있다.
- A→B의 지지도는 전체 거래 중 A와 B가 함께 나온 비율, 신뢰도는 A가 있는 거래 중 B도 있는 비율, 향상도는 신뢰도를 전체 B 발생확률로 나눈 값이다.

예시 빵 구매자가 우유도 자주 구매하는지 살펴 진열·쿠폰을 설계한다.

시험 포인트 장바구니 연관=동시 관계, 순차패턴=순서 관계.

참고: C33-34 D36-37 G(웹)

05-35 지지도 Support

핵심 개념 규칙 A→B의 지지도는 전체 거래에서 A와 B를 모두 포함한 거래 비율이다.

- Support(A→B)=P(A∩B)
- 규칙의 실제 발생 규모를 나타내며 너무 낮으면 일반화·실무 활용에 제약이 있을 수 있다.

예시 100건 거래 중 빵·우유를 함께 산 20건의 지지도=0.2.

시험 포인트 지지도 분모는 전체 거래 N이다.

참고: C33-34 D36-37

05-36 신뢰도 Confidence

핵심 개념 규칙 A→B의 신뢰도는 A를 구매한 거래 가운데 B도 구매한 조건부 비율이다.

- Confidence(A→B)=P(B|A)=P(A∩B)/P(A)
- 기본 구매율이 높은 품목은 신뢰도가 높아도 의미 없는 규칙일 수 있다.

예시 빵 구매 40건 중 우유 동반 20건이면 신뢰도=0.5.

시험 포인트 신뢰도 분모는 A를 포함한 거래 수, 지지도와 다름.

참고: C33-34 D36-37

05-37 향상도 Lift

핵심 개념 향상도는 A를 구매했을 때 B를 살 확률이 원래 B를 살 확률의 몇 배인지 비교한다.

- Lift(A→B)=P(A∩B)/(P(A)P(B))=Confidence/P(B)
- 1이면 독립, 1보다 크면 양의 연관, 1보다 작으면 음의 연관
- 인과효과는 뜻하지 않는다.

예시 빵 동반구매 시 우유확률 0.5, 우유 전체 구매율 0.25면 Lift=2.

시험 포인트 지지도·신뢰도·향상도 각각 분모의 의미로 구별.

참고: C33-34 D36-37

05-38 Apriori·빈발항목집합

핵심 개념 Apriori는 '자주 등장하지 않는 품목집합을 포함한 더 큰 집합 역시 빈발하지 않다'는 성질로 후보 조합을 줄인다.

- 최소 지지도를 만족하는 1개 항목집합에서 시작해 2개·3개 조합으로 확장하고 규칙의 신뢰도·향상도를 평가한다
- 후보 생성 비용은 품목 수가 많으면 커진다.

예시 마트 주문에서 자주 팔리는 2품목 조합만 남기고 3품목 후보를 검사한다.

시험 포인트 Apriori=빈발 조합 후보 가지치기, 부스팅·트리 가지치기와 다른 개념.

참고: C33-34 D36-37

05-39 연관규칙의 실무 함정

핵심 개념 유의미한 규칙은 상품 추천·교차판매·진열에 도움이 되지만 높은 신뢰도만으로 사업 가치를 판단해서는 안 된다.

- 인기 상품 B는 아무 조건에서도 많이 팔려 단순 신뢰도가 높을 수 있고, 드문 고가 상품은 최소 지지도에서 제외될 수 있다
- 목표 고객·매출·마진·실험 결과를 함께 봐야 한다.
- 거래 항목 수가 많아질수록 후보 조합이 급격히 늘어나므로 최소 지지도·신뢰도 설정으로 후보를 줄이고 향상도·비즈니스 타당성을 함께 확인한다.

예시 B가 95% 거래에 등장하면 A→B 신뢰도 95%는 그 자체로 특별하지 않다.

시험 포인트 연관성 발견과 마케팅 시행 효과 검증은 별도다.

참고: D36-37 G(웹)

05-40 순차패턴·시퀀스 분석

핵심 개념 순차패턴 분석은 여러 사건이 함께 발생했는지만 보는 연관규칙과 달리 어떤 순서로 발생했는지를 찾아내는 방법이다.

- '장바구니 A와 B가 동시에 있음'과 'A를 구매한 뒤 일정 기간 후 B 구매'는 다른 조건이다
- 사건 시점·간격·고객별 순서 데이터가 필요하며 시계열 예측과 연결할 수 있다.

예시 앱 설치→첫 구매→구독 해지로 이어지는 고객 행동의 대표 순서를 발견한다.

시험 포인트 장바구니 분석은 함께 발생, 순차패턴은 시간적 순서가 중요하다.

참고: D36-37

DAY 06 · 3과목 · 데이터분석

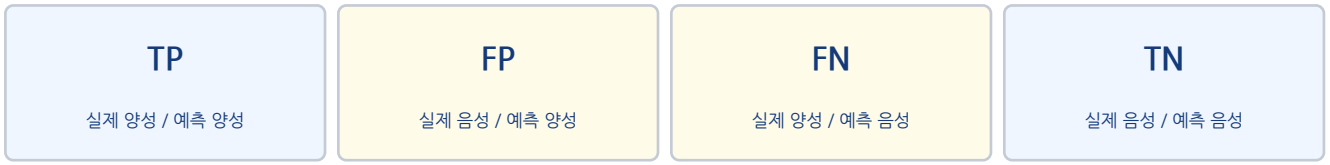
모형 평가와 R 결과 해석

혼동행렬·검증 방법·성능지표의 분모를 분명히 하고 시험용 R 코드를 읽는 훈련을 한다.

06-01 혼동행렬 TP·TN·FP·FN

핵심 개념 혼동행렬은 실제 양성·음성과 모델 예측 양성·음성의 일치·오류를 네 유형으로 나눈 표다.

정답	양성으로 예측	음성으로 예측
실제 양성	TP	FN
실제 음성	FP	TN



- TP=실제양성·예측양성, FN=실제양성·예측음성(놓침), FP=실제음성·예측양성(오탐), TN=실제음성·예측음성
- 지표를 외우기 전에 실제·예측 축 방향을 확인한다.

예시 보안 탐지에서 이상 거래를 정상으로 판단하면 FN, 정상을 이상으로 경고하면 FP.

시험 포인트 정밀도·재현율·특이도는 같은 네 칸을 서로 다른 분모로 사용하는 공식이다.

참고: C28-29 D33

06-02 정확도·오분류율

핵심 개념 정확도는 전체 관측치 중 맞힌 비율, 오분류율은 전체 중 틀린 비율이다.

- Accuracy=(TP+TN)/(TP+FP+TN+FN)
- Error=(FP+FN)/N=1-Accuracy
- 클래스 비율이 크게 불균형하면 정확도만으로 모델을 평가하기 어렵다.

예시 정상 990·이상 10을 전부 정상 예측하면 정확도 99%지만 이상 10건을 모두 놓쳤다.

시험 포인트 전체 데이터가 분모이며 정확도+오분류율=1.

참고: C28-29 D33

06-03 정밀도 Precision

핵심 개념 정밀도는 '양성이라고 예측한 것' 가운데 실제 양성의 비율이다.

구분	분모	의미
정밀도	TP+FP	양성 판정 중 진짜 양성
재현율	TP+FN	실제 양성 중 맞힌 비율

- Precision=TP/(TP+FP)
- 잘못된 양성 경보가 비쌀 때 중요하다
- 예측양성이 하나도 없으면 분모 0으로 통상 정의·처리 방법을 별도 정한다.

예시 경고 20건 중 진짜 사고가 15건이면 정밀도 0.75.

시험 포인트 분모는 예측 양성 TP+FP. 일상어 '측정의 정밀성'과 혼동하지 않는다.

참고: C28-29 D33

06-04 재현율 Recall·민감도 TPR

핵심 개념 재현율은 '실제 양성' 가운데 모델이 양성으로 찾아낸 비율이며 민감도·TPR과 같은 뜻이다.

구분	분모	의미
재현율	TP+FN	실제 양성을 놓치지 않는 비율
정밀도	TP+FP	예측한 양성의 적중률

- Recall=TP/(TP+FN)
- 위험한 사건을 놓치면 피해가 큰 상황에서 중요하다
- 임계값을 낮추면 재현율이 올라가기도 하지만 오탐이 늘 수 있다.

예시 실제 침해 50건 중 45건 탐지면 재현율=0.90.

시험 포인트 분모는 실제 양성 TP+FN.

참고: C28-29 D33

06-05 특이도·FPR·음성예측도

핵심 개념 특이도는 실제 음성 중 음성으로 맞힌 비율, FPR은 실제 음성 중 잘못 양성으로 경고한 비율, NPV는 음성 예측 중 실제 음성 비율이다.

- Specificity=TN/(TN+FP), FPR=FP/(FP+TN)=1-Specificity, NPV=TN/(TN+FN)
- 음성 예측을 평가할 때는 NPV, 실제 음성 대상 탐지 성질은 특이도를 본다.

예시 정상 고객 100명 중 95명을 정상으로 판단하면 특이도=0.95.

시험 포인트 특이도의 분모는 실제 음성, NPV는 예측 음성.

참고: C28-29 D33

06-06 F1·Fβ 점수

핵심 개념 F1은 정밀도·재현율의 조화평균으로 양성 분류의 균형을 요약한다.

- F1=2PR/(P+R)=2TP/(2TP+FP+FN)
- Fβ=(1+β²)PR/(β²P+R)에서 β>1이면 재현율에 더 무게
- 음성 성능 전체를 대신하지는 않는다.

예시 놓침과 오탐을 함께 줄여야 하는 탐지 모델의 단일 비교 지표로 사용한다.

시험 포인트 F1은 정확도와 다른 공식. P=0 또는 R=0 경우 처리 확인.

참고: C28-29 D33

06-07 ROC 곡선·AUC

핵심 개념 ROC 곡선은 양성 판정 임계값을 바꿔 가며 FPR(가로축)과 TPR(세로축)을 그린 것이고 AUC는 그 아래 면적이다.

- 무작위 순위 예측의 기대 AUC는 0.5, 완벽한 순위 구별은 1
- 0.5 미만도 가능하다
- AUC는 순위 판별력을 요약하지만 임계값에서의 실제 비용을 설명하지는 않는다.

예시 사기 탐지 임계값을 여러 값으로 바꾸어 거짓경고율과 탐지율 변화를 본다.

시험 포인트 ROC: X=1-특이도, Y=재현율.

참고: C28-29 D33-34

06-08 PR 곡선·데이터 불균형

핵심 개념 PR 곡선은 정밀도와 재현율의 관계를 그려 양성 클래스가 드문 자료에서 유용한 평가 관점을 제공한다.

- 대부분 정상인 자료에서는 정확도와 ROC-AUC가 높더라도 경고의 대부분이 거짓일 수 있다
- 양성 빈도·실무 비용을 고려해 PR-AUC 및 임계값별 성능을 검토한다.

예시 사기 확률이 낮은 거래에서 상위 위험도 0.1%를 경보할 때의 정밀도 확인.

시험 포인트 PR은 양성의 실제 존재 비율(유병률)에 민감하다.

참고: C28-29 D33

06-09 임계값·비용민감 의사결정

핵심 개념 분류모형의 예측확률을 실제 양성·음성 결정으로 바꾸려면 임계값을 정해야 한다.

- 임계값을 낮추면 일반적으로 탐지가 늘지만 오탐도 늘 수 있다
- FN 비용과 FP 비용, 인력 처리 능력, 비즈니스 목적에 맞춰 임계값을 정한다
- 기본 0.5가 정답은 아니다.

예시 위험 로그인은 낮은 임계값에 추가인증, 고위험은 계정 일시 제한을 한다.

시험 포인트 좋은 확률 모델과 좋은 정책 임계값은 다른 평가 대상이다.

참고: C28-29 D33

06-10 향상도·리프트 차트·이익평가

핵심 개념 Lift 차트는 무작위 고객 선정과 비교해 모델 상위 점수 그룹이 목표 사건을 얼마나 집중시켰는지 보여준다.

- 연관분석의 Lift와 모형 성능 평가의 Lift는 모두 기준 대비 향상이라는 생각을 공유하지만 정의의 맥락이 다르다
- 실제 캠페인에서는 순편익·ROI가 최종 선택 기준이 될 수 있다.

예시 상위 위험도 10% 고객에서 전체보다 이탈 사건이 3배 많이 발견된다면 상위 그룹 Lift는 3.

시험 포인트 모형 선택은 성능 수치 하나보다 목표 사업지표와 비용을 함께 본다.

참고: C28 D32-34

06-11 교차검증·그룹 누출 주의

핵심 개념 교차검증은 여러 분할에서 학습·평가를 반복해 일반화 성능의 안정성을 확인하는 방법이다.

- 분할 전에 전체 데이터의 평균으로 표준화하면 검증자료 정보가 학습에 스며든다
- 같은 사람의 기록이 학습·검증에 동시에 들어가는 경우 그룹기반 분할을 고려한다.

예시 한 고객이 여러 번 주문한 자료를 고객 기준으로 그룹 분할한다.

시험 포인트 전처리·변수선택·하이퍼파라미터 튜닝도 검증 구조 안에서 수행한다.

참고: C27-28 D32

06-12 편향·분산 트레이드오프

핵심 개념 복잡한 모델은 훈련 자료에 더 잘 맞을 수 있지만 표본이 바뀔 때의 예측 변동(분산)이 커질 수 있다.

- 너무 단순한 모델의 구조적 오류는 편향, 과도하게 민감한 모델의 불안정성은 분산으로 이해한다
- 규제·앙상블·교차검증으로 적절한 균형을 찾는다.

예시 깊이 30 나무 하나보다 적절히 제한된 랜덤 포레스트가 안정적일 수 있다.

시험 포인트 편향과 통계의 '표본선택 편향'은 다른 맥락의 말이다.

참고: C28-33 D32-34

06-13 성능평가와 통계적 유의성

핵심 개념 예측모형의 검증은 새 데이터의 예측 성능을 보는 것이고, 통계적 유의성 검정은 표본에서 모수·차이에 관한 주장 근거를 평가한다.

- 높은 R^2나 낮은 p값이 곧 실무 수익을 보장하지 않는다
- 모델의 성능·설명성·운영비·공정성·안정성까지 다르게 평가한다.

예시 새 모델의 AUC가 좋아도 설명 불가능해서 규제상 배포 불가능할 수 있다.

시험 포인트 p값=예측 정확도가 아니다.

참고: C27-28 D32-34

06-14 R 데이터 입출력·탐색 코드

핵심 개념 read.csv·read.table은 표를 읽고 write.csv는 결과를 저장하며 head·summary·str·table로 기본적인 자료 품질을 확인한다.

- read.csv('orders.csv'), head(df), summary(df$amount), table(df$status)처럼 도구를 목적별로 익힌다
- 문자열의 따옴표와 R 대소문자 구분에 주의한다.

예시 거래 CSV를 읽어 구매액의 평균·상태별 빈도를 빠르게 확인한다.

시험 포인트 R 함수 이름과 매개변수의 정확한 문법을 코드 문제에서 읽는다.

참고: C16-17 D25-26

06-15 R lm·summary 회귀출력

핵심 개념 lm(y~x1+x2,data=df)은 선형회귀를 맞추고 summary()는 계수·표준오차·t값·p값·R^2·잔차 정보 등을 보여준다.

- Estimate는 계수 추정, Std.Error는 표준오차, t value는 Estimate/Std.Error, Pr(>|t|)는 양측 검정 p값
- 다른 변수 고정 시 계수 의미를 해석한다.

예시 공부시간 변수의 Estimate=3이면 조건이 같을 때 공부시간 1 증가 시 평균 점수 3 증가로 읽는다.

시험 포인트 p=0.0776은 α=0.05보다 커 유의하지 않다.

참고: C23-24 D28

06-16 R glm 로지스틱 출력

핵심 개념 glm(y~x,family=binomial,data=df)은 이진 결과에 대한 일반화선형모형(로지스틱)을 적합한다.

- 예측 type='response'는 사건확률, 기본 link 척도는 로그오즈
- coef의 지수 exp(β)는 오즈비로 해석한다
- 반응변수의 사건 코딩 방향을 확인한다.

예시 이탈 여부를 로지스틱으로 예측하고 0.7 이상인 고객을 경고한다.

시험 포인트 선형 lm의 숫자예측과 로지스틱 glm의 확률예측을 구분한다.

참고: C23-24 D28

06-17 R t.test·aov·chisq.test

핵심 개념 t.test는 평균 검정, aov는 분산분석, chisq.test는 적합도·독립성 같은 카이제곱 검정에 사용한다.

- t.test(x,mu=기준값), t.test(y~group,data=df), aov(score~class,data=df), chisq.test(table(a,b)) 등 입력 구조를 읽는다
- 대응검정은 paired=TRUE 옵션을 확인한다.

예시 세 반 점수 평균이면 aov, 치료 전후 같은 사람 점수면 t.test(...,paired=TRUE).

시험 포인트 함수 이름뿐 아니라 종속변수 형태와 그룹 구조로 판단한다.

참고: C21-23 D28

06-18 R cor·prcomp·arima

핵심 개념 cor는 상관, prcomp는 PCA, arima는 시계열 ARIMA 모형을 계산하는 대표 함수다.

- cor(x,y,method='spearman')은 순위상관, prcomp(df,scale.=TRUE)는 표준화 기반 PCA, arima(x,order=c(p,d,q))는 ARIMA 차수를 지정한다.

예시 계절 매출 예측에서 차분 차수와 AR·MA 차수 후보를 지정한다.

시험 포인트 prcomp의 loadings·rotation·설명분산과 arima의 order 파라미터를 구분.

참고: C23-26 D28-30

06-19 R 그래프·패키지 기능 구분

핵심 개념 plot·hist·boxplot·pairs 같은 기본 그래프와 ggplot2 같은 시각화 패키지를 사용해 분포·관계를 점검한다.

- hist는 수치 구간빈도, boxplot은 분위·이상치, pairs는 다변량 산점도 행렬
- 그래프를 그렸다는 것만으로 검증된 예측모형이 만들어지는 것은 아니다.

예시 hist(df$age), boxplot(amount~region,data=df)로 집단 비교한다.

시험 포인트 시각화 출력에서 축·범례·집단·범위가 해석의 근거이다.

참고: C17-20 D24-26

06-20 R 의사결정나무·군집·연관 관련 도구

핵심 개념 rpart는 의사결정나무, kmeans는 K-means 군집, hclust는 계층적 군집, arules 패키지는 연관규칙 분석을 돕는다.



- 각 함수의 목적과 입력형태를 구별하고 kmeans의 centers는 군집 개수 또는 초기 중심 지정 관련, hclust는 거리 객체의 병합 구조를 받는다는 점을 기억한다.

예시 hclust(dist(x))로 거리 기반 계층 구조를 만들고 kmeans(scale(x),3)으로 군집을 만든다.

시험 포인트 kmeans()는 분류 정답 없이 군집을 학습한다.

참고: C30-34 D33-37

06-21 분석 재현성과 운영 품질

핵심 개념 분석에 사용한 데이터 범위·전처리·난수시드·모형 버전·평가 기준을 남겨야 같은 결과를 재검증할 수 있다.

- set.seed()는 많은 난수 기반 절차의 재현성을 돕지만 모든 외부 환경 차이를 없애지 않는다
- 운영 중 원천 데이터 변경과 성능 저하를 추적한다.

예시 분석 코드·설정·모형 평가표와 데이터를 버전으로 관리한다.

시험 포인트 재현 가능성은 기출식 문법 암기보다 실무 신뢰성과 관련된다.

참고: D18-23,32

DAY 07 · 3과목 · 데이터분석

텍스트·사회관계망·시뮬레이션·최적화

앞선 통계·데이터마이닝 지식을 문서, 네트워크, 의사결정 문제까지 확장해 연결한다.

07-01 텍스트 마이닝 개요

핵심 개념 텍스트 마이닝은 문서·SNS·리뷰의 언어 자료를 정제·표현·분석해 주제·감정·관계·예측 정보를 얻는 과정이다.

- 문서 분류·문서군집·요약·검색·키워드 추출·감성분석으로 활용하며 언어 특유의 중의성·부정표현·문맥 해석이 중요하다
- 동일한 단어가 분야에 따라 다른 의미를 가질 수 있다.

예시 상품 리뷰 수만 건을 묶어 고장·배송·가격 불만을 자동으로 분류한다.

시험 포인트 텍스트 마이닝은 비정형 원문을 분석에 적합한 특징 벡터 등으로 바꾸는 과정이 필요하다.

참고: D38

07-02 Corpus 말뭉치·전처리

핵심 개념 말뭉치는 분석 목적에 따라 모은 문서 집합이며 정규화·토큰화·불용어 제거·어간 추출·표제어 추출 등의 절차로 문장을 분석용 형태로 만든다.

- 영문은 대소문자·어미 처리가, 한국어는 조사·어미·띄어쓰기·형태소 처리가 중요할 수 있다
- '않다', '없다' 같은 부정 단어를 무작정 불용어로 제거하면 감성 방향이 뒤바뀐다.

예시 '배송이 빠르지 않다'에서 부정표현을 보존해 불만 리뷰로 분석한다.

시험 포인트 불용어 제거·어간 추출은 도움이 될 때 선택적으로 적용한다.

참고: D38

07-03 문서-단어 행렬 DTM·TF-IDF

핵심 개념 DTM은 행=문서, 열=단어, 값=등장 빈도 등으로 문서를 숫자 표로 바꾸는 구조다.

- TF는 문서 내 단어 빈도, IDF는 여러 문서에 드물게 나타나는 단어에 높은 가중치를 주는 개념으로 TF-IDF는 둘을 결합한다
- 희소행렬로 표현되는 경우가 많다.

예시 '배송'이 대부분 리뷰에 나오지만 '누수'는 일부 불량 리뷰에서만 나오면 후자가 특징적인 신호가 될 수 있다.

시험 포인트 DTM은 자료구조, TF-IDF는 가중치 표현 방식이다.

참고: D38

07-04 감성분석·의견 마이닝

핵심 개념 감성분석은 문장이나 문서의 긍정·부정·중립 또는 감정 강도를 추정한다.

- 사전 기반 점수, 지도학습 텍스트 분류, 언어모델 등이 가능하다
- 반어법·부정·대상별 맥락 때문에 단어 하나만으로 감성을 확정하기 어렵다.

> **예시** 신규 환불정책에 관한 후기의 긍정률을 월별로 비교한다.

> **시험 포인트** 문서 집계 추세가 유용해도 개별 예측 오류를 숨기지 않아야 한다.

참고: B4 C5 D38

07-05 워드클라우드·키워드 분석

핵심 개념 워드클라우드는 단어 등장 빈도 등 가중치를 크기·색으로 나타내는 텍스트 시각화 방식이다.

- 눈에 잘 띄는 단어를 보여주지만 문서의 원인·문맥·중요도를 자동 증명하지 않는다
- TF-IDF·공기어 네트워크·토픽 모델과 병행해 의미를 확인한다.

> **예시** 이용후기에서 '배송', '환불', '품질'의 언급 크기를 시각화한다.

> **시험 포인트** 워드클라우드는 감성분석이나 인과분석의 결과와 동일하지 않다.

참고: D38

07-06 정보검색 Precision·Recall

핵심 개념 정보검색에서 Precision은 반환된 문서 중 관련 문서 비율, Recall은 전체 관련 문서 중 찾아낸 비율이다.

- 분류 혼동행렬의 정밀도·재현율과 수학적 구조가 같지만 '양성'의 뜻이 '관련 문서'로 바뀐다
- 더 많이 검색하면 보통 재현율은 늘고 정밀도는 내려갈 수 있다.

> **예시** 검색결과 10건 중 관련 8건이면 정밀도 0.8, 전체 관련 20건 중 8건 발견이면 재현율 0.4.

> **시험 포인트** 검색 정확도를 '전체 정답 비율'이라 말한 자료와 Precision을 혼동하지 않는다.

참고: D38

07-07 사회관계망 분석 SNA

핵심 개념 SNA는 사람·기업·계정 같은 객체를 노드로, 관계를 에지로 나타내 연결 구조·영향력·커뮤니티를 분석한다.

요소	의미
노드	사람·계정·기관 등 대상
간선	연결·관계
중심성	중요한 위치를 수치화

- 친구·거래·메시지·공동작업 관계를 방향 있는 그래프·없는 그래프로 구분
- 개인 특성뿐 아니라 누구와 연결됐는지가 중요한 설명변수가 된다.

예시 SNS 계정의 전파 중심 인물, 부정결제 연관 계정망을 찾는다.

시험 포인트 SNA=관계 구조 분석, 단순 텍스트 키워드 빈도 분석과 다르다.

참고: B4 C5 D38-40

07-08 그래프·인접행렬·1모드·2모드

핵심 개념 네트워크는 정점(vertex)과 에지(edge), 연결 여부 또는 가중치를 기록한 인접행렬로 나타낼 수 있다.

- 1모드는 같은 유형 노드 간 관계(사람-사람), 2모드는 서로 다른 유형(사람-상품) 연결
- 방향·가중치·자기연결의 허용 여부를 문제에 따라 확인한다.

예시 고객×상품 구매 이력 행렬은 2모드 네트워크가 될 수 있다.

시험 포인트 인접행렬의 1은 연결, 0은 미연결을 뜻하는 이진형 표현일 수 있다.

참고: D39

07-09 연결정도 중심성 Degree

핵심 개념 연결정도 중심성은 한 노드가 직접 연결된 이웃의 수 또는 가중치 합을 나타내는 지표다.

- 방향 그래프에서는 들어오는 연결(in-degree)과 나가는 연결(out-degree)을 구분
- 노드 수가 다르면 (n-1)로 나누는 정규화 중심성을 비교할 수 있다.

예시 친구 요청을 많이 받는 계정과 다른 사람에게 많이 메시지를 보내는 계정을 구별한다.

시험 포인트 Degree=직접 연결 수, 중요 이웃까지 반영하는 위세 중심성과 다르다.

참고: D39

07-10 근접·매개·위세 중심성

핵심 개념 근접은 다른 노드까지 평균적으로 얼마나 가까운지, 매개는 다른 노드 사이 최단경로의 중개 역할, 위세는 영향력 높은 이웃과의 연결을 평가한다.

- 근접은 거리 합과 반비례, 매개는 최단경로 통과 비율, 위세(eigenvector)는 중요한 이웃과의 연결에 가중
- 그래프가 분리돼 있으면 근접 정의에 별도 주의 필요하다.

예시 두 회사 커뮤니티를 잇는 계정은 매개중심성이 높을 수 있다.

시험 포인트 연결정도=직접 이웃, 근접=거리, 매개=경유, 위세=중요한 이웃.

참고: D39

07-11 네트워크 밀도·상호성·전이성

핵심 개념 밀도는 가능한 연결 가운데 실제 연결의 비율, 상호성은 서로 주고받는 방향 연결, 전이성은 친구의 친구 관계가 닫힌 삼각관계로 이어지는 경향이다.

- 경로 길이·도달성·삼자 관계 빈도도 네트워크의 전역 특성으로 사용
- 단순히 노드 수가 많다고 밀도가 높은 것은 아니다.

예시 메신저 그룹의 구성원이 촘촘히 소통하면 밀도가 높을 수 있다.

시험 포인트 네트워크 수준 통계량과 개별 노드 중심성을 구분한다.

참고: D39

07-12 커뮤니티 탐지·Walktrap·에지 매개

핵심 개념 커뮤니티 탐지는 전체 네트워크에서 내부 연결이 상대적으로 밀집된 집단을 찾는 기법이다.

- Walktrap은 짧은 무작위 보행에서 같은 커뮤니티에 머무르는 경향, 에지 매개 기반 방식은 집단 사이를 잇는 다리 에지의 역할을 이용한다
- 발견된 집단에 고객 속성·행동을 결합해 프로파일링할 수 있다.

예시 고객 추천 관계망에서 취향이 유사하게 연결된 집단을 찾아 마케팅에 활용한다.

시험 포인트 SNA의 커뮤니티는 군집과 유사한 목적이나 입력이 그래프 관계라는 차이가 있다.

참고: D39-40

07-13 사회연결망의 활용과 주의

핵심 개념 SNA는 이탈 전파·입소문·사기 계정망·커뮤니티 영향력·추천 대상 발굴에 쓰인다.

- 네트워크 데이터는 연결이 무수히 많으면 계산·시각화가 어려워지고 개인관계 개인정보 문제가 생길 수 있다
- 그림이 보여주는 연결은 실제 인과·친밀도와 다를 수 있다.

예시 동일 전화번호·기기ID를 공유하는 이상 계정의 네트워크를 조사한다.

시험 포인트 중심성이 높다고 항상 사회적 신뢰가 높다는 뜻은 아니다.

참고: D39-40

07-14 시뮬레이션의 정의와 목적

핵심 개념 시뮬레이션은 현실의 복잡한 시스템을 모형으로 단순화해 조건을 바꿔 실행하면서 예상 결과·위험·대안을 비교하는 모의실험이다.

- 실제 테스트 비용이 높거나 위험하거나 시간이 오래 걸릴 때 유용하다
- 분석 데이터·확률분포·업무 규칙을 입력하고 결과를 여러 번 검증해야 한다.

예시 병원 접수 인원을 늘리면 대기시간이 얼마나 줄어들지 가상 실행한다.

시험 포인트 시뮬레이션은 '무슨 일이 일어날까', 최적화는 '가장 좋은 선택은 무엇인가'를 주로 묻는다.

참고: D40-42

07-15 정적·동적·결정론·확률적 시뮬레이션

핵심 개념 정적 모델은 한 시점·일정 조건의 상태, 동적 모델은 시간 변화, 결정론 모델은 같은 입력에 같은 출력, 확률적 모델은 난수·확률변수로 변동을 반영한다.

- 연속형 상태변수와 이산사건으로 구분할 수도 있으며 둘을 조합한 하이브리드 모델도 있다
- 몬테카를로는 확률적 반복 샘플링에 자주 쓰인다.

예시 대기행렬의 고객도착 시간과 서비스시간을 확률분포로 생성한다.

시험 포인트 정적/동적은 시간 관점, 결정론/확률론은 무작위성 관점이다.

참고: D40-41

07-16 몬테카를로와 이산사건 시뮬레이션

핵심 개념 몬테카를로는 확률변수를 반복 추출해 결과 분포를 추정하는 방법, 이산사건 시뮬레이션은 특정 사건이 일어날 때 시스템 상태를 갱신하는 방식이다.

- 몬테카를로는 복잡한 위험의 확률범위를 볼 수 있고 이산사건은 고객 도착·처리·대기처럼 이벤트 순서를 반영한다
- 난수시드·반복횟수·표본오차를 관리한다.

예시 택배 지연 확률은 몬테카를로, 콜센터 상담 대기시간은 이산사건으로 평가한다.

시험 포인트 몬테카를로=확률 반복, 이산사건=이벤트 기반 상태변화.

참고: D40-42

07-17 시뮬레이션의 장점·한계

핵심 개념 실제 시스템을 바꾸지 않고 여러 대안을 비교하고 긴 시간을 압축해 실험할 수 있다는 것이 장점이다.

- 모형 개발과 검증 비용이 들고 복잡한 가정을 잘못 설정하면 결과가 현실과 달라질 수 있다
- 확률적 모델은 여러 번 실행해 결과의 변동성을 추정해야 한다.

예시 공장 설비 추가 이전에 생산량 증가·병목 구간을 모의 분석한다.

시험 포인트 시뮬레이션이 자동으로 '최적' 대안을 제시하는 것은 아니다.

참고: D40-41

07-18 시뮬레이션의 일곱 단계

핵심 개념 문제 정의→비용·효용 검토→모델 개발 방식 선택→프로그램 구현→현실 적합성 검증→모의실험 실행→결과 분석으로 정리할 수 있다.

- 단계는 현실 문제·자료 수집 여건에 따라 되돌아가거나 바뀔 수 있다
- 실제 자료·전문가의 피드백으로 모델을 검증하고 유용한 행동 지침을 도출한다.

예시 매장 대기시간 문제를 정의하고 도착률 자료로 모형 구축 후 인력 시나리오 비교.

시험 포인트 모델이 실행된다는 것과 모델이 실제 상황을 적절히 표현한다는 것은 다른 검증이다.

참고: D41

07-19 최적화·목적함수·제약조건

핵심 개념 최적화는 의사결정변수의 값을 선택해 제약조건을 만족하면서 목적함수를 최대화하거나 최소화하는 방법이다.

- 목적함수는 이익·비용·시간 등 기준, 제약은 예산·인력·재고·법규 등 한계
- 실행가능해(feasible solution)와 최적해(optimal solution)를 구분한다.

예시 배송차량 수·경로를 정해 총 배송시간을 최소화하되 차량용량을 넘기지 않는다.

시험 포인트 시뮬레이션은 시나리오 평가, 최적화는 기준 아래 최선의 선택 탐색.

참고: B4 D40-42

07-20 선형계획법 LP·혼합정수계획 MIP

핵심 개념 LP는 목적함수·제약식이 선형이고 연속 의사결정변수를 다루는 대표 최적화 기법이며 MIP는 일부 변수가 정수로 제한된 문제를 포함한다.

- 직원 수·창고 개수처럼 분할할 수 없는 의사결정은 정수 변수를 고려해야 한다
- 제약이 서로 충돌하면 실행가능한 해가 없을 수 있다.

예시 광고비 배분은 LP로 근사, 점포를 열지 말지의 0/1 결정은 정수모형으로 표현한다.

시험 포인트 LP=연속 선형, MIP=일부 정수 변수.

참고: D40,42

07-21 최적화 민감도 분석·그림자 가격

핵심 개념 민감도 분석은 입력계수·제약 한계를 바꿨을 때 최적해와 목적값이 얼마나 달라지는지 살펴보는 것이다.

- 그림자 가격(dual value)은 특정 제약의 우변이 소폭 바뀔 때 목적값이 변하는 양을 의미하는 조건부 값이다
- 항상 모든 범위에서 일정한 효과를 주지는 않는다.

예시 창고 처리량 상한을 1단위 늘렸을 때 배송비가 얼마나 줄어드는지 분석한다.

시험 포인트 '그림자가격=독립변수가 1 증가하면 목적함수가 무조건 변하는 양'은 지나친 일반화다.

참고: D42

07-22 유전알고리즘 GA

핵심 개념 유전알고리즘은 선택·교차·돌연변이를 반복해 후보 해의 집단을 개선하는 최적화 탐색 방법이다.

- 목적함수와 제약이 복잡해 정확한 수학 최적화가 어려운 문제에도 적용 가능하지만 언제나 전역 최적해를 보장하지 않는다
- 적합도 평가와 다양성 유지가 중요하다.

예시 행사 일정과 방송 편성을 여러 조합으로 바꾸어 시청률 기대값을 높인다.

시험 포인트 GA는 지도 분류 알고리즘이 아니라 최적화 메타휴리스틱.

참고: B4 C5 D40-42

07-23 최적화 수행 단계

핵심 개념 문제 이해→결정변수 선택→평가기준 선택→목적함수 작성→제약식 작성→입력자료 수집→해 탐색과 검증의 순서로 정리한다.

- 해가 없으면 제약·자료·모형 정의를 검토해야 하며, 임의로 제약을 바꾸어 원하는 결과를 만들면 실제 의사결정에 부적절하다
- 단순한 모형부터 점진적으로 개선한다.

예시 인력 10명·예산 100만원이라는 제약 아래 상담 대기시간 최소화를 모델링한다.

시험 포인트 '목적함수'와 '제약조건'을 정확히 구별한다.

참고: D42

07-24 운영분석의 닫힌 고리

핵심 개념 분석 결과를 업무행동에 반영하고 그 행동 결과를 다시 데이터로 수집해 다음 판단을 개선하는 반복 체계다.

- 예측→최적화→실행→관측→모형 검증·개선을 이어 붙이면 데이터가 실무 의사결정을 지속적으로 돕는다
- 자동화는 오류 감시·인간의 재검토 절차가 함께 필요하다.

예시 배송량 예측→차량 배차 최적화→실제 배송시간 피드백→모형 개선.

시험 포인트 운영 적용과 일회성 보고서 제출은 다르다.

참고: D22-23,40-42

07-25 공간분석·GIS·지리정보

핵심 개념 공간분석은 좌표·거리·행정구역·경로·인접 관계를 사용해 지리적으로 나타나는 패턴을 찾는 기법이다.

- GIS는 공간정보를 저장·관리·분석·표시하는 체계이고, 핫스팟 탐지·경로최적화·상권분석·위치기반서비스(LBS) 등에 활용한다
- 지구상의 경위도와 직선 거리는 같은 단위가 아니므로 적절한 좌표계·거리 계산이 필요하다.

예시 교통사고 위치를 지도에 표시해 사고가 집중된 교차로를 찾는다.

시험 포인트 공간 위치의 가까움과 고객 속성의 유사성은 다른 거리 정의이다.

참고: C3 D3,23

07-26 사회연결망 구조적 틈새·집중도

핵심 개념 구조적 틈새는 서로 충분히 연결되지 않은 집단 사이를 매개하는 위치이고, 집중도는 네트워크의 연결이나 중심성이 소수 노드에 몰리는 정도다.

- 매개 중심성은 단일 노드의 중개 역할, 네트워크 집중도는 전체 분포의 쏠림을 평가한다
- 직접 연결 수가 적어도 여러 집단을 연결하는 다리가 중요한 위치일 수 있다.

예시 다른 조직과 거의 연결되지 않은 두 연구팀을 잇는 담당자의 중개 역할을 찾는다.

시험 포인트 중심성=한 노드의 위치, 집중도=전체 네트워크 구조의 편중.

참고: D39

07-27 문서 분류·문서 군집·정보검색

핵심 개념 문서 분류는 미리 정한 카테고리로 텍스트를 배정, 문서 군집은 라벨 없이 유사한 문서를 묶고 정보검색은 질문에 관련된 문서를 찾아 순위를 매긴다.

- 분류는 정답 라벨이 있는 지도학습을, 군집은 비지도학습을 주로 이용
- 검색에서는 관련 문서의 누락·오탐을 재현율과 정밀도로 평가한다
- 같은 텍스트 특징 벡터를 여러 과제에 재사용할 수 있다.

예시 고객문의의 '환불'·'배송' 카테고리 분류와 새 유형 문의 발견을 서로 다른 방식으로 수행한다.

시험 포인트 문서 검색 결과의 순위 품질·문서 라벨 분류 정확도·문서 주제 군집은 목표가 다르다.

참고: D38

부록 A. 시험 필수 공식

계산 전에 분모가 무엇인지, 어떤 조건에서 적용하는지 확인하세요.

기초통계

항목	공식	의미와 조건
산술평균	x_bar = Σx_i / n	값의 합을 개수로 나눈 대표값
표본분산	s^2 = Σ(x_i - x_bar)^2 / (n-1)	표본 평균에서 떨어진 제곱거리의 평균 성격
표준편차	s = √s^2	관측값의 퍼짐, 원래 단위 유지
표준오차	SE(x_bar) = s / √n	표본평균 추정의 흔들림
변동계수	CV = s / x_bar	평균에 대한 상대 산포, 적용 조건 확인
기하평균	GM = (x1*x2*…*xn)^(1/n)	곱셈적 성장 비율에 적합
조화평균	HM = n / SUM(1/xi)	평균 속도 등 분모 구조 주의
공분산	Cov(X,Y) = SUM[(xi-xbar)(yi-ybar)]/(n-1)	두 변수 동반 변화 방향
피어슨 상관	r = Cov(X,Y) / (sx*sy)	-1 ~ 1, 단위 없는 선형 상관

확률

항목	공식	의미와 조건
합집합	P(A∪B)=P(A)+P(B)-P(A∩B)	중복된 교집합 한 번 빼기
조건부확률	P(A|B)=P(A∩B)/P(B)	B가 일어났다는 조건의 분모
독립	P(A∩B)=P(A)P(B)	A와 B가 독립일 때만
여사건	P(A^c)=1-P(A)	한 번 이상=1-0회
베이즈	P(H|E)=P(E|H)P(H)/P(E)	사후=우도×사전/증거

분포

항목	공식	의미와 조건
이항	P(X=k)=C(n,k)*p^k*(1-p)^(n-k)	n번 독립 성공/실패의 성공 횟수
이항 평균·분산	E[X]=np, Var[X]=np(1-p)	고정 n과 성공확률 p
포아송	P(X=k)=e^(-λ) λ^k/k!	단위 구간 사건 건수, 평균·분산=λ
기하	P(X=k) = (1-p)^(k-1)*p	첫 성공까지 시행횟수 k
기대값	E[X] = SUM[x*P(X=x)]	가능한 결과의 확률 가중 평균

통계 추론

항목	공식	의미와 조건
평균 t통계량	t=(x_bar-μ_0)/(s/√n)	관측 평균 차이 / 표준오차
정규근사 신뢰구간	x_bar ± 1.96 × SE	95% 근사, 적용 조건을 확인
카이제곱	chi^2 = SUM[(O-E)^2/E]	관측빈도 O와 기대빈도 E 비교

분산분석

항목	공식	의미와 조건
F통계량	F=집단간 MS / 집단내 MS	분산분석의 평균비

회귀

항목	공식	의미와 조건
단순회귀	Y = β_0+β₁X+ε	절편·기울기·오차항
개별 계수 t	t = beta_hat_j / SE(beta_hat_j)	계수가 0인지 검정
결정계수	R^2 = 1 - SSE/SST	설명한 표본 변동의 비율
수정 R^2	1-(1-R^2)(n-1)/(n-p-1)	설명변수 p개에 대한 보정
VIF	1/(1-R_j^2)	해당 X의 보조회귀 R^2 이용
오즈	p/(1-p)	사건 확률을 오즈로 변환
오즈비	exp(β)	로지스틱 기울기의 지수
로지스틱 확률	p = 1/(1+exp(-z))	z = beta0 + beta1*x1 + …

모형 선택

항목	공식	의미와 조건
AIC	-2logL + 2k	적합도와 모형 복잡도
BIC	-2logL + klogn	표본 n에 따른 벌점

군집

항목	공식	의미와 조건
유클리드 거리	√Σ$(x_i-y_i)^2$	직선거리
맨해튼 거리	Σ|x_i-y_i|	좌표별 절댓값 거리 합
실루엣	(b-a)/max(a,b)	응집도와 다른 군집으로부터의 분리

의사결정나무

항목	공식	의미와 조건
지니	$1-\Sigma p_k^2$	값이 작으면 노드가 순수
엔트로피	$-\Sigma p_k \log_2 p_k$	불확실성·혼합 정도

분류 평가

항목	공식	의미와 조건
정확도	(TP+TN)/(TP+FP+FN+TN)	맞힌 결과 / 전체
오분류율	(FP+FN)/N	틀린 결과 / 전체
정밀도	TP/(TP+FP)	맞힌 양성 / 예측 양성
재현율	TP/(TP+FN)	맞힌 양성 / 실제 양성
특이도	TN/(TN+FP)	맞힌 음성 / 실제 음성
FPR	FP/(FP+TN)	1-특이도
음성예측도	TN/(TN+FN)	맞힌 음성 / 예측 음성
F1	2PR/(P+R)	정밀도·재현율 조화평균
F-beta	(1+b^2)*P*R / (b^2*P+R)	b가 커지면 재현율 가중 증가

연관규칙

항목	공식	의미와 조건
지지도	P(A∩B)	A와 B 동시 등장 / 전체
신뢰도	P(B|A)	A 구매 중 B도 구매
향상도	P(A∩B)/(P(A)P(B))	1=독립, 1보다 크면 양의 연관

전처리

항목	공식	의미와 조건
표준화 Z	(x-평균)/표준편차	평균 0·표준편차 1 변환
Min-Max	(x-최소)/(최대-최소)	0~1 범위 변환(조건 충족 시)

시계열

항목	공식	의미와 조건
1차 차분	$\Delta Y_t = Y_t - Y_{t-1}$	시간적 변화량

군집

항목	공식	의미와 조건
K-means 군집내 제곱합	$WCSS = \sum_k \sum_{x \in C_k} \|x-\mu_k\|^2$	군집 내 각 점과 중심의 제곱거리 합, 작게 만드는 방향

다차원척도법

항목	공식	의미와 조건
MDS 스트레스 개념	$Stress \approx \sqrt{\Sigma(d_{ij}-\delta_{ij})^2 / \Sigma\delta_{ij}^2}$	정의·정규화 버전마다 형태가 다름. 일반적으로 작을수록 재현 양호

부록 B. 계산 문제 연습

공식 기호 → 숫자 대입 → 답 → 의미의 순서로 계산하세요.

01 표본분산과 표준편차

문제 조건 데이터 2, 4, 6 (n=3)

계산 과정 평균=(2+4+6)/3=4. 편차 제곱합=$(-2)^2+0^2+2^2=8$.

예시 정답: 표본분산 $s^2=8/(3-1)=4$, 표준편차 $s=2$

헷갈리지 않기 표본분산 분모가 n이 아니라 n-1인 이유: 표본평균을 추정하는 데 자유도 1을 사용한다.

02 일표본 t통계량

문제 조건 표본평균 74, 귀무가설 평균 70, s=10, n=25

계산 과정 $SE=s/\sqrt{n}=10/5=2$. 평균 차이=74-70=4.

예시 정답: $t=(74-70)/2=2$

헷갈리지 않기 t=2라는 수치 자체가 유의성을 확정하지 않는다. 자유도와 단측·양측 기준을 함께 확인한다.

03 혼동행렬의 다섯 지표

문제 조건 TP=36, FN=4, FP=9, TN=51 (전체 100)

계산 과정 정밀도=36/(36+9)=0.800. 재현율=36/(36+4)=0.900.

예시 정답: 정확도=(36+51)/100=0.870. 특이도=51/(51+9)=0.850. F1=72/(72+9+4)≈0.847.

헷갈리지 않기 정밀도는 예측 양성, 재현율은 실제 양성이 분모다.

04 지지도·신뢰도·향상도

문제 조건 100건 거래: A 구매 40, B 구매 25, A·B 동시 20

계산 과정 P(A)=40/100=0.4, P(B)=25/100=0.25, $P(A\cap B)=20/100=0.2$.

예시 정답: 지지도=0.2, 신뢰도=20/40=0.5, 향상도=0.5/0.25=2.0.

헷갈리지 않기 향상도 2는 B 구매가 A 조건에서 전체보다 2배 흔하다는 뜻이며 인과를 증명하지 않는다.

05 베이즈 양성 이후 실제 질병확률

문제 조건 유병률 1%, 민감도 90%, 특이도 95%

계산 과정 P(질병∩양성)=0.01×0.90=0.009. P(건강∩양성)=0.99×0.05=0.0495.

예시 정답: P(질병|양성)=0.009/(0.009+0.0495)≈0.154 (15.4%).

헷갈리지 않기 검사 민감도 90%와 양성 이후 실제 질병확률 15.4%는 다른 조건부확률이다.

06 정규근사 신뢰구간

문제 조건 표본평균 70, 표준오차 2, 95% 정규근사

계산 과정 오차한계=1.96×2=3.92.

예시 정답: 신뢰구간=70±3.92=[66.08,73.92].

헷갈리지 않기 95%라는 수치는 구간을 만드는 절차의 장기적 포함 비율로 해석한다.

07 분류나무의 지니불순도

문제 조건 노드 10명 중 양성 7명, 음성 3명

계산 과정 p_+=0.7, p_-=0.3.

예시 정답: Gini=1-(0.7²+0.3²)=1-(0.49+0.09)=0.42.

헷갈리지 않기 한 클래스만 있으면 Gini=0. 노드를 잘 나누면 가중평균 불순도가 줄어든다.

08 랜덤 포레스트의 무작위성

문제 조건 고객 예측에 설명변수 16개가 있고 분류 문제

계산 과정 부트스트랩으로 각 나무의 학습행을 복원추출한 뒤 분할에서 무작위 변수 후보를 고른다.

예시 정답: √16=4는 자주 쓰는 분할 후보 개수의 출발점. 최적 설정이라고 보장되지 않음.

헷갈리지 않기 여러 나무를 독립적으로 키워 평균·다수결로 결합하면 배깅 계열이다. 부스팅처럼 이전 오차를 순차 보완하는 구조가 아니다.

09 완전사례·평균대치·다중대치 비교

문제 조건 구매액 100건 중 15건 결측

계산 과정 완전사례분석은 85건으로 계산, 평균대치는 15칸을 한 번 대체, 다중대치는 여러 완성 데이터를 분석 후 통합.

예시 정답: 방법마다 편향·불확실성 조건이 달라 한 방법이 언제나 최선은 아님.

헷갈리지 않기 결측 패턴을 먼저 확인하고 학습·검증 분할 이후 전처리 규칙을 훈련 자료에서 정해야 데이터 누출을 방지한다.

10 MDS 거리 보존과 PCA 비교

문제 조건 고객 간 유사도가 주어져 있고 고객별 변수 원자료는 없다

계산 과정 MDS는 주어진 유사도/거리에서 2D 배치, PCA는 원 수치 변수의 공분산 구조로 축을 찾는다.

예시 정답: 거리표만 주어진 경우 MDS가 자연스러운 선택이다.

헷갈리지 않기 MDS의 스트레스는 적합 품질, PCA의 고윳값·기여율은 설명 분산을 나타낸다.

부록 C. 출처별 표현 차이와 교정

같은 개념의 표기가 자료마다 다른 경우, 옳은 정의와 조건을 따로 기록했어요.

01 데이터베이스 네 특징

자료 비교 A 3쪽의 네 번째 항목은 운영 데이터로 설명되나 다른 세 자료는 변화되는 데이터를 기본 특징으로 명시한다.

교정·보완 통합·저장·공용·변화를 기본 네 특징으로 정리. 운영 데이터는 별도의 성격으로 보충.

02 What/How 네 영역

자료 비교 A 6쪽의 2×2 표에는 대상·방법 조건과 솔루션·통찰의 배치가 일치하지 않는 부분이 있다.

교정·보완 대상 O·방법 X=솔루션, 대상 X·방법 O=통찰을 축 정의로 판별.

03 CRISP-DM 단계

자료 비교 일부 축약 노트는 마지막 단계를 생략·축약하거나 모델링 평가와 업무 평가를 섞어 쓴다.

교정·보완 6단계 업무→데이터 이해→준비→모델링→평가→전개. 사업 적합성 평가는 별도.

04 빅데이터 4V·5V

자료 비교 일부는 4V=3V+Value, 다른 설명은 신뢰성 Veracity도 포함한다.

교정·보완 3V는 공통. 확장 V의 선택은 정의·관점에 따라 다름을 표시하고 Value와 Veracity 둘 다 학습.

05 정성·정량 / 정형·비정형

자료 비교 정성 자료를 비정형과, 정량 자료를 정형과 완전히 동일시한 설명이 있다.

교정·보완 측정한 값의 성격과 저장 구조는 다른 기준. 표의 범주형 값은 정성+정형일 수 있다.

06 신뢰구간 95%

자료 비교 일부 문서는 신뢰구간에 모수가 있을 확률을 95%라고 기술한다.

교정·보완 빈도주의 신뢰구간은 반복 표본에서 만든 구간의 장기 포함률 95%라는 뜻.

07 R 행렬 채우기

자료 비교 일부 노트는 matrix()가 행부터 채워지는 듯 표현한다.

교정·보완 R은 기본 열 우선이며 byrow=TRUE 옵션으로 행 우선 채우기 설정 가능.

08 비정형 데이터의 연산

자료 비교 반정형·비정형은 연산이 불가능하다고 단정하는 표현이 있다.

교정·보완 전처리·구조 추출·특징화 후 분석 가능. 핵심은 고정 스키마 유무.

09 개인정보 익명·가명

자료 비교 익명정보는 어떤 방법으로도 절대 누구인지 알 수 없고 가명정보는 무조건 동의 없이 사용 가능하다는 식의 단정이 있다.

교정·보완 합리적으로 예상 가능한 재식별 수단과 구체적 법적 요건에 따라 구분.

10 회귀 Ridge와 정보기준

자료 비교 일부 복원·요약에는 Ridge 명칭을 생략하거나 AIC/BIC와 규제회귀의 차이를 흐리게 설명한다.

교정·보완 Ridge=L2, Lasso=L1 벌점 회귀. AIC/BIC는 별도 모형 비교 기준.

11 모형 평가의 정밀도

자료 비교 프로젝트 관리의 accuracy/precision은 측정 정확성/반복 일관성 의미로 소개되기도 하고, 분류모형의 precision은 TP/(TP+FP)다.

교정·보완 정밀도라는 한국어가 같은데 평가 대상과 분모가 다르므로 맥락을 분명히 분리.

12 표본조사·인과 관계

자료 비교 빅데이터 시대에 전수조사·상관분석이 확대되면서 표본·인과가 필요 없어진다는 식의 서술이 있다.

교정·보완 전수자료의 편향도 가능하며 상관 관계만으로 인과를 확정할 수 없다.

13 ARIMA와 이동평균

자료 비교 단순 이동평균 평활과 MA(q) 과거오차 모형을 같은 개념처럼 설명할 수 있다.

교정·보완 평활은 과거값 평균, MA(q)는 과거 백색잡음의 선형결합으로 구분.

14 분포에 관한 일반화

자료 비교 자료의 양이 충분히 많으면 원자료 자체가 정규분포를 따른다는 단정이 있다.

교정·보완 중심극한정리는 적절한 조건에서 표본평균 분포의 정규근사를 설명한다.

15 최적화 제약과 최적해

자료 비교 모든 계수에 불확실성이 있으면 최적화 불가능하다는 식의 지나친 표현이 있다.

교정·보완 민감도·확률적·강건 최적화 등 불확실성 하의 방법도 존재. 실행 불가능성과 불확실성은 다르다.

16 기출 문항 표기

자료 비교 예전 자료의 단답형·서술형 공부법이나 단정적 출제 빈도 표현은 현행 시험 범위를 별도 확인해야 한다.

교정·보완 시험 형식은 공식 자료로 최종 확인하고, 이 교재는 개념 판별·4지선다 대비에 집중.

17 KDD 단계 수 표시

자료 비교 PDF E 57~59쪽은 비즈니스 이해를 포함하여 KDD 단계를 여섯 항목으로 보여 준다.

교정·보완 대표적으로 암기하는 KDD 핵심 흐름은 데이터선택→전처리→변환→마이닝→평가의 다섯 단계이며, 비즈니스 이해는 필수적 배경 활동으로 별도 보충한다.

18 이상치 판정과 제거

자료 비교 PDF F 1~2쪽은 ±3표준편차·IQR 방식 등을 소개하지만 모든 극단치를 제거해야 한다고 볼 수 없다.

교정·보완 이상값 여부의 원인·목표변수·분포를 확인하며, 특정 기준은 후보 탐지 기법이지 자동 삭제 기준이 아니다.

19 MDS와 다중공선성

자료 비교 PDF F 3쪽의 O/X 설명에는 MDS가 다중공선성을 해결한다고 기술돼 있다.

교정·보완 MDS는 주로 관측치 사이 비유사도의 저차원 표현이다. 변수의 다중공선성 진단·완화는 VIF·Ridge·PCA 등을 구별해 검토한다.

20 PCA 기여율의 고정 기준

자료 비교 PDF F 4쪽은 누적기여율 85% 이상을 기준으로 제시한다.

교정·보완 85%는 해석 목적에 따른 선택 기준 중 하나이고, 고윳값·스크리 플롯·검증 성능 등을 함께 판단한다.

21 다중 대치법 정의

자료 비교 PDF F 1쪽은 단순 대치법을 여러 번 실시한 결과로 다중대치를 설명한다.

교정·보완 다중대치는 결측의 조건부 분포에서 여러 완성 데이터를 생성하고 분석 결과를 결합해 불확실성을 반영하는 방식이다.

22 랜덤 포레스트·부스팅 혼합

자료 비교 블로그 3과목 정리의 앙상블 설명에서 랜덤 포레스트를 부스팅처럼 선형결합으로 묶는 대목이 있다.

교정·보완 랜덤 포레스트는 부트스트랩 표본과 분할변수 무작위성을 활용하는 배깅 계열이며 부스팅은 오류를 순차 보완한다.

23 랜덤 포레스트 성능의 단정

자료 비교 블로그는 RF가 배깅·부스팅보다 더 정확하고 변수 수 제곱근을 최적으로 설명하는 표현이 있다.

교정·보완 우월한 정확도는 데이터셋·하이퍼파라미터·평가 방식에 따라 달라진다. sqrt(p)는 분류의 흔한 경험적 설정 중 하나다.

24 신경망의 일률적 사전 이산화

자료 비교 블로그에 입력변수를 범주로 이산화하면 좋다는 설명이 있다.

교정·보완 신경망은 연속형 값을 그대로 사용할 수 있으며 표준화·정규화가 유용한 경우가 많다. 무조건 구간화하면 정보 손실이 가능하다.

25 연관분석 예시의 분모 일관성

자료 비교 블로그의 지지도·신뢰도·향상도 숫자 예시는 서로 다른 가상 거래 개수와 분모가 이어지는 구간이 있다.

교정·보완 공식 정의를 기준으로 각 지표의 분모를 먼저 확인하고, 하나의 일관된 거래표로 재계산한다.

26 로지스틱 회귀 계수 검정

자료 비교 PDF F 5쪽은 로지스틱 모형 검정에 카이제곱을 강조한다.

교정·보완 로지스틱 모형 전체는 우도비 카이제곱 등을 활용할 수 있고 개별 계수는 Wald z 검정도 자주 쓰인다. 선형회귀와 t검정 동일시를 피한다.

27 정규성·정상성 용어

자료 비교 PDF F 2~3쪽에서 회귀 오차가 정규분포임을 정상성으로 표현한 부분이 있다.

교정·보완 오차의 정규성(normality)과 시계열 정상성(stationarity)은 전혀 다른 개념이다.

28 확률과 검정력

자료 비교 PDF F 2쪽에는 제2종 오류를 귀무가설을 채택한 것으로 표현한다.

교정·보완 엄밀하게 귀무가설 기각 실패이며, 검정력은 1-β다.

29 의사결정나무의 CART 회귀분할

자료 비교 PDF F 5쪽은 연속형 출력의 경우 이진분리라고 써 분할수와 분할기준을 혼동할 수 있다.

교정·보완 CART는 분류·회귀 모두 이진분할을 사용한다. 분류는 주로 지니, 회귀는 SSE·분산 감소 등을 사용한다.

부록 D. 학습 출처와 통합 기준

원본 PDF와 추가 자료를 한 개념의 누적 설명으로 정리한 기준입니다.

상황	통합 처리
정의와 설명이 모두 동일	하나의 설명만 유지
같은 개념인데 예시나 조건이 추가	기존 항목의 설명을 계속 확장
용어는 같지만 의미나 공식이 다름	서로 다른 맥락을 나란히 비교
출처 간 설명에 오류·불일치	학습용 교정안을 만들고 부록에 기록
새 자료에만 등장하는 개념	독립 항목으로 추가

코드	참고 자료
A	ADsP 7일 완성 요약집 11페이지 미리보기 (디자인 기준)
B	데이터분석 준전문가 핵심 요약노트 8쪽
C	2026 ADsP 요약자료 34쪽
D	ADsP내용정리 42쪽
E	2025 핵심내용 요약 113쪽
F	3과목 데이터 분석 이론 5쪽
G	사용자 제공 3과목 블로그 글

확인 본 자료는 개인 학습용 요약 교재이며 한국데이터산업진흥원 공식 교재는 아닙니다. 기존 PDF에서 내용이 다른 부분은 출처를 비교해 설명을 보완했습니다.

D-DAY. 시험 직전 확인

암기보다 중요한 것은 비슷한 개념을 문제 상황에 맞게 구별하는 것입니다.

과목	반드시 구별할 내용
1과목	DIKW = 데이터·정보·지식·지혜 / SECI = 공통화·표출화·연결화·내면화
1과목	DB 특성 = 통합·저장·공용·변화 / 3V = 크기·속도·다양성
1과목	정성·정량(값의 의미) ≠ 정형·비정형(저장 구조)
2과목	KDD = 선택·전처리·변환·마이닝·평가
2과목	CRISP-DM = 업무·데이터 이해·준비·모델링·평가·전개
2과목	What/How OO 최적화 · OX 솔루션 · XO 통찰 · XX 발견
2과목	하향식=문제 먼저 / 상향식=데이터 먼저
3과목	표준편차=원자료 퍼짐 / 표준오차=표본통계량의 흔들림
3과목	t=평균·개별 계수, F=모형 전체·여러 평균, 카이제곱=범주 빈도
3과목	KNN=지도학습·예측, K-means=비지도학습·군집
3과목	배깅=복원추출·병렬결합, 부스팅=순차적인 오류 보완
3과목	정밀도=TP/(TP+FP), 재현율=TP/(TP+FN)
3과목	지지도=P(A∩B), 신뢰도=P(B|A), 향상도=신뢰도/P(B)
3과목	ARIMA = AR(p)+차분(d)+MA(q) / SARIMA=계절성 추가

마지막 암기 모호한 보기에서는 용어를 먼저 구분하고, 공식은 분모부터 확인하세요.